



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional
visando eficiência energética e Latência no Processamento
Hiperespectral Embarcado**

Limeira
2025

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional visando
eficiência energética e Latência no Processamento Hiperespectral
Embarcado**

Dissertação apresentada à Faculdade de
Tecnologia da Universidade Estadual de
Campinas como parte dos requisitos para a
obtenção do título de Mestre em Tecnologia, na
área de Sistemas de Informação e Comunicação.

Orientador: Prof. Dr. Leandro Ronchini Ximenes

Este trabalho corresponde à versão final da
Dissertação defendida por Diego de Freitas
Maia e orientada pelo Prof. Dr. Leandro
Ronchini Ximenes.

Limeira
2025

Na versão final, esta página será substituída pela ficha catalográfica no TCC, na dissertação de mestrado ou na tese de doutorado.

Caso não tenha ficha catalográfica, deixe essa página em branco conforme as instruções a seguir.

No arquivo principal (`tese.tex`), adicione o nome do arquivo PDF com a ficha catalográfica como parâmetro para o comando `\fichacatalografica{}`. Caso a versão da sua dissertação ou tese seja a versão anterior à aprovação pela banca, você pode substituir esta por uma página em branco com o comando a seguir:

`\fichacatalografica{branco.pdf}`

Substitua o arquivo `branco.pdf` por `white.pdf`, nos textos em inglês, ou por `blanco.pdf`, para textos em espanhol. Todos esses arquivos PDF já estão disponíveis neste modelo.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão fazer referência ao apoio recebido e inserir esta informação na ficha catalográfica, além do nome da agência, o número do processo pelo qual recebeu o auxílio.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Prof. Dr. Leandro Ronchini Ximenes
Presidente da Comissão Julgadora

Prof.^a Dr.^a Segunda Avaliadora
Instituição da segunda avaliadora

Dr. Terceiro Avaliador
Instituição do terceiro avaliador

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria de Pós-graduação da Faculdade de Tecnologia.

Sumário

Resumo	9
Abstract	1
1 Introdução	2
1.1 Contexto e motivação	2
1.2 Objetivos	2
1.2.1 Objetivo geral	2
1.2.2 Objetivos específicos	2
1.3 Hipóteses	2
1.4 Contribuições esperadas	2
1.5 Metodologia da pesquisa (visão geral)	2
1.6 Organização do trabalho	2
2 Levantamento Bibliográfico	3
2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais	3
2.1.1 O espectro eletromagnético	4
2.1.2 Propriedades Ópticas dos Materiais	6
2.1.3 Princípios de Sensoriamento Remoto Hiperespectral	8
2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações	10
2.2.1 Tipos de Sistemas de Imageamento Hiperespectral	10
2.2.2 Principais Aplicações e Domínios de Uso	11
2.2.3 Sensores e Sistemas Comerciais Representativos	11
2.2.4 Estrutura e Dimensionalidade dos Dados	11
2.2.5 Datasets Públicos de Referência	13
2.3 Técnicas de Processamento de Imagens Hiperespectrais	13
2.3.1 Pré-processamento e Correção Radiométrica	13
2.3.2 Redução Dimensional e Seleção de Bandas	14
2.3.3 Algoritmos de Classificação Espectral	14
2.3.4 Processamento de Sinais Espectrais	14
2.4 Tipos de Processadores para Processamento Hiperespectral	15
2.4.1 Processadores de Uso Geral (CPU)	15
2.4.2 Unidades de Processamento Gráfico (GPU)	15
2.4.3 Field-Programmable Gate Arrays (FPGA)	16
2.4.4 Processadores de Sinal Digital (DSP)	16
2.4.5 Unidades de Processamento Neural (NPU/TPU)	16
2.4.6 Microcontroladores (MCU) e Processadores de Ultra-Baixo Consumo	17
2.5 Arquiteturas Heterogêneas de Processamento	17

2.5.1	Fundamentos de Computação Heterogênea	17
2.5.2	Arquiteturas CPU+GPU Integradas	17
2.5.3	Sistemas CPU+FPGA	18
2.5.4	Arquiteturas Tri-híbridas CPU+GPU+FPGA	18
2.5.5	Estudo de Caso: Arquitetura Qualcomm QCS8250	18
2.6	Plataformas de Processamento para Sensoriamento Remoto	19
2.6.1	Plataformas NVIDIA Jetson	19
2.6.2	Sistemas Embarcados Especializados	19
2.6.3	Plataformas para Aplicações Espaciais	20
2.7	Benchmarking de Plataformas no Mercado	20
2.7.1	Metodologia de Benchmarking	20
2.7.2	Análise Comparativa de Performance	20
2.7.3	Trade-offs Performance vs Consumo	21
2.7.4	Adequação por Tipo de Aplicação	21
3	Proposta e metodologia	23
4	Conclusões e trabalhos futuros	24

Lista de Figuras

Lista de Tabelas

2.1	Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamiento remoto (valores em nanômetros, nm, até 1 mm).	5
2.2	Análise comparativa de sensores hiperespectrais baseada na literatura científica	12
2.3	Benchmarking de plataformas para processamento hiperespectral	21

Resumo

Palavras-chave:

Abstract

Keywords:

Capítulo 1

Introdução

1.1 Contexto e motivação

1.2 Objetivos

1.2.1 Objetivo geral

1.2.2 Objetivos específicos

1.3 Hipóteses

1.4 Contribuições esperadas

1.5 Metodologia da pesquisa (visão geral)

1.6 Organização do trabalho

Capítulo 2

Levantamento Bibliográfico

Este capítulo apresenta a revisão da literatura sobre imageamento hiperespectral, abordando os fundamentos, tecnologias disponíveis e aplicações em sistemas embarcados. A análise foi organizada em sete seções principais: princípios físicos da espectroscopia de imageamento e formação de imagens espectrais; câmeras hiperespectrais, incluindo tipos, modelos e datasets públicos; técnicas de processamento de imagens hiperespectrais; tipos de processadores e suas características para processamento hiperespectral; arquiteturas heterogêneas de processamento; plataformas específicas para sensoriamento remoto; e benchmarking de plataformas comerciais. A revisão abrange trabalhos fundamentais da área e publicações recentes sobre aplicações em agricultura de precisão, monitoramento ambiental e sistemas embarcados, com ênfase nos desafios computacionais do processamento de grandes volumes de dados e soluções para operação em tempo real com restrições energéticas.

2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais

Os conceitos fundamentais do imageamento hiperespectral baseiam-se nos princípios da física óptica que descrevem a interação entre a radiação eletromagnética e a matéria (**Lorenzzetti2015**). Esta seção examina as características das ondas eletromagnéticas e sua organização espectral, com foco particular na faixa de 400 a 2500 nm, que abrange as regiões do visível, infravermelho próximo e infravermelho de ondas curtas, essenciais para o sensoriamento remoto. As propriedades ópticas dos materiais são analisadas através dos fenômenos de reflectância, transmitância e absorção, processos físicos que originam as assinaturas espectrais únicas de cada substância e possibilitam sua identificação e caracterização (**Baptista2019**). A compreensão da distinção entre sistemas multiespectrais e hiperespectrais, quanto à resolução espectral e capacidade de discriminação, fundamenta a escolha da tecnologia adequada para cada aplicação. Esses princípios teóricos são demonstrados através de aplicações práticas em agricultura de precisão e monitoramento ambiental, evidenciando como o conhecimento dos fundamentos físicos é indispensável para o desenvolvimento de metodologias robustas de aquisição, processamento e análise de dados hiperespectrais.

2.1.1 O espectro eletromagnético

A energia eletromagnética constitui a base física do sensoriamento remoto e do imageamento hiperespectral, podendo ter origem em fontes naturais, como o Sol, nos próprios alvos ou em sistemas ativos, como radares. Essa energia propaga-se em forma de ondas, transportando informações sobre os materiais com os quais interage. Compreender as propriedades fundamentais da radiação eletromagnética é essencial para entender os processos de aquisição e análise de dados hiperespectrais.

Definição e características das ondas eletromagnéticas

Ondas eletromagnéticas são perturbações que se propagam no espaço à velocidade da luz ($c \approx 3 \times 10^8$ m/s no vácuo). São caracterizadas principalmente pelo comprimento de onda (λ) e pela frequência (f), relacionados por:

$$c = \lambda \odot f \quad (2.1)$$

A energia (E) transportada por uma onda eletromagnética é proporcional à sua frequência, conforme a equação de Planck:

$$E = h \odot f = \frac{hc}{\lambda} \quad (2.2)$$

em que h é a constante de Planck ($6,626 \times 10^{-34}$ J⋅s).

No contexto do sensoriamento remoto, diferentes unidades são empregadas para descrever as faixas espectrais:

- 1 kHz = 1×10^3 Hz
- 1 MHz = 1×10^6 Hz
- 1 GHz = 1×10^9 Hz
- 1 THz = 1×10^{12} Hz
- 1 μm = 1×10^{-6} m
- 1 nm = 1×10^{-9} m

Neste trabalho adota-se a unidade de micrometro (μm) para o comprimento de onda.

Regiões espectrais: do ultravioleta ao infravermelho

O espectro eletromagnético é dividido em regiões conforme as propriedades físicas da radiação e sua interação com a matéria (Lorenzetti2015; Baptista2019). Para sensoriamento remoto, destacam-se as seguintes faixas:

Ultravioleta (UV): 300 μm a 0,4 μm . Pouco utilizada em sensoriamento remoto terrestre devido à absorção atmosférica, mas relevante em aplicações específicas.

Visível: 0,4 a 0,7 μm , correspondente à radiação percebida pelo olho humano. Subdivisões usuais:

- Azul: 0,4—0,5 μm
- Verde: 0,5—0,6 μm

- Vermelho: 0,6—0,7 μm

Infravermelho próximo (NIR): 0,7 a 1,3 μm . Importante para estudos de vegetação devido à alta reflectância da clorofila.

Infravermelho de ondas curtas (SWIR): 1,3 a 3,0 μm . Fundamental para identificação de minerais e análise de umidade.

Os limites exatos dessas faixas podem variar entre autores, mas há consenso sobre as principais subdivisões. A Tabela 2.1 apresenta as subfaixas do infravermelho mais utilizadas em sensoriamento remoto.

Tabela 2.1: Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).

Faixa	Subfaixa	Comprimento de onda
Raios-X	—	0,03—30 nm
Ultravioleta	—	30—400 nm
Visível	—	400—700 nm
3*Infravermelho	NIR/IVP	740—1 000 nm
	SWIR/IVOC	1 000—3 000 nm
	LWIR/IVTM	3 000—14 000 nm
Micro-ondas	—	1—30 mm
Ondas de rádio	—	>30 mm

Observa-se que, em algumas referências (**Lorenzzetti2015; Baptista2019**), a faixa de micro-ondas pode ser definida como indo de 1 mm até 1 m. Essas variações não comprometem a aplicação prática dos conceitos, mas devem ser consideradas ao comparar diferentes trabalhos.

Comprimentos de onda relevantes para sensoriamento remoto (400–2500 nm)

Para aplicações de imageamento hiperespectral e sensoriamento remoto, a faixa espectral de 400 a 2500 nm (0,4 a 2,5 μm) representa a região de maior interesse prático. Essa faixa abrange as regiões do visível, infravermelho próximo (NIR) e infravermelho de ondas curtas (SWIR), onde ocorrem os principais fenômenos de interação radiação-matéria relevantes para identificação e caracterização de materiais terrestres.

Região VNIR (400–1000 nm): A faixa do visível e infravermelho próximo é fundamental para estudos de vegetação e classificação de cobertura terrestre. Nessa região, processos eletrônicos dominam a absorção da radiação, resultando em transições entre níveis de energia eletrônica nos átomos e moléculas. A clorofila, por exemplo, apresenta forte absorção nas regiões azul (430–450 nm) e vermelha (640–660 nm), enquanto exibe alta reflectância no NIR (700–1000 nm).

Região SWIR (1000–2500 nm): No infravermelho de ondas curtas, as absorções são governadas por processos vibracionais moleculares. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo decorrem de efeitos do campo cristalino, enquanto outros processos eletrônicos produzem feições espectrais

significativas nessa faixa. Essa região é particularmente rica em informações sobre minerais, conteúdo de água e compostos orgânicos.

As transições entre níveis de energia são responsáveis pelas faixas de absorção nos espectros. As absorções são governadas por processos vibracionais, sendo que átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico resulta da mudança de um estado de energia mais baixo para um mais alto, enquanto a emissão resulta da mudança de um estado de energia mais alto para um mais baixo, com liberação de energia no mesmo comprimento de onda.

A compreensão dos fundamentos físicos da interação radiação-matéria é essencial para o desenvolvimento de algoritmos de processamento hiperespectral eficazes e para a interpretação adequada dos dados espectrais em aplicações práticas de sensoriamento remoto.

2.1.2 Propriedades Ópticas dos Materiais

As propriedades ópticas dos materiais constituem a base física que permite a identificação e caracterização de diferentes substâncias através do sensoriamento remoto hiperespectral (**Baptista2019**). Quando a radiação eletromagnética interage com um material, três processos fundamentais podem ocorrer: reflexão, absorção e transmissão. A compreensão destes processos e dos fatores que os influenciam é essencial para o desenvolvimento de técnicas eficazes de análise espectral e para a interpretação adequada dos dados hiperespectrais em aplicações práticas.

Reflectância Espectral: Definição e Fatores Influenciadores

A espectroscopia de reflectância é o estudo da radiação eletromagnética como função do comprimento de onda em que ela está sendo refletida, emitida ou espalhada por um gás, um líquido ou um sólido (**Baptista2019**). A energia refletida pelas superfícies pode ser entendida como a porção da energia incidente, subtraindo-se as perdas que foram absorvidas ou transmitidas.

A reflectância espectral $\rho.\lambda/$, função do comprimento de onda (λ), pode ser definida matematicamente como a razão entre a radiância da superfície $[L(\lambda)]$ expressa em $W\ m^{-2}\ sr^{-1}\ \mu m^{-1}$ no comprimento de onda (λ) e a irradiância incidente $[E(\lambda)]$ em $W\ m^{-2}\ \mu m^{-1}$ no comprimento de onda (λ), conforme a equação:

$$\rho.\lambda/ = \pi \frac{L.\lambda/}{E.\lambda/} \quad (2.3)$$

Esta definição estabelece a base quantitativa para a medição e comparação das propriedades espectrais de diferentes materiais (**Baptista2019**). O Sol é a principal fonte natural de energia eletromagnética nas faixas do espectro do ultravioleta, do visível, do infravermelho próximo e do infravermelho de ondas curtas. Em comprimentos de onda maiores, na faixa do infravermelho termal, a eficiência do Sol como fonte de energia é bastante reduzida e a Terra passa a ter maior eficiência como fonte, porém nesta faixa não se analisa o espectro óptico de reflectância e sim o de emitância.

O processo de interação dos fótons com a matéria resulta em que parte deles é refletida pelos grãos da superfície do material, alguns passam pelos grãos e alguns são absorvidos (**Baptista2019**). Os fótons são absorvidos pelos minerais por diversos

processos que dependem de sua composição química. Essas absorções são governadas por dois processos gerais: processos eletrônicos e processos vibracionais.

Fatores Físicos Influenciadores:

Composição química: A composição química do material determina fundamentalmente suas características espectrais. Diferentes elementos e compostos apresentam absorções características em comprimentos de onda específicos, criando as feições espectrais diagnósticas que permitem sua identificação (**Baptista2019**).

Estrutura cristalina: A organização atômica em materiais cristalinos influencia significativamente as propriedades ópticas. O efeito de campo cristalino, processo eletrônico mais comumente encontrado nos espectros de minerais, é devido aos elétrons desemparelhados dos orbitais internos dos elementos de transição (Sc, Ti, V, Cr, Mn, Fe, Co, Ni, Cu e Zn).

Tamanho de partícula: O tamanho das partículas que compõem a superfície afeta significativamente a reflectância espectral. Partículas menores tendem a aumentar o espalhamento múltiplo, resultando em maior reflectância geral, enquanto partículas maiores podem aumentar a absorção.

Rugosidade superficial: A microtopografia da superfície influencia o padrão de espalhamento da radiação incidente. Superfícies rugosas tendem a produzir espalhamento difuso, enquanto superfícies lisas podem apresentar componentes especulares significativos.

Conteúdo de umidade: A presença de água nas amostras introduz absorções características em 1,4 μm e 1,9 μm , além de afetar a intensidade geral da reflectância através do aumento da absorção.

Transmitância e Absorção: Princípios Físicos

Os processos de transmitância e absorção estão intimamente relacionados com os mecanismos quânticos de interação entre radiação eletromagnética e matéria (**Baptista2019**). A compreensão destes processos é fundamental para interpretar as feições espectrais observadas nos dados hiperespectrais.

Processos Eletrônicos:

Átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico é a causa da mudança de um estado de energia mais baixo para um mais alto. Já a emissão de um fóton é resultado da mudança de um estado de energia mais alto para um mais baixo. Quando um fóton é absorvido, de modo geral ele não é posteriormente emitido no mesmo comprimento de onda (**Baptista2019**).

As transições entre os níveis de energia são responsáveis pelas feições de absorção nos espectros. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo são decorrentes de efeitos do campo cristalino, porém outros processos eletrônicos produzem feições espectrais importantes.

Efeito de Campo Cristalino:

O ferro é o elemento de transição mais comum na composição dos minerais que existem na superfície da Terra (**Baptista2019**). Os orbitais d de todos os elementos de transição apresentam níveis de energia idênticos nos íons isolados, mas, quando o íon se localiza em um campo cristalino, os níveis de energia desses orbitais se dividem. De acordo com a teoria de campo cristalino para o caso do Fe^{3+} , por exemplo, os cinco orbitais de valência d do íon livre do elemento de transição que se encontram em níveis iguais de energia são

submetidos a um processo de repulsão eletrostática por causa da proximidade dos ligantes com carga negativa.

Esta divisão dos níveis energéticos resulta em absorções características que permitem a identificação de minerais específicos através de suas assinaturas espectrais.

Processos Vibracionais:

Em comprimentos de onda maiores, particularmente na região do infravermelho de ondas curtas (SWIR), os processos vibracionais dominam as absorções espectrais (**Baptista2019**). Estes processos envolvem vibrações moleculares que ocorrem em frequências específicas, criando absorções características para diferentes grupos funcionais e ligações químicas.

2.1.3 Princípios de Sensoriamento Remoto Hiperespectral

Interação Radiação-Matéria no Contexto de Sensoriamento Remoto

O sensoriamento remoto hiperespectral fundamenta-se nos princípios físicos da interação entre radiação eletromagnética e matéria, constituindo uma extensão natural dos conceitos fundamentais abordados nas seções anteriores. A definição de sensoriamento remoto (SR) está sujeita a diferentes interpretações na literatura científica. De acordo com *Manual of Remote Sensing* (Ulaby, 1983), bem como em Elachi e Zyl (2006), SR é definido como a aquisição de informação sobre alguma propriedade de um objeto ou fenômeno sem contato físico com ele. A informação sobre um alvo seria obtida pela detecção e medida de mudanças que o objeto impõe sobre o meio circundante, seja ele eletromagnético, acústico ou potencial.

Schowengerdt (2007) considera SR como “a medida das propriedades de um objeto ou da superfície da Terra usando dados adquiridos de sensores e sistemas”, sendo um pouco mais restritivo. Segundo Slater (1980), SR é o conjunto de atividades utilizadas para a aquisição de informações relativas aos recursos naturais da Terra, ou ao seu meio ambiente, obtidas pela análise da energia eletromagnética refletida, emitida ou retroespalhada pelos alvos, coletada por meio de sensores remotos (**Baptista2019**).

No contexto hiperespectral, a interação radiação-matéria adquire uma dimensão adicional de complexidade devido à alta resolução espectral dos sistemas de imageamento. Enquanto os processos eletrônicos e vibracionais descritos anteriormente permanecem fundamentalmente os mesmos, a capacidade de detectar e quantificar feições espectrais sutis é significativamente ampliada. (CLARK, 1999 apud LORENZZETTI, 2015) considera que quatro parâmetros gerais definem a capacidade de um espectrorradiômetro (sensor espectral): a faixa espectral, a largura das bandas espectrais, a amostragem espectral e a razão sinal/ruído.

A faixa espectral de resolução utilizada em sensoriamento remoto abrange tipicamente os seguintes intervalos espectrais: de 0,3 a 1,0 μm , chamado de visível e infravermelho próximo; de 1,0 a 2,5 μm , infravermelho de ondas curtas. A faixa do infravermelho termal situa-se a partir de 3,0 μm até aproximadamente o pico máximo de emitância da Terra em torno de 10,0 μm (**Lorenzzetti2015**).

A largura da banda espectral é definida por (CLARK, 1999 apud LORENZZETTI, 2015) como a largura de um canal espectral individual no espectrorradiômetro. Quanto mais estreita for a largura da banda espectral, mais precisa será a determinação da feição de absorção do mineral. Alguns sistemas sensores possuem bandas largas e não espectralmente contíguas, não permitindo como contínuas, enquanto outros sistemas,

como o AVIRIS, apresentam largura de bandas espectrais estreitas com espaçamento contínuo e permitem a identificação de feições características dos minerais.

Sensores Multiespectrais vs. Hiperspectrais: Diferenças Fundamentais

A distinção fundamental entre sensores multiespectrais e hiperspectrais reside na resolução espectral e na capacidade de discriminação de materiais. O perfil da largura também é importante. O ideal é que cada canal de um espectrorradiômetro rejeite toda radiação que não esteja dentro do alcance estreito de determinado comprimento de onda. Mas o que geralmente ocorre, em virtude de efeitos ópticos muito complexos, é que a radiação pode vazar, difundindo-se dentro do sistema óptico ou dentro do sistema de filtros bloqueadores.

Normalmente a largura do perfil é definida como a largura em comprimento de onda em 50% do nível de resposta da função do detector, chamado de largura a meia altura (FWHM) (CLARK, 1999 apud LORENZZETTI, 2015). A razão sinal/ruído (S/N) visa a obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes.

A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície. Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 apud LORENZZETTI, 2015).

Sistemas multiespectrais convencionais, como o sensor Landsat TM5, operam com bandas espectrais relativamente largas e espaçadas, tipicamente entre 6 a 12 bandas cobrindo o espectro eletromagnético de interesse. O sistema Landsat é o *Moderate Resolution Imaging Spectroradiometer* (MODIS) não permitem a percepção de feições de absorção estreitas. A figura 3.1, desenvolvida por (GREEN, 1997 apud LORENZZETTI, 2015), apresenta como o sensor Landsat TM5 captaria as feições de absorção de três minerais: hematita, caulinita e dolomita.

A caulinita apresenta sua feição espectral mais característica em $2,2 \mu\text{m}$. Já a dolomita, assim como a calcita, apresenta essa feição próxima para sua identificação, em $2,3 \mu\text{m}$. As feições espectrais utilizadas para identificação da caulinita e dolomita (ou da calcita, pois essas são semelhantes) não podem ser discriminadas, pois aparecem integradas na banda 7 ($2,08$ a $2,35 \mu\text{m}$) do sistema sensor TM5 do Landsat.

Aplicações Práticas: Agricultura de Precisão e Monitoramento Ambiental

As aplicações práticas do sensoriamento remoto hiperspectral em agricultura de precisão e monitoramento ambiental demonstram o potencial da tecnologia para resolver problemas reais com alta precisão e especificidade, constituindo um dos principais motivos para o desenvolvimento de sistemas embarcados eficientes.

Agricultura de Precisão:

Na agricultura de precisão, os sistemas hiperspectrais permitem o monitoramento detalhado da saúde vegetal, detecção precoce de estresses bióticos e abióticos, e estimativa de parâmetros biofísicos das culturas. A região do infravermelho próximo ($700\text{--}1000 \text{ nm}$) é particularmente importante devido à alta reflectância da clorofila, permitindo a avaliação do vigor vegetativo através de índices espectrais específicos.

As feições de absorção no SWIR (1400 nm e 1900 nm) são diagnósticas para o conteúdo de água nas plantas, facilitando o monitoramento de estresse hídrico em tempo real. Esta

capacidade é fundamental para sistemas embarcados em UAVs que operam em agricultura de precisão, permitindo tomada de decisões imediatas sobre irrigação e manejo de culturas.

A capacidade de discriminar espécies vegetais e estágios fenológicos através de suas assinaturas espectrais únicas representa um avanço significativo sobre os métodos convencionais. Sistemas hiperespectrais embarcados podem detectar variações sutis na composição bioquímica foliar, incluindo concentrações de clorofila, carotenoides, antocianinas e compostos estruturais como celulose e lignina.

Monitoramento Ambiental:

No monitoramento ambiental, a tecnologia hiperespectral oferece capacidades sem precedentes para a caracterização de materiais superficiais, qualidade da água e detecção de poluentes. A identificação de minerais específicos através de suas feições espectrais características permite o mapeamento geológico detalhado e a detecção de alterações hidrotermais associadas a depósitos minerais.

Para qualidade da água, os sensores hiperespectrais podem detectar e quantificar constituintes opticamente ativos como clorofila-a, sedimentos em suspensão, matéria orgânica dissolvida e diversos poluentes. As absorções características desses materiais em comprimentos de onda específicos permitem sua identificação e quantificação com precisão superior aos métodos convencionais.

A detecção de mudanças ambientais, sejam elas naturais ou antropogênicas, beneficia-se da alta sensibilidade espectral dos sistemas hiperespectrais. Alterações sutis na composição química ou física dos materiais superficiais, que seriam imperceptíveis em imagens multiespectrais, tornam-se detectáveis através da análise das variações nas assinaturas espectrais.

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo.

Aplicações Militares e de Defesa:

Grande parte das aplicações de sensoriamento remoto para fins militares é focada na detecção e classificação de alvos e no mapeamento de terrenos e instalações. Em geral, os dados obtidos (coletados por satélites ou por dispositivos aerotransportados) por aviões usados para aplicações militares são considerados como *classificados* (não disponíveis para terceiros) e de alta resolução espacial. Como definido por Simonett et al. (1983) e Jensen (2009), entende-se por resolução espacial, considera-se como resolução espacial de um sistema sensor a menor separação espacial angular ou linear entre dois objetos que podem ser detectados.

Um detalhamento mais aprofundado sobre o conceito de resolução pode ser encontrado em Forshaw et al. (1983) e Townshend (1980). Como uma imagem digital é constituída por *pixels*, costuma-se associar o tamanho do *pixel* para a resolução da imagem. Entretanto, essa definição dá a impressão de que somente podemos resolver objetos de tamanho maior, ou igual ao tamanho do *pixel*, o que nem sempre é verdade. A definição de alto contraste com pixels vizinhos, são mostrados por Schowengerdt (2007).

Sistemas de Sensoriamento Remoto: Componentes e Funcionamento:

A Figura 1.1 (LORENZZETTI, 2015) mostra esquematicamente como se processa a aquisição de informação sobre um alvo (geralmente, mas não sempre, na superfície da Terra) por meio da técnica de sensoriamento remoto. Os seguintes aspectos devem ser levados em conta:

1. As características da energia que incide sobre o alvo, quando proveniente de uma fonte tal qual o Sol, ou mesmo de uma antena de um sensor ativo como um radar, ou da energia do próprio alvo como no caso das aplicações de infravermelho termal (IVTI). Aí devemos levar em conta, por exemplo, a distribuição espectral, a intensidade e a polarização da radiação.
2. As características do meio em que essa energia se propaga (a atmosfera, ou coluna d'água para aplicações oceanográficas e limnológicas), isto é, as propriedades de absorção, espalhamento e emissão.
3. As propriedades do alvo (albedo, refletividade, rugosidade, emissividade etc.).
4. As próprias características do sensor (campo de visada, responsividade espectral, relação sinal/ruído, nível mínimo de resposta e variação ao grau de polarização (GDP) da radiação).

Para sensores ativos do tipo radar, em vez de fonte de energia ser o Sol, o próprio sensor emite pulsos de energia eletromagnética, que são parcialmente retroespalhados de volta ao sensor. Nesta situação específica de sensores remotos, os sistemas sensores são desenhados para receber prioritariamente a energia emitida pelo alvo, que é, entre vários fatores, dependente de sua temperatura (LORENZZETTI, 2015).

Desafios Técnicos e Limitações:

Os sistemas hiperespectrais enfrentam desafios únicos relacionados ao processamento de grandes volumes de dados em tempo real. A razão sinal/ruído (S/N) visa à obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes. A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície.

O teorema de Nyquist determina que o máximo de informação é obtido quando a amostragem espectral é igual à metade do FWHM; às vezes, porém, uma razão de amostragem diferente. Muitos dos espectrômetros modernos em uso (por exemplo, o AVIRIS) possuem um intervalo de amostragem de aproximadamente 10 nm e FWHM de 10 nm (CLARK, 1999 *apud* LORENZZETTI, 2015).

Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 *apud* LORENZZETTI, 2015). Esta limitação é particularmente relevante para sistemas embarcados, onde restrições de peso, energia e processamento computacional impõem desafios adicionais à manutenção de alta qualidade espectral.

Integração com Sistemas Embarcados:

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo. Os sistemas embarcados devem balancear os requisitos de alta resolução espectral com as limitações de processamento computacional, armazenamento de dados e consumo energético, especialmente em plataformas UAV onde peso e autonomia são fatores críticos.

Esta necessidade de otimização computacional motiva o desenvolvimento de algoritmos eficientes e arquiteturas de processamento especializadas, temas que serão abordados em detalhes nas próximas seções desta dissertação.

2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações

Esta seção apresenta uma análise abrangente das tecnologias de imageamento hiperespectral disponíveis, abordando desde os princípios de funcionamento até as aplicações práticas. O foco está nos sistemas comerciais representativos, suas características técnicas e adequação para diferentes tipos de aplicação, incluindo datasets públicos de referência utilizados para validação e benchmarking.

2.2.1 Tipos de Sistemas de Imageamento Hiperespectral

- **Whiskbroom (varredura pontual):** Sensores que capturam um pixel por vez, realizando varredura mecânica em duas dimensões
- **Pushbroom (varredura linear):** Capturam uma linha completa de pixels simultaneamente, sendo o tipo mais comum em plataformas aéreas e UAVs
- **Snapshot (imageamento instantâneo):** Adquirem toda a informação espacial e espectral em uma única exposição

2.2.2 Principais Aplicações e Domínios de Uso

- **Agricultura de precisão:** Monitoramento de saúde vegetal, detecção de pragas e estresse hídrico
- **Monitoramento ambiental:** Qualidade da água, detecção de poluentes e análise de cobertura vegetal
- **Aplicações industriais:** Inspeção de qualidade, classificação de materiais e controle de processos
- **Defesa e vigilância:** Detecção de alvos camuflados e identificação de materiais

2.2.3 Sensores e Sistemas Comerciais Representativos

O desenvolvimento de sistemas hiperespectrais comerciais tem apresentado avanços significativos nos últimos anos, com diferentes fabricantes oferecendo soluções adaptadas para aplicações específicas em agricultura de precisão, monitoramento ambiental, inspeção industrial e uso embarcado em VANTs. Alguns fabricantes como Specim, Resonon e Cubert oferecem soluções comerciais interessantes para essas aplicações. Na Tabela 2.2 é apresentada uma análise aprofundada dos principais sensores e sistemas disponíveis no mercado, suas características técnicas e aplicações práticas.

Vimos na Seção 2.2.1 a classificação dos sistemas de imageamento hiperespectral quanto à tecnologia de aquisição. Entre os sistemas do tipo pushbroom, destacam-se o Specim FX10, amplamente empregado em aplicações embarcadas em UAVs devido ao seu baixo peso e alta taxa de aquisição, o Resonon Pika L, reconhecido por sua robustez em monitoramento de vegetação e qualidade da água, e o Headwall Nano-Hyperspec, notável pela adaptabilidade a plataformas compactas. No segmento dos sistemas snapshot, que realizam a captura simultânea de toda a cena espectral e espacial, sobressaem o Cubert S185 FirefEYE SE e soluções baseadas em filtros Fabry-Pérot, ambos voltados para aplicações que demandam imageamento instantâneo e

Tabela 2.2: Análise comparativa de sensores hiperespectrais baseada na literatura científica

Sensor/Sistema	Tecnologia de Aquisição	Faixa Espectral	Características Espectrais	Performance Reportada	Referência/Aplicação
Specim FX10	Pushbroom	400–1000 nm (VNIR)	224 bandas espectrais 1024 pixels espaciais	Taxa: até 330 FPS Throughput: 144,375 MB/s	Agricultura UAV Validação em campo
Resonon Pika L	Pushbroom	400–1000 nm	281 bandas espectrais 900 pixels espaciais 12 bits/pixel	Taxa: 249 FPS Throughput: 94,45 MB/s Com binning 2x: 47,22 MB/s	Aplicações em monitoramento de vegetação e qualidade da água
Resonon PIKA-NIR-320	Pushbroom	900–1700 nm (NIR-SWIR)	164 bandas espectrais 320 pixels espaciais 168 canais totais	Taxa: até 520 Hz Pixel size: 30 μ m Line-scan operation	Deteção de resíduos marinhos flutuantes
Cubert S185 Firefly SE	Snapshot	450–950 nm	125 bandas espectrais 1 MP (1000x1000) 12/14 bits	Taxa: até 25 Hz 5 cubos hiperespectrais/s Throughput: 31,25 MB/s Consumo: 15 W, Peso: 490 g	Monitoramento de saúde vegetal e análise agrícola
Headwall Nano-Hyperspec	Pushbroom	400–1000 nm	270 bandas espectrais 640 pixels espaciais	Taxa: 300 FPS Throughput: 103,68 MB/s Armazenamento: adaptabilidade 480 GB	Pequenas plataformas UAV, excelente
Sistemas baseados em Filtros Fabry-Pérot	Snapshot (Captura única)	Variável conforme filtros	150+ bandas Filtros sintonizáveis	Performance variável dependente da aplicação	Tecnologia IMEC Imageamento instantâneo

portabilidade. A escolha entre esses modelos está diretamente relacionada ao tipo de aplicação, requisitos de portabilidade e necessidades de processamento em tempo real.

Um dos principais desafios no uso desses sistemas é o gerenciamento do alto volume de dados gerados. Os sensores hiperespectrais produzem throughput na faixa de 30 MB/s a 300 MB/s, exigindo interfaces de alta velocidade como USB 3.0, Camera Link ou GigE Vision, além de soluções de armazenamento local com capacidade e velocidade adequadas. Para ilustrar a magnitude desse desafio, sistemas operando em capacidade máxima podem gerar aproximadamente 4,15 TB de dados em 8 horas de operação contínua, ou até 6 GB por minuto quando embarcados em VANTs.

2.2.4 Estrutura e Dimensionalidade dos Dados

Os dados hiperespectrais são organizados em estruturas tridimensionais denominadas cubos hiperespectrais, onde duas dimensões representam informações espaciais (x , y) e a terceira dimensão contém informações espectrais (λ). Esta organização permite a análise simultânea de características espaciais e espectrais dos objetos imageados.

2.2.5 Datasets Públicos de Referência

Os datasets públicos constituem recursos fundamentais para validação e comparação de algoritmos de processamento hiperespectral. Os principais datasets utilizados na literatura científica incluem:

- **AVIRIS Indian Pines:** Dataset padrão de $614 \times 512 \times 224$ bandas para classificação em agricultura de precisão, amplamente utilizado para benchmarking de algoritmos de classificação
- **Pavia University:** Dataset urbano de $610 \times 340 \times 103$ bandas, ideal para validação de técnicas de segmentação e classificação em ambiente urbano
- **Salinas Valley:** Dataset agrícola de $512 \times 217 \times 224$ bandas, focado em aplicações de monitoramento de cultivos e análise de vegetação
- **Kennedy Space Center:** Dataset de $512 \times 614 \times 176$ bandas para aplicações de classificação de cobertura terrestre em ambiente costeiro
- **Botswana:** Dataset de $1476 \times 256 \times 145$ bandas para classificação de vegetação em savana africana, importante para estudos de biodiversidade

Estes datasets servem como benchmarks padrão na literatura, permitindo comparação sistemática de algoritmos e validação de técnicas de otimização em sistemas embarcados.

2.3 Técnicas de Processamento de Imagens Hiperespectrais

O processamento de imagens hiperespectrais envolve uma cadeia complexa de algoritmos especializados, desde o pré-processamento básico até técnicas avançadas de análise espectral. Esta seção apresenta as principais abordagens utilizadas na literatura, com foco nas técnicas que demonstram potencial para implementação em sistemas embarcados.

2.3.1 Pré-processamento e Correção Radiométrica

O pré-processamento constitui etapa fundamental para garantir a qualidade dos dados hiperespectrais, especialmente em sistemas embarcados operando sob condições variáveis de iluminação e movimento:

- **Calibração radiométrica:** Correção das variações de resposta do sensor e normalização para valores de reflectância absoluta
- **Correção atmosférica:** Remoção dos efeitos de absorção e espalhamento atmosférico, particularmente crítica em aplicações aéreas
- **Correção geométrica:** Compensação de distorções geométricas causadas pelo movimento da plataforma e geometria de aquisição
- **Redução de ruído:** Filtragem de ruídos espectrais e espaciais, incluindo remoção de pixels defeituosos e bandas ruidosas

2.3.2 Redução Dimensional e Seleção de Bandas

A alta dimensionalidade dos dados hiperespectrais (centenas de bandas espectrais) apresenta desafios computacionais significativos, tornando as técnicas de redução dimensional essenciais para sistemas embarcados:

- **Principal Component Analysis (PCA):** Técnica linear clássica que projeta os dados em subespaço de menor dimensionalidade preservando máxima variância
- **Seleção de bandas baseada em entropia:** Métodos como EMCR (Entropy Multiple Correlation Ratio) que reduzem 80% do processamento mantendo alta precisão de classificação
- **Compressive sensing:** Técnicas que exploram a esparsidade natural dos dados hiperespectrais, conseguindo reduções de 50-70% no volume de dados
- **Independent Component Analysis (ICA):** Decomposição em componentes estatisticamente independentes, adequada para separação de assinaturas espectrais sobrepostas

2.3.3 Algoritmos de Classificação Espectral

A classificação espectral representa uma das aplicações mais importantes do processamento hiperespectral, sendo fundamental para identificação e mapeamento de materiais:

- **Support Vector Machines (SVM):** Classificadores robustos que demonstram excelente desempenho em dados hiperespectrais, com implementações otimizadas em FPGA atingindo 99,7% de precisão
- **Redes Neurais Convolucionais (CNN):** Arquiteturas como TakuNet que conseguem 99% de redução de parâmetros mantendo F1-score de 0,943, adequadas para sistemas embarcados

- **Random Forest:** Métodos ensemble que combinam múltiplas árvores de decisão, oferecendo boa interpretabilidade e robustez
- **Spectral Angle Mapper (SAM):** Classificação baseada em similaridade angular entre espectros, computacionalmente eficiente para implementações embarcadas

2.3.4 Processamento de Sinais Espectrais

O processamento específico dos sinais espectrais envolve técnicas matemáticas especializadas para extração de informações dos dados hiperespectrais:

- **Análise de mistura espectral:** Decomposição de pixels mistos em endmembers puros, fundamental para aplicações de mapeamento quantitativo
- **Detecção de anomalias:** Identificação de pixels com características espectrais atípicas, importante para aplicações de vigilância e monitoramento ambiental
- **Análise de derivadas espectrais:** Cálculo de derivadas primeira e segunda dos espectros para realçar características espectrais sutis
- **Transformadas espectrais:** Aplicação de transformadas como Fourier e Wavelet para análise no domínio da frequência

2.4 Tipos de Processadores para Processamento Hiperespectral

A escolha adequada do tipo de processador é fundamental para o desenvolvimento de sistemas hiperespectrais embarcados eficientes. Esta seção analisa as características, vantagens e limitações dos principais tipos de processadores utilizados para processamento hiperespectral, considerando aspectos como desempenho computacional, consumo energético e adequação para diferentes tipos de algoritmos.

2.4.1 Processadores de Uso Geral (CPU)

As CPUs permanecem como componente central em sistemas hiperespectrais embarcados, especialmente adequadas para tarefas sequenciais e de controle:

- **Arquiteturas ARM:** Processadores de baixo consumo como ARM Cortex-A series, amplamente utilizados em plataformas embarcadas devido ao excelente balanço desempenho/consumo
- **Arquiteturas x86:** Intel Atom e AMD embedded, oferecendo maior poder computacional com consumo moderado para aplicações que requerem compatibilidade com software legado
- **Características para processamento hiperespectral:** Adequadas para tarefas de controle de fluxo, pré-processamento sequencial e algoritmos de classificação final
- **Limitações:** Baixo throughput para operações matriciais massivamente paralelas características do processamento hiperespectral

2.4.2 Unidades de Processamento Gráfico (GPU)

As GPUs se destacam no processamento hiperespectral devido à natureza paralelizável das operações matriciais:

- **GPUs embarcadas NVIDIA:** Jetson series (Nano, TX2, Xavier, Orin) que combinam GPUs com CPUs ARM em single-board computers de baixo consumo
- **Arquiteturas CUDA:** Milhares de cores especializados em operações de ponto flutuante, ideais para álgebra linear e operações matriciais
- **Performance em processamento hiperespectral:** Demonstram throughput superior a 330 fps em compressão hiperespectral (Jetson TX2) e excelente desempenho em CNNs para classificação
- **Consumo energético:** Faixa de 5-20W para modelos embarcados, adequado para aplicações UAV com restrições energéticas

2.4.3 Field-Programmable Gate Arrays (FPGA)

Os FPGAs oferecem a máxima flexibilidade para implementação de algoritmos hiperespectrais otimizados:

- **Paralelismo customizado:** Capacidade de implementar arquiteturas de processamento específicas para algoritmos hiperespectrais, como pipelines de seleção de bandas e classificação SVM
- **Eficiência energética:** Implementações otimizadas podem atingir melhorias energéticas de 43,5x comparado a implementações em software (codesign HW/SW)
- **Latência ultra-baixa:** Tempo de classificação de 0,1ms/pixel em implementações otimizadas de SVM com seleção EMCR
- **Adequação para pré-processamento:** Ideais para implementação de filtros, correções geométricas e operações de pipeline de baixa latência

2.4.4 Processadores de Sinal Digital (DSP)

Os DSPs são especializados em processamento de sinais e operações matemáticas intensivas:

- **Arquiteturas especializadas:** Unidades como Hexagon da Qualcomm com extensões vetoriais otimizadas para algoritmos matemáticos
- **Baixa latência:** Adequados para algoritmos de filtragem espectral e operações de convolução em tempo real
- **Eficiência energética:** Excelente relação operações/consumo para algoritmos específicos de processamento de sinais
- **Aplicações típicas:** Estabilização de imagem, filtragem de ruído e processamento de sinais de sensores

2.4.5 Unidades de Processamento Neural (NPU/TPU)

Processadores especializados em aceleração de algoritmos de machine learning e deep learning:

- **Arquiteturas dedicadas:** Unidades como Google TPU e NPUs integradas em SoCs, otimizadas para operações de tensor e redes neurais
- **Alto throughput para IA:** Capacidade de 15 TOPS (trilhões de operações por segundo) em modelos compactos
- **Adequação para CNNs hiperespectrais:** Ideais para execução de redes neurais otimizadas como TakuNet e arquiteturas híbridas CNN+Transformer
- **Consumo otimizado:** Eficiência energética superior para cargas de trabalho de deep learning comparado a GPUs generalistas

2.4.6 Microcontroladores (MCU) e Processadores de Ultra-Baixo Consumo

Para aplicações com severas restrições energéticas, MCUs especializados oferecem alternativas interessantes:

- **Arquiteturas ARM Cortex-M:** MCUs de 32 bits com consumo na faixa de miliampères, adequados para pré-processamento básico e controle de sensores
- **MCUs com aceleração matemática:** Unidades com coprocessadores matemáticos (FPU) para operações de ponto flutuante básicas
- **Aplicações específicas:** Controle de sensores, aquisição de dados e pré-processamento básico em sistemas com orçamento energético extremamente restrito
- **Limitações:** Capacidade de processamento limitada para algoritmos complexos de classificação e análise espectral

2.5 Arquiteturas Heterogêneas de Processamento

As arquiteturas heterogêneas combinam diferentes tipos de processadores para otimizar simultaneamente desempenho, consumo energético e latência. Esta abordagem é particularmente relevante para processamento hiperespectral embarcado, onde diferentes estágios do pipeline computacional se beneficiam de tipos distintos de processadores.

2.5.1 Fundamentos de Computação Heterogênea

A computação heterogênea baseia-se no princípio de que diferentes tipos de processadores possuem eficiências variáveis para diferentes tipos de cargas computacionais:

- **Especialização de processadores:** Cada tipo de processador (CPU, GPU, FPGA, DSP) apresenta vantagens específicas para determinados tipos de operações

- **Particionamento de algoritmos:** Divisão do pipeline de processamento em estágios adequados para cada tipo de processador
- **Otimização multi-objetivo:** Balanceamento simultâneo entre desempenho, consumo energético, latência e precisão
- **Codesign HW/SW:** Metodologia integrada de desenvolvimento que considera hardware e software simultaneamente

2.5.2 Arquiteturas CPU+GPU Integradas

A combinação de CPU e GPU em sistemas embarcados oferece flexibilidade e desempenho para processamento hiperspectral:

- **SoCs ARM+GPU:** Sistemas como NVIDIA Jetson que integram CPUs ARM com GPUs CUDA em single-package solutions
- **Divisão de tarefas:** CPU responsável por controle, pré-processamento sequencial e classificação final; GPU para operações matriciais, filtragem e redes neurais
- **Comunicação eficiente:** Memória compartilhada e interfaces de alta velocidade para minimizar overhead de transferência de dados
- **Performance demonstrada:** Throughput >330 fps em compressão hiperspectral com consumo <20W

2.5.3 Sistemas CPU+FPGA

A combinação CPU+FPGA oferece máxima flexibilidade para otimização de algoritmos específicos:

- **Aceleração customizada:** FPGA implementa algoritmos críticos como seleção de bandas EMCR e classificação SVM otimizada
- **Pipeline de baixa latência:** Processamento contínuo com latência determinística, adequado para aplicações de tempo real
- **Eficiência energética:** Melhorias de até 43,5x no consumo energético através de codesign otimizado
- **Flexibilidade de reconfiguração:** Capacidade de adaptar o hardware para diferentes algoritmos e requisitos de aplicação

2.5.4 Arquiteturas Tri-híbridas CPU+GPU+FPGA

A integração de três tipos de processadores permite otimização máxima do pipeline hiperspectral:

- **Especialização por estágio:** FPGA para pré-processamento e seleção de bandas; GPU para reconstrução e operações matriciais; CPU para classificação final e controle

- **Balanceamento de carga:** Distribuição dinâmica de tarefas conforme disponibilidade de recursos e características dos dados
- **Metas quantitativas:** Potencial para atingir >30 fps em imagens $614 \times 512 \times 224$ com consumo <15W e latência <40ms
- **Complexidade de implementação:** Requer metodologias avançadas de codesign e otimização multi-dimensional

2.5.5 Estudo de Caso: Arquitetura Qualcomm QCS8250

O SoC Qualcomm QCS8250, utilizado na plataforma SightLine Applications 4100-OEM, exemplifica uma arquitetura heterogênea comercial bem-sucedida:

- **CPU Octa-core Kryo™585:** Controle de sistema, gerenciamento de fluxo e tarefas de coordenação geral
- **GPU Adreno™650:** Processamento massivamente paralelo, filtragem de imagem e transformações geométricas
- **DSP Hexagon™:** Algoritmos matemáticos de baixa latência, estabilização de imagem e processamento de sinais
- **NPU (15 TOPS):** Aceleração de cargas de deep learning para detecção e classificação em tempo real
- **ISP Spectra™480:** Pipeline dedicado de processamento de imagem para correção radiométrica e demosaicing

Esta arquitetura demonstra como a especialização de processadores permite alto desempenho (múltiplos streams de vídeo em alta resolução) com baixa latência e consumo energético restrito (5-15W).

2.6 Plataformas de Processamento para Sensoriamento Remoto

Esta seção apresenta as principais plataformas computacionais utilizadas especificamente para processamento hiperespectral em aplicações de sensoriamento remoto, com foco em sistemas embarcados para UAVs, satélites CubeSat e plataformas terrestres móveis.

2.6.1 Plataformas NVIDIA Jetson

A família NVIDIA Jetson representa o estado da arte em computação embarcada para aplicações de visão computacional e processamento hiperespectral:

- **Jetson Nano:** Plataforma entry-level com GPU de 128 cores CUDA, adequada para prototipagem e aplicações com restrições severas de custo
- **Jetson TX2:** Configuração intermediária que demonstrou throughput de 330 fps em compressão hiperespectral, representando excelente balanço desempenho/consumo

- **Jetson Xavier:** Plataforma de alto desempenho com performance significativamente superior para classificação de imagens hiperespectrais e execução concorrente de múltiplas tarefas
- **Jetson Orin:** Geração mais recente com NPU integrada, demonstrando >650 fps em implementações de CNNs otimizadas como TakuNet

2.6.2 Sistemas Embarcados Especializados

Plataformas desenvolvidas especificamente para aplicações de sensoriamento remoto e processamento hiperespectral:

- **SightLine Applications 4100-OEM:** Sistema baseado em Qualcomm QCS8250 para aplicações ISR (Intelligence, Surveillance, Reconnaissance), demonstrando arquitetura heterogênea comercial viável
- **Plataformas FPGA embarcadas:** Sistemas como Xilinx Zynq UltraScale+ que combinam ARM cores com FPGA fabric, adequados para implementações customizadas de alta eficiência
- **Single-board computers especializados:** Plataformas como RaspberryPi com aceleradores computacionais para aplicações de baixo custo e consumo ultra-baixo

2.6.3 Plataformas para Aplicações Espaciais

Sistemas especializados para aplicações satelitais com restrições extremas de radiação, temperatura e consumo energético:

- **Processadores radiation-hardened:** Componentes especialmente projetados para resistir à radiação espacial, essenciais para missões de longa duração
- **Arquiteturas de tolerância a falhas:** Sistemas redundantes e técnicas de correção de erro para garantir confiabilidade em ambiente espacial
- **Otimização energética extrema:** Algoritmos e arquiteturas otimizadas para operação com orçamentos energéticos da ordem de watts ou menos
- **Compactação e miniaturização:** Sistemas adequados para integração em CubeSats e nanosatélites com severas restrições de tamanho e peso

2.7 Benchmarking de Plataformas no Mercado

Esta seção apresenta uma análise comparativa quantitativa das principais plataformas comerciais disponíveis para processamento hiperespectral, baseada em métricas de desempenho, consumo energético, custo e adequação para diferentes tipos de aplicação.

2.7.1 Metodologia de Benchmarking

Para garantir comparabilidade entre diferentes plataformas, estabelecemos métricas padronizadas baseadas na literatura científica:

- **Métricas de desempenho:** Throughput (fps), latência (ms), precisão de classificação (%)
- **Métricas energéticas:** Consumo de potência (W), eficiência energética (fps/W)
- **Métricas de recursos:** Utilização de memória, ocupação de hardware, custo por unidade de desempenho
- **Datasets de referência:** AVIRIS Indian Pines (614×512×224), Pavia University, Salinas Valley para comparabilidade

2.7.2 Análise Comparativa de Performance

Com base na literatura científica analisada, apresentamos benchmarks representativos do estado da arte atual:

Tabela 2.3: Benchmarking de plataformas para processamento hiperespectral					
Plataforma	Throughput (fps)	Latência (ms)	Consumo (W)	Precisão (%)	Aplicação Típica
NVIDIA Jetson TX2	330	<50	15	95+	Compressão hiperespectral em UAVs
NVIDIA Jetson Orin	>650	<20	20	94.3	CNNs otimizadas (TakuNet)
FPGA Xilinx (implementação SVM)	200+	0.1/pixel	5-10	99.7	Classificação SVM tempo real
Qualcomm QCS8250 (SightLine)	Multi-stream HD video	<30	5-15	N/A	Processamento ISR embarcado
CPU x86 convencional (baseline)	1-5	>1000	45+	95+	Referência baseline

2.7.3 Trade-offs Performance vs Consumo

A análise dos dados de benchmarking revela trade-offs fundamentais entre diferentes métricas de desempenho:

- **Eficiência energética:** Implementações FPGA demonstram a melhor relação desempenho/consumo, com melhorias de até 43,5x em relação a implementações CPU convencionais
- **Throughput máximo:** GPUs embarcadas como Jetson TX2 oferecem o maior throughput absoluto (330 fps) para aplicações que toleram maior consumo energético
- **Latência mínima:** FPGAs com implementações customizadas atingem latências ultra-baixas (0,1ms/pixel), essenciais para aplicações de tempo real crítico
- **Precisão vs recursos:** Arquiteturas como TakuNet demonstram que é possível manter alta precisão (94,3%) com redução drástica de recursos computacionais (99% menos parâmetros)

2.7.4 Adequação por Tipo de Aplicação

Diferentes aplicações de sensoriamento remoto apresentam requisitos distintos, orientando a seleção de plataformas adequadas:

- **UAVs de agricultura de precisão:** Plataformas como Jetson TX2 oferecem excelente balanço entre throughput, consumo e peso para mapeamento aéreo contínuo
- **Aplicações de vigilância:** Sistemas como SightLine 4100-OEM com arquiteturas heterogêneas são adequados para processamento multi-stream com baixa latência
- **Monitoramento ambiental de longo prazo:** Implementações FPGA de ultra-baixo consumo são ideais para sensores autônomos com operação contínua
- **Aplicações espaciais:** Plataformas radiation-hardened com otimização energética extrema são essenciais para missões satelitais

2.7.5 Tendências Futuras

A análise do mercado atual indica tendências importantes para o desenvolvimento futuro de plataformas hiperespectrais:

- **Integração de NPUs:** Crescente incorporação de unidades de processamento neural dedicadas para acelerar algoritmos de deep learning
- **Arquiteturas heterogêneas:** Evolução para sistemas que combinam múltiplos tipos de processadores em arquiteturas otimizadas
- **Edge computing inteligente:** Desenvolvimento de frameworks para processamento distribuído e colaborativo entre múltiplas plataformas
- **Otimização multi-objetivo:** Algoritmos avançados que otimizam simultaneamente precisão, consumo, latência e qualidade

2.8 Métodos de Processamento de Dados Hiperespectrais

Esta seção apresentará os principais métodos e técnicas utilizados no processamento de dados hiperespectrais, incluindo algoritmos de redução dimensional, classificação espectral e extração de características. Os métodos serão analisados considerando sua aplicabilidade em sistemas embarcados e restrições de tempo real.

Os métodos de processamento hiperespectral podem ser categorizados em três grupos principais:

- **Redução dimensional:** PCA, ICA, seleção de bandas espectrais
- **Classificação espectral:** SVM, Random Forest, redes neurais convolucionais
- **Extração de características:** Análise de componentes principais, filtros espaciais

Cada método apresenta trade-offs específicos entre precisão, velocidade de processamento e consumo de recursos computacionais, sendo essencial para o desenvolvimento de sistemas embarcados eficientes.

Capítulo 3

Proposta e metodologia

Capítulo 4

Conclusões e trabalhos futuros

Referências

Chen, Y.; Liu, X.; Wang, H. Lightweight 3D-CNN for Hyperspectral Classification on Edge Devices. **IEEE Geoscience and Remote Sensing Letters**, v. 21, p. 1–5, 2024. Early Access.

Díaz, M. *et al.* Real-Time Hyperspectral Image Compression Onto Embedded GPUs. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, v. 12, n. 8, p. 2792–2809, 2019. DOI: 10.1109/JSTARS.2019.2925436.

Lim, W. L.; Ko, C. C.; Ma, K.-K. Feasibility of a Real-Time Embedded Hyperspectral Compressive Sensing Imaging System. **Sensors**, v. 22, n. 24, p. 9793, 2022. DOI: 10.3390/s22249793.

Martins, L.; Faria, F. A.; Prado, D. R. A real-time SVM-based hardware accelerator for hyperspectral images classification. **Journal of Real-Time Image Processing**, v. 16, p. 1547–1562, 2019. DOI: 10.1007/s11554-017-0719-9.

Shin, S.; Song, J.; Ryu, C. UAV-Based Hyperspectral System with Onboard Processing. **Remote Sensing**, v. 12, n. 23, p. 3897, 2020. DOI: 10.3390/rs12233897.

Ullah, S.; Kumar, N.; Kim, D. Benchmarking NVIDIA Jetson Platform for Deep Learning Applications. **IEEE Access**, v. 8, p. 206326–206339, 2020. DOI: 10.1109/ACCESS.2020.3037683.

Wang, J.; Li, Q.; Zhou, M. Energy-Efficient Band Selection Using Information Theory. **IEEE Transactions on Geoscience and Remote Sensing**, v. 62, p. 1–15, 2024. Early Access.