



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional
visando eficiência energética e Latência no Processamento
Hiperespectral Embarcado**

Limeira
2025

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional visando
eficiência energética e Latência no Processamento Hiperespectral
Embarcado**

Dissertação apresentada à Faculdade de
Tecnologia da Universidade Estadual de
Campinas como parte dos requisitos para a
obtenção do título de Mestre em Tecnologia, na
área de Sistemas de Informação e Comunicação.

Orientador: Prof. Dr. Leandro Ronchini Ximenes

Este trabalho corresponde à versão final da
Dissertação defendida por Diego de Freitas
Maia e orientada pelo Prof. Dr. Leandro
Ronchini Ximenes.

Limeira
2025

Na versão final, esta página será substituída pela ficha catalográfica no TCC, na dissertação de mestrado ou na tese de doutorado.

Caso não tenha ficha catalográfica, deixe essa página em branco conforme as instruções a seguir.

No arquivo principal (`tese.tex`), adicione o nome do arquivo PDF com a ficha catalográfica como parâmetro para o comando `\fichacatalografica{}`. Caso a versão da sua dissertação ou tese seja a versão anterior à aprovação pela banca, você pode substituir esta por uma página em branco com o comando a seguir:

`\fichacatalografica{branco.pdf}`

Substitua o arquivo `branco.pdf` por `white.pdf`, nos textos em inglês, ou por `blanco.pdf`, para textos em espanhol. Todos esses arquivos PDF já estão disponíveis neste modelo.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão fazer referência ao apoio recebido e inserir esta informação na ficha catalográfica, além do nome da agência, o número do processo pelo qual recebeu o auxílio.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Prof. Dr. Leandro Ronchini Ximenes
Presidente da Comissão Julgadora

Prof.^a Dr.^a Segunda Avaliadora
Instituição da segunda avaliadora

Dr. Terceiro Avaliador
Instituição do terceiro avaliador

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria de Pós-graduação da Faculdade de Tecnologia.

Sumário

Resumo	8
Abstract	1
1 Introdução	2
1.1 Contexto e motivação	2
1.2 Objetivos	2
1.2.1 Objetivo geral	2
1.2.2 Objetivos específicos	2
1.3 Hipóteses	2
1.4 Contribuições esperadas	2
1.5 Metodologia da pesquisa (visão geral)	2
1.6 Organização do trabalho	2
2 Levantamento bibliográfico	3
2.1 Fundamentos do Espectro Eletromagnético e Interação com a Matéria . . .	3
2.1.1 O Espectro Eletromagnético	3
2.1.2 Propriedades Ópticas dos Materiais	3
2.1.3 Princípios de Sensoriamento Espectral	3
2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações	4
2.2.1 Tipos de Sistemas de Imageamento Hiperespectral	4
2.2.2 Principais Aplicações e Domínios de Uso	4
2.2.3 Sensores e Sistemas Comerciais Representativos	4
2.2.4 Estrutura e Dimensionalidade dos Dados	7
2.2.5 Datasets Públicos de Referência	7
3 Proposta e metodologia	8
4 Conclusões e trabalhos futuros	9

Lista de Figuras

Lista de Tabelas

2.1	Análise comparativa de sensores hiperespectrais baseada na literatura científica	5
-----	--	---

Resumo

Palavras-chave:

Abstract

Keywords:

Capítulo 1

Introdução

1.1 Contexto e motivação

1.2 Objetivos

1.2.1 Objetivo geral

1.2.2 Objetivos específicos

1.3 Hipóteses

1.4 Contribuições esperadas

1.5 Metodologia da pesquisa (visão geral)

1.6 Organização do trabalho

Capítulo 2

Levantamento bibliográfico

Este capítulo apresenta a revisão da literatura sobre imageamento hiperespectral, abordando os fundamentos, tecnologias disponíveis e aplicações. A análise foi organizada em três seções principais: princípios físicos da espectroscopia de imageamento e formação de imagens espectrais; arquiteturas de sensores hiperespectrais, desde sistemas dispersivos até implementações baseadas em filtros sintonizáveis; e métodos de processamento de dados, incluindo redução dimensional, classificação espectral e extração de características. A revisão abrange trabalhos fundamentais da área e publicações recentes sobre aplicações em agricultura de precisão, monitoramento ambiental e sistemas embarcados, com ênfase nos desafios computacionais do processamento de grandes volumes de dados e soluções para operação em tempo real.

2.1 Fundamentos do Espectro Eletromagnético e Interação com a Matéria

Os conceitos fundamentais do imageamento hiperespectral baseiam-se nos princípios da física óptica que descrevem a interação entre a radiação eletromagnética e a matéria. Esta seção examina as características das ondas eletromagnéticas e sua organização espectral, com foco particular na faixa de 400 a 2500 nm, que abrange as regiões do visível, infravermelho próximo e infravermelho de ondas curtas, essenciais para o sensoriamento remoto. As propriedades ópticas dos materiais são analisadas através dos fenômenos de reflectância, transmitância e absorção, processos físicos que originam as assinaturas espectrais únicas de cada substância e possibilitam sua identificação e caracterização. A compreensão da distinção entre sistemas multispectrais e hiperespectrais, quanto à resolução espectral e capacidade de discriminação, fundamenta a escolha da tecnologia adequada para cada aplicação. Esses princípios teóricos são demonstrados através de aplicações práticas em agricultura de precisão e monitoramento ambiental, evidenciando como o conhecimento dos fundamentos físicos é indispensável para o desenvolvimento de metodologias robustas de aquisição, processamento e análise de dados hiperespectrais.

2.1.1 O Espectro Eletromagnético

- **Definição e características das ondas eletromagnéticas**
- **Regiões espectrais:** do ultravioleta ao infravermelho

- **Comprimentos de onda relevantes para sensoriamento remoto (400-2500 nm)**

2.1.2 Propriedades Ópticas dos Materiais

- **Reflectância espectral:** definição e fatores influenciadores
- **Transmitância e absorção:** princípios físicos
- **Assinatura espectral:** conceito e importância para identificação de materiais

2.1.3 Princípios de Sensoriamento Espectral

- **Interação radiação-matéria no contexto de sensoriamento remoto**
- **Sensores multiespectrais vs. hiperespectrais:** diferenças fundamentais
- **Aplicações práticas:** agricultura de precisão e monitoramento ambiental

2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações

2.2.1 Tipos de Sistemas de Imageamento Hiperespectral

- **Whiskbroom (varredura pontual):** Sensores que capturam um pixel por vez, realizando varredura mecânica em duas dimensões
- **Pushbroom (varredura linear):** Capturam uma linha completa de pixels simultaneamente, sendo o tipo mais comum em plataformas aéreas e UAVs
- **Snapshot (imageamento instantâneo):** Adquirem toda a informação espacial e espectral em uma única exposição

2.2.2 Principais Aplicações e Domínios de Uso

- **Agricultura de precisão:** Monitoramento de saúde vegetal, detecção de pragas e estresse hídrico
- **Monitoramento ambiental:** Qualidade da água, detecção de poluentes e análise de cobertura vegetal
- **Aplicações industriais:** Inspeção de qualidade, classificação de materiais e controle de processos
- **Defesa e vigilância:** Detecção de alvos camuflados e identificação de materiais

2.2.3 Sensores e Sistemas Comerciais Representativos

O desenvolvimento de sistemas hiperespectrais comerciais tem apresentado avanços significativos nos últimos anos, com diferentes fabricantes oferecendo soluções adaptadas para aplicações específicas em agricultura de precisão, monitoramento ambiental, inspeção industrial e uso embarcado em VANTs (**Aasen2015**; Díaz *et al.*, 2019; Shin, S.; Song; Ryu, 2020). Alguns fabricantes como Specim, Resonon e Cubert oferecem soluções

comerciais interessantes para essas aplicações, na Tabela 2.1 é apresentada uma análise aprofundada dos principais sensores e sistemas disponíveis no mercado, suas características técnicas e aplicações práticas.

Vimos na Seção 2.2.1 a classificação dos sistemas de imageamento hiperespectral quanto à tecnologia de aquisição. Entre os sistemas do tipo pushbroom, destacam-se o Specim FX10, amplamente empregado em aplicações embarcadas em UAVs devido ao seu baixo peso e alta taxa de aquisição (**SpecimFX10Datasheet**; Díaz *et al.*, 2019), o Resonon Pika L, reconhecido por sua robustez em monitoramento de vegetação e qualidade da água (**Aasen2015**; **ResononPikaLManual**), e o Headwall Nano-Hyperspec, notável pela adaptabilidade a plataformas compactas (**HeadwallNanoHyperspec**; Shin, S.; Song; Ryu, 2020). No segmento dos sistemas snapshot, que realizam a captura simultânea de toda a cena espectral e espacial, sobressaem o Cubert S185 Firefly SE (**CubertS185Manual**) e soluções baseadas em filtros Fabry-Pérot (**FabryPerotReview**; Shin, S.; Song; Ryu, 2020), ambos voltados para aplicações que demandam imageamento instantâneo e portabilidade. A escolha entre esses modelos está diretamente relacionada ao tipo de aplicação, requisitos de portabilidade e necessidades de processamento em tempo real (**Aasen2015**; Díaz *et al.*, 2019; Shin, S.; Song; Ryu, 2020).

Um dos principais desafios no uso desses sistemas é o gerenciamento do alto volume de dados gerados. Os sensores hiperespectrais produzem throughput na faixa de 30 MB/s a 300 MB/s, exigindo interfaces de alta velocidade como USB 3.0, Camera Link ou GigE Vision, além de soluções de armazenamento local com capacidade e velocidade adequadas (**ResononPikaLManual**; **SpecimFX10Datasheet**; Díaz *et al.*, 2019). Para ilustrar a magnitude desse desafio, sistemas operando em capacidade máxima podem gerar aproximadamente 4,15 TB de dados em 8 horas de operação contínua, ou até 6 GB por minuto quando embarcados em VANTs, conforme demonstrado por Díaz *et al.* (2019) em implementações com throughput de 144,375 MB/s.

A qualidade dos dados hiperespectrais depende fundamentalmente de procedimentos adequados de pré-processamento. A calibração radiométrica e a correção atmosférica são etapas essenciais para garantir a precisão espectral dos cubos hiperespectrais. Seonho Shin, Song e Ryu (2020) demonstrou que métodos de correção radiométrica baseados em Extreme Learning Machines (ELM) podem proporcionar melhorias de 5–55% na qualidade dos dados, sendo particularmente eficazes para sistemas embarcados em drones com condições de iluminação variáveis.

Para aplicações que demandam processamento em tempo real ou em sistemas embarcados, a escolha da plataforma computacional é crítica. Ullah, Kumar e Kim (2020) realizaram estudos de benchmarking entre plataformas NVIDIA Jetson para processamento em borda, demonstrando que o modelo Xavier apresenta desempenho significativamente superior ao Nano e TX1 para classificação de imagens hiperespectrais e execução concorrente de múltiplas tarefas. Alternativamente, implementações em FPGA têm mostrado resultados promissores. Martins, Faria e Prado (2019) demonstraram que aceleradores baseados em SVM (Support Vector Machine) com seleção otimizada de bandas espectrais baseada em entropia e correlação (EMCR) podem viabilizar classificação em tempo real com alta acurácia (99,7%) e baixo consumo de recursos de silício.

A escolha do sensor mais adequado deve considerar diversos fatores relacionados ao domínio de aplicação. Para mapeamento aéreo em VANTs, onde se busca alta resolução espectral com varredura contínua de grandes áreas, os sensores pushbroom como o

Tabela 2.1: Análise comparativa de sensores hiperespectrais baseada na literatura científica

Sensor/Sistema	Tecnologia de Aquisição	Faixa Espectral	Características Espectrais	Performance Reportada	Referência/Aplicação
Specim FX10	Pushbroom	400–1000 nm (VNIR)	224 bandas espectrais 1024 pixels espaciais	Taxa: até 330 FPS Throughput: 144,375 MB/s	Díaz <i>et al.</i> (2019) – Agricultura UAV Validação em campo
Resonon Pika L	Pushbroom	400–1000 nm	281 bandas espectrais 900 pixels espaciais 12 bits/pixel	Taxa: 249 FPS Throughput: 94,45 MB/s Com binning 2 [×] : 47,22 MB/s	Aplicações em monitoramento de vegetação e qualidade da água
Resonon PIKA-NIR-320	Pushbroom	900–1700 nm (NIR-SWIR)	164 bandas espectrais 320 pixels espaciais 168 canais totais	Taxa: até 520 Hz Pixel size: 30 μ m Line-scan operation	Detecção de resíduos marinhos flutuantes (Lim; Ko; Ma, 2022)
Cubert S185 FirefYE SE	Snapshot	450–950 nm	125 bandas espectrais 1 MP (1000 $\times$ 1000) 12/14 bits	Taxa: até 25 Hz 5 cubos hiperespectrais/s Throughput: 31,25 MB/s Consumo: 15 W, Peso: 490 g	Monitoramento de saúde vegetal e análise agrícola
Headwall Nano-Hyperspec	Pushbroom	400–1000 nm	270 bandas espectrais 640 pixels espaciais	Taxa: 300 FPS Throughput: 103,68 MB/s Armazenamento: 480 GB	Pequenas plataformas UAV, excelente adaptabilidade
Sistemas baseados em Filtros Fabry-Pérot	Snapshot (Captura única)	Variável conforme filtros	150+ bandas Filtros sintonizáveis	Performance variável dependente da aplicação	Tecnologia IMEC Imageamento instantâneo

Specim FX10 apresentam vantagens significativas. Díaz *et al.* (2019) demonstraram a eficácia deste sensor em aplicações de agricultura de precisão, alcançando throughput de 330 fps com processamento em tempo real em plataformas NVIDIA Jetson TX2. O sistema se destaca por integrar capacidade de georreferenciamento direto, eliminando a necessidade de correções geométricas posteriores e simplificando o fluxo de processamento para aplicações de mapeamento preciso.

Por outro lado, aplicações que requerem captura instantânea de toda a cena, como inspeção industrial de objetos em movimento ou monitoramento de fenômenos dinâmicos, beneficiam-se dos sistemas snapshot. O Cubert S185 FirefLEYE SE, com seu baixo consumo energético de 15 W e peso reduzido de 490 g, apresenta-se como solução adequada para plataformas com restrições de peso e energia (**Cubert2020; FirefLEYESE2021**). Sistemas baseados em filtros Fabry-Pérot oferecem flexibilidade adicional ao permitir sintonização espectral dinâmica, facilitando a implementação de algoritmos de processamento acelerado diretamente no fluxo de aquisição (**IMEC2017; Li2019**).

2.2.4 Estrutura e Dimensionalidade dos Dados

Os dados hiperespectrais são organizados em estruturas tridimensionais denominadas cubos hiperespectrais, onde duas dimensões representam informações espaciais (x , y) e a terceira dimensão contém informações espectrais (λ). Esta organização permite a análise simultânea de características espaciais e espectrais dos objetos imageados.

2.2.5 Datasets Públicos de Referência

Os datasets públicos constituem recursos fundamentais para validação e comparação de algoritmos de processamento hiperespectral. Os principais datasets utilizados na literatura científica incluem:

- **Indian Pines:** Dataset de solo e cultura
- **Pavia University:** Dataset de cobertura vegetal
- **Salinas:** Dataset de solo e cultura
- **Kennedy Space Center:** Dataset de solo e cultura
- **AVIRIS:** Dataset de solo e cultura
- **Botswana:** Dataset de classificação de vegetação em savana africana

performance e identificar padrões de eficiência por categoria de técnica.
J/frame)

Chen2024) (Wang2024)

Díaz *et al.* (2019))

oportunidades significativas para pesquisa:
trabalhos)

demonstra sistema completo UAV com validação em campo.
trabalhos)

FPS, latência, consumo e precisão.
trabalhos)

apenas 2 validações em campo real.

revisão

devido a:

por:

desenvolvimentos muito recentes ou trabalhos clássicos anteriores.

excluído trabalhos conceituais importantes.

metodológica dos trabalhos incluídos.

capítulo

atual da arte em processamento hiperespectral embarcado, revelando tanto avanços significativos quanto lacunas importantes que justificam o desenvolvimento de frameworks integrados.

tempo real

framework arquitetural heterogêneo proposto no próximo capítulo, demonstrando tanto a viabilidade técnica quanto a necessidade de abordagens integradas.

Capítulo 3

Proposta e metodologia

Capítulo 4

Conclusões e trabalhos futuros

Referências

Barrios, Y.; Rodríguez, A.; Sánchez, A.; Pérez-Jiménez, R. A Parallel FPGA Implementation of the CCSDS-123 Compression Algorithm. **Remote Sensing**, v. 11, n. 6, p. 673, 2019. DOI: 10.3390/rs11060673.

Díaz, M. *et al.* Real-Time Hyperspectral Image Compression Onto Embedded GPUs. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, v. 12, n. 8, p. 2792–2809, 2019. DOI: 10.1109/JSTARS.2019.2925436.

Hwang, J.-J.; Choi, S.; Chang, H. Energy-Aware Design Methodology for Lossless Hyperspectral Image Compression. **IEEE Transactions on Very Large Scale Integration (VLSI) Systems**, v. 19, n. 6, p. 1045–1056, 2011. DOI: 10.1109/TVLSI.2010.2045392.

Lim, W. L.; Ko, C. C.; Ma, K.-K. Feasibility of a Real-Time Embedded Hyperspectral Compressive Sensing Imaging System. **Sensors**, v. 22, n. 24, p. 9793, 2022. DOI: 10.3390/s22249793.

Lou, X.; Zhang, Y.; Wang, C. Benchmark Datasets for Hyperspectral Image Processing. **IEEE Transactions on Geoscience and Remote Sensing**, v. 62, p. 1–18, 2024.

Martins, L.; Faria, F. A.; Prado, D. R. A real-time SVM-based hardware accelerator for hyperspectral images classification. **Journal of Real-Time Image Processing**, v. 16, p. 1547–1562, 2019. DOI: 10.1007/s11554-017-0719-9.

Shin, M.; Park, J.; Lee, S. Robust Radiometric and Geometric Correction Methods for Drone-Based Hyperspectral Imaging. **Remote Sensing**, v. 16, n. 4, p. 687, 2024. DOI: 10.3390/rs16040687.

Shin, S.; Song, J.; Ryu, C. UAV-Based Hyperspectral System with Onboard Processing. **Remote Sensing**, v. 12, n. 23, p. 3897, 2020. DOI: 10.3390/rs12233897.

Silva, R.; Oliveira, C.; Santos, M. Pipeline de Fusão Espacial-Espectral para UAVs. **Brazilian Journal of Remote Sensing**, v. 15, n. 2, p. 45–62, 2024.

Takuya, N.; Sato, H.; Tanaka, K. TakuNet: An Efficient CNN for Hyperspectral Image Classification. **IEEE Transactions on Geoscience and Remote Sensing**, v. 62, p. 1–12, 2024. Early Access.

Torti, E.; Fontanella, A.; Danese, G.; Leporati, F. Parallel Unmixing of Hyperspectral Data on Heterogeneous Platforms. **IEEE Transactions on Parallel and Distributed Systems**, v. 30, n. 12, p. 2849–2862, 2019. DOI: 10.1109/TPDS.2019.2920988.

Ullah, S.; Kumar, N.; Kim, D. Benchmarking NVIDIA Jetson Platform for Deep Learning Applications. **IEEE Access**, v. 8, p. 206326–206339, 2020. DOI: 10.1109/ACCESS.2020.3037683.