



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional
visando eficiência energética e Latência no Processamento
Hiperespectral Embarcado**

Limeira
2025

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional visando
eficiência energética e Latência no Processamento Hiperespectral
Embarcado**

Dissertação apresentada à Faculdade de
Tecnologia da Universidade Estadual de
Campinas como parte dos requisitos para a
obtenção do título de Mestre em Tecnologia, na
área de Sistemas de Informação e Comunicação.

Orientador: Prof. Dr. Leandro Ronchini Ximenes

Este trabalho corresponde à versão final da
Dissertação defendida por Diego de Freitas
Maia e orientada pelo Prof. Dr. Leandro
Ronchini Ximenes.

Limeira
2025

Na versão final, esta página será substituída pela ficha catalográfica no TCC, na dissertação de mestrado ou na tese de doutorado.

Caso não tenha ficha catalográfica, deixe essa página em branco conforme as instruções a seguir.

No arquivo principal (`tese.tex`), adicione o nome do arquivo PDF com a ficha catalográfica como parâmetro para o comando `\fichacatalografica{}`. Caso a versão da sua dissertação ou tese seja a versão anterior à aprovação pela banca, você pode substituir esta por uma página em branco com o comando a seguir:

`\fichacatalografica{branco.pdf}`

Substitua o arquivo `branco.pdf` por `white.pdf`, nos textos em inglês, ou por `blanco.pdf`, para textos em espanhol. Todos esses arquivos PDF já estão disponíveis neste modelo.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão fazer referência ao apoio recebido e inserir esta informação na ficha catalográfica, além do nome da agência, o número do processo pelo qual recebeu o auxílio.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Prof. Dr. Leandro Ronchini Ximenes
Presidente da Comissão Julgadora

Prof.^a Dr.^a Segunda Avaliadora
Instituição da segunda avaliadora

Dr. Terceiro Avaliador
Instituição do terceiro avaliador

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria de Pós-graduação da Faculdade de Tecnologia.

Sumário

Resumo	9
Abstract	1
1 Introdução	2
1.1 Contexto e motivação	2
1.2 Objetivos	2
1.2.1 Objetivo geral	2
1.2.2 Objetivos específicos	2
1.3 Hipóteses	2
1.4 Contribuições esperadas	2
1.5 Metodologia da pesquisa (visão geral)	2
1.6 Organização do trabalho	2
2 Levantamento Bibliográfico	3
2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais	3
2.1.1 O espectro eletromagnético	4
2.1.2 Propriedades Ópticas dos Materiais	6
2.1.3 Princípios de Sensoriamento Remoto Hiperespectral	8
2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações	12
2.2.1 Tipos de Sistemas de Imageamento Hiperespectral	12
2.2.2 Sensores e Sistemas Comerciais Representativos	12
2.3 Técnicas de Processamento de Imagens Hiperespectrais	14
2.3.1 Pré-processamento e Correção Radiométrica	14
2.3.2 Redução Dimensional e Seleção de Bandas	15
2.3.3 Algoritmos de Classificação Espectral	15
2.3.4 Processamento de Sinais Espectrais Avançado	16
2.3.5 Considerações para Implementação Embarcada	17
2.4 Tipos de Processadores para Processamento Hiperespectral	18
2.4.1 Processadores de Uso Geral (CPU)	18
2.4.2 Unidades de Processamento Gráfico (GPU)	18
2.4.3 Field-Programmable Gate Arrays (FPGA)	19
2.5 Arquiteturas Heterogêneas de Processamento	20
2.5.1 Fundamentos de Computação Heterogênea	20
2.5.2 Arquiteturas CPU+GPU Integradas	20
2.5.3 Sistemas CPU+FPGA	21
2.5.4 Arquiteturas Tri-híbridas CPU+GPU+FPGA	22
2.6 Plataformas de Processamento para Sensoriamento Remoto	22

2.6.1	Sistemas Embarcados Especializados	22
2.6.2	Tendências Futuras	23
3	Proposta e metodologia	24
4	Conclusões e trabalhos futuros	25

Lista de Figuras

Lista de Tabelas

2.1	Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamiento remoto (valores em nanômetros, nm, até 1 mm).	5
2.2	Análise comparativa de sensores hiperespectrais baseada na literatura científica	13

Resumo

Palavras-chave:

Abstract

Keywords:

Capítulo 1

Introdução

1.1 Contexto e motivação

1.2 Objetivos

1.2.1 Objetivo geral

1.2.2 Objetivos específicos

1.3 Hipóteses

1.4 Contribuições esperadas

1.5 Metodologia da pesquisa (visão geral)

1.6 Organização do trabalho

Capítulo 2

Levantamento Bibliográfico

Este capítulo apresenta a revisão da literatura sobre imageamento hiperespectral, abordando os fundamentos, tecnologias disponíveis e aplicações em sistemas embarcados. A análise foi organizada em sete seções principais: princípios físicos da espectroscopia de imageamento e formação de imagens espectrais; câmeras hiperespectrais, incluindo tipos, modelos e datasets públicos; técnicas de processamento de imagens hiperespectrais; tipos de processadores e suas características para processamento hiperespectral; arquiteturas heterogêneas de processamento; plataformas específicas para sensoriamento remoto; e benchmarking de plataformas comerciais. A revisão abrange trabalhos fundamentais da área e publicações recentes sobre aplicações em agricultura de precisão, monitoramento ambiental e sistemas embarcados, com ênfase nos desafios computacionais do processamento de grandes volumes de dados e soluções para operação em tempo real com restrições energéticas.

2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais

Os conceitos fundamentais do imageamento hiperespectral baseiam-se nos princípios da física óptica que descrevem a interação entre a radiação eletromagnética e a matéria (LORENZZETTI, 2015). Esta seção examina as características das ondas eletromagnéticas e sua organização espectral, com foco particular na faixa de 400 a 2500 nm, que abrange as regiões do visível, infravermelho próximo e infravermelho de ondas curtas, essenciais para o sensoriamento remoto. As propriedades ópticas dos materiais são analisadas através dos fenômenos de reflectância, transmitância e absorção, processos físicos que originam as assinaturas espectrais únicas de cada substância e possibilitam sua identificação e caracterização (BAPTISTA, 2019). A compreensão da distinção entre sistemas multiespectrais e hiperespectrais, quanto à resolução espectral e capacidade de discriminação, fundamenta a escolha da tecnologia adequada para cada aplicação. Esses princípios teóricos são demonstrados através de aplicações práticas em agricultura de precisão e monitoramento ambiental, evidenciando como o conhecimento dos fundamentos físicos é indispensável para o desenvolvimento de metodologias robustas de aquisição, processamento e análise de dados hiperespectrais.

2.1.1 O espectro eletromagnético

A energia eletromagnética constitui a base física do sensoriamento remoto e do imageamento hiperespectral, podendo ter origem em fontes naturais, como o Sol, nos próprios alvos ou em sistemas ativos, como radares. Essa energia propaga-se em forma de ondas, transportando informações sobre os materiais com os quais interage. Compreender as propriedades fundamentais da radiação eletromagnética é essencial para entender os processos de aquisição e análise de dados hiperespectrais.

Definição e características das ondas eletromagnéticas

Ondas eletromagnéticas são perturbações que se propagam no espaço à velocidade da luz (c é 3×10^8 m/s no vácuo). São caracterizadas principalmente pelo comprimento de onda (λ) e pela frequência (f), relacionados por:

$$c = \lambda \odot f \quad (2.1)$$

A energia (E) transportada por uma onda eletromagnética é proporcional à sua frequência, conforme a equação de Planck:

$$E = h \odot f = \frac{hc}{\lambda} \quad (2.2)$$

em que h é a constante de Planck ($6,626 \times 10^{-34}$ J⋅s).

No contexto do sensoriamento remoto, diferentes unidades são empregadas para descrever as faixas espectrais:

- 1 kHz = 1×10^3 Hz
- 1 MHz = 1×10^6 Hz
- 1 GHz = 1×10^9 Hz
- 1 THz = 1×10^{12} Hz
- 1 μm = 1×10^{-6} m
- 1 nm = 1×10^{-9} m

Neste trabalho adota-se a unidade de micrometro (μm) para o comprimento de onda.

Regiões espectrais: do ultravioleta ao infravermelho

O espectro eletromagnético é dividido em regiões conforme as propriedades físicas da radiação e sua interação com a matéria (LORENZZETTI, 2015; BAPTISTA, 2019). Para sensoriamento remoto, destacam-se as seguintes faixas:

Ultravioleta (UV): 300 μm a 0,4 μm . Pouco utilizada em sensoriamento remoto terrestre devido à absorção atmosférica, mas relevante em aplicações específicas.

Visível: 0,4 a 0,7 μm , correspondente à radiação percebida pelo olho humano. Subdivisões usuais:

- Azul: 0,4—0,5 μm
- Verde: 0,5—0,6 μm

- Vermelho: 0,6—0,7 μm

Infravermelho próximo (NIR): 0,7 a 1,3 μm . Importante para estudos de vegetação devido à alta reflectância da clorofila.

Infravermelho de ondas curtas (SWIR): 1,3 a 3,0 μm . Fundamental para identificação de minerais e análise de umidade.

Os limites exatos dessas faixas podem variar entre autores, mas há consenso sobre as principais subdivisões. A Tabela 2.1 apresenta as subfaixas do infravermelho mais utilizadas em sensoriamento remoto.

Tabela 2.1: Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).

Faixa	Subfaixa	Comprimento de onda
Raios-X	—	0,03—30 nm
Ultravioleta	—	30—400 nm
Visível	—	400—700 nm
Infravermelho	NIR/IVP	740—1 000 nm
	SWIR/IVOC	1 000—3 000 nm
	LWIR/IVTM	3 000—14 000 nm
Micro-ondas	—	1—30 mm
Ondas de rádio	—	>30 mm

Observa-se que, em algumas referências (LORENZZETTI, 2015; BAPTISTA, 2019), a faixa de micro-ondas pode ser definida como indo de 1 mm até 1 m. Essas variações não comprometem a aplicação prática dos conceitos, mas devem ser consideradas ao comparar diferentes trabalhos.

Comprimentos de onda relevantes para sensoriamento remoto (400–2500 nm)

Para aplicações de imageamento hiperespectral e sensoriamento remoto, a faixa espectral de 400 a 2500 nm (0,4 a 2,5 μm) representa a região de maior interesse prático. Essa faixa abrange as regiões do visível, infravermelho próximo (NIR) e infravermelho de ondas curtas (SWIR), onde ocorrem os principais fenômenos de interação radiação-matéria relevantes para identificação e caracterização de materiais terrestres.

Região VNIR (400–1000 nm): A faixa do visível e infravermelho próximo é fundamental para estudos de vegetação e classificação de cobertura terrestre. Nessa região, processos eletrônicos dominam a absorção da radiação, resultando em transições entre níveis de energia eletrônica nos átomos e moléculas. A clorofila, por exemplo, apresenta forte absorção nas regiões azul (430–450 nm) e vermelha (640–660 nm), enquanto exibe alta reflectância no NIR (700–1000 nm).

Região SWIR (1000–2500 nm): No infravermelho de ondas curtas, as absorções são governadas por processos vibracionais moleculares. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo decorrem de efeitos do campo cristalino, enquanto outros processos eletrônicos produzem feições espectrais

significativas nessa faixa. Essa região é particularmente rica em informações sobre minerais, conteúdo de água e compostos orgânicos.

As transições entre níveis de energia são responsáveis pelas faixas de absorção nos espectros. As absorções são governadas por processos vibracionais, sendo que átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico resulta da mudança de um estado de energia mais baixo para um mais alto, enquanto a emissão resulta da mudança de um estado de energia mais alto para um mais baixo, com liberação de energia no mesmo comprimento de onda.

A compreensão dos fundamentos físicos da interação radiação-matéria é essencial para o desenvolvimento de algoritmos de processamento hiperespectral eficazes e para a interpretação adequada dos dados espectrais em aplicações práticas de sensoriamento remoto.

2.1.2 Propriedades Ópticas dos Materiais

As propriedades ópticas dos materiais constituem a base física que permite a identificação e caracterização de diferentes substâncias através do sensoriamento remoto hiperespectral (BAPTISTA, 2019). Quando a radiação eletromagnética interage com um material, três processos fundamentais podem ocorrer: reflexão, absorção e transmissão. A compreensão destes processos e dos fatores que os influenciam é essencial para o desenvolvimento de técnicas eficazes de análise espectral e para a interpretação adequada dos dados hiperespectrais em aplicações práticas.

Reflectância Espectral: Definição e Fatores Influenciadores

A espectroscopia de reflectância é o estudo da radiação eletromagnética como função do comprimento de onda em que ela está sendo refletida, emitida ou espalhada por um gás, um líquido ou um sólido (BAPTISTA, 2019). A energia refletida pelas superfícies pode ser entendida como a porção da energia incidente, subtraindo-se as perdas que foram absorvidas ou transmitidas.

A reflectância espectral $\rho.\lambda/$, função do comprimento de onda (λ), pode ser definida matematicamente como a razão entre a radiância da superfície $[L(\lambda)]$ expressa em $W\ m^{-2}\ sr^{-1}\ \mu m^{-1}$ no comprimento de onda (λ) e a irradiância incidente $[E(\lambda)]$ em $W\ m^{-2}\ \mu m^{-1}$ no comprimento de onda (λ), conforme a equação:

$$\rho.\lambda/ = \pi \frac{L.\lambda/}{E.\lambda/} \quad (2.3)$$

Esta definição estabelece a base quantitativa para a medição e comparação das propriedades espectrais de diferentes materiais (BAPTISTA, 2019). O Sol é a principal fonte natural de energia eletromagnética nas faixas do espectro do ultravioleta, do visível, do infravermelho próximo e do infravermelho de ondas curtas. Em comprimentos de onda maiores, na faixa do infravermelho termal, a eficiência do Sol como fonte de energia é bastante reduzida e a Terra passa a ter maior eficiência como fonte, porém nesta faixa não se analisa o espectro óptico de reflectância e sim o de emitância.

O processo de interação dos fótons com a matéria resulta em que parte deles é refletida pelos grãos da superfície do material, alguns passam pelos grãos e alguns são absorvidos (BAPTISTA, 2019). Os fótons são absorvidos pelos minerais por diversos processos que

dependem de sua composição química. Essas absorções são governadas por dois processos gerais: processos eletrônicos e processos vibracionais.

Fatores Físicos Influenciadores:

Composição química: A composição química do material determina fundamentalmente suas características espectrais. Diferentes elementos e compostos apresentam absorções características em comprimentos de onda específicos, criando as feições espectrais diagnósticas que permitem sua identificação (BAPTISTA, 2019).

Estrutura cristalina: A organização atômica em materiais cristalinos influencia significativamente as propriedades ópticas. O efeito de campo cristalino, processo eletrônico mais comumente encontrado nos espectros de minerais, é devido aos elétrons desemparelhados dos orbitais internos dos elementos de transição (Sc, Ti, V, Cr, Mn, Fe, Co, Ni, Cu e Zn).

Tamanho de partícula: O tamanho das partículas que compõem a superfície afeta significativamente a reflectância espectral. Partículas menores tendem a aumentar o espalhamento múltiplo, resultando em maior reflectância geral, enquanto partículas maiores podem aumentar a absorção.

Rugosidade superficial: A microtopografia da superfície influencia o padrão de espalhamento da radiação incidente. Superfícies rugosas tendem a produzir espalhamento difuso, enquanto superfícies lisas podem apresentar componentes especulares significativos.

Conteúdo de umidade: A presença de água nas amostras introduz absorções características em $1,4\ \mu\text{m}$ e $1,9\ \mu\text{m}$, além de afetar a intensidade geral da reflectância através do aumento da absorção.

Transmitância e Absorção: Princípios Físicos

Os processos de transmitância e absorção estão intimamente relacionados com os mecanismos quânticos de interação entre radiação eletromagnética e matéria (BAPTISTA, 2019). A compreensão destes processos é fundamental para interpretar as feições espectrais observadas nos dados hiperespectrais.

Processos Eletrônicos:

Átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico é a causa da mudança de um estado de energia mais baixo para um mais alto. Já a emissão de um fóton é resultado da mudança de um estado de energia mais alto para um mais baixo. Quando um fóton é absorvido, de modo geral ele não é posteriormente emitido no mesmo comprimento de onda (BAPTISTA, 2019).

As transições entre os níveis de energia são responsáveis pelas feições de absorção nos espectros. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo são decorrentes de efeitos do campo cristalino, porém outros processos eletrônicos produzem feições espectrais importantes.

Efeito de Campo Cristalino:

O ferro é o elemento de transição mais comum na composição dos minerais que existem na superfície da Terra (BAPTISTA, 2019). Os orbitais d de todos os elementos de transição apresentam níveis de energia idênticos nos íons isolados, mas, quando o íon se localiza em um campo cristalino, os níveis de energia desses orbitais se dividem. De acordo com a teoria de campo cristalino para o caso do Fe^{3+} , por exemplo, os cinco orbitais de valência d do íon livre do elemento de transição que se encontram em níveis

iguais de energia são submetidos a um processo de repulsão eletrostática por causa da proximidade dos ligantes com carga negativa.

Esta divisão dos níveis energéticos resulta em absorções características que permitem a identificação de minerais específicos através de suas assinaturas espectrais.

Processos Vibracionais:

Em comprimentos de onda maiores, particularmente na região do infravermelho de ondas curtas (SWIR), os processos vibracionais dominam as absorções espectrais (BAPTISTA, 2019). Estes processos envolvem vibrações moleculares que ocorrem em frequências específicas, criando absorções características para diferentes grupos funcionais e ligações químicas.

2.1.3 Princípios de Sensoriamento Remoto Hiperespectral

Interação Radiação-Matéria no Contexto de Sensoriamento Remoto

O sensoriamento remoto hiperespectral fundamenta-se nos princípios físicos da interação entre radiação eletromagnética e matéria, constituindo uma extensão natural dos conceitos fundamentais abordados nas seções anteriores. A definição de sensoriamento remoto (SR) está sujeita a diferentes interpretações na literatura científica. De acordo com *Manual of Remote Sensing* (Ulaby, 1983), bem como em Elachi e Zyl (2006), SR é definido como a aquisição de informação sobre alguma propriedade de um objeto ou fenômeno sem contato físico com ele. A informação sobre um alvo seria obtida pela detecção e medida de mudanças que o objeto impõe sobre o meio circundante, seja ele eletromagnético, acústico ou potencial.

Schowengerdt (2007) considera SR como “a medida das propriedades de um objeto ou da superfície da Terra usando dados adquiridos de sensores e sistemas”, sendo um pouco mais restritivo. Segundo Slater (1980), SR é o conjunto de atividades utilizadas para a aquisição de informações relativas aos recursos naturais da Terra, ou ao seu meio ambiente, obtidas pela análise da energia eletromagnética refletida, emitida ou retroespalhada pelos alvos, coletada por meio de sensores remotos (BAPTISTA, 2019).

No contexto hiperespectral, a interação radiação-matéria adquire uma dimensão adicional de complexidade devido à alta resolução espectral dos sistemas de imageamento. Enquanto os processos eletrônicos e vibracionais descritos anteriormente permanecem fundamentalmente os mesmos, a capacidade de detectar e quantificar feições espectrais sutis é significativamente ampliada. (CLARK, 1999 apud LORENZZETTI, 2015) considera que quatro parâmetros gerais definem a capacidade de um espectrorradiômetro (sensor espectral): a faixa espectral, a largura das bandas espectrais, a amostragem espectral e a razão sinal/ruído.

A faixa espectral de resolução utilizada em sensoriamento remoto abrange tipicamente os seguintes intervalos espectrais: de 0,3 a 1,0 μm , chamado de visível e infravermelho próximo; de 1,0 a 2,5 μm , infravermelho de ondas curtas. A faixa do infravermelho termal situa-se a partir de 3,0 μm até aproximadamente o pico máximo de emitância da Terra em torno de 10,0 μm (LORENZZETTI, 2015).

A largura da banda espectral é definida por (CLARK, 1999 apud LORENZZETTI, 2015) como a largura de um canal espectral individual no espectrorradiômetro. Quanto mais estreita for a largura da banda espectral, mais precisa será a determinação da feição de absorção do mineral. Alguns sistemas sensores possuem bandas largas e não espectralmente contíguas, não permitindo como contínuas, enquanto outros sistemas,

como o AVIRIS, apresentam largura de bandas espectrais estreitas com espaçamento contínuo e permitem a identificação de feições características dos minerais.

Sensores Multiespectrais vs. Hiperespectrais: Diferenças Fundamentais

A distinção fundamental entre sensores multiespectrais e hiperespectrais reside na resolução espectral e na capacidade de discriminação de materiais. O perfil da largura também é importante. O ideal é que cada canal de um espectrorradiômetro rejeite toda radiação que não esteja dentro do alcance estreito de determinado comprimento de onda. Mas o que geralmente ocorre, em virtude de efeitos ópticos muito complexos, é que a radiação pode vazar, difundindo-se dentro do sistema óptico ou dentro do sistema de filtros bloqueadores.

Normalmente a largura do perfil é definida como a largura em comprimento de onda em 50% do nível de resposta da função do detector, chamado de largura a meia altura (FWHM) (CLARK, 1999 apud LORENZZETTI, 2015). A razão sinal/ruído (S/N) visa a obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes.

A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície. Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 apud LORENZZETTI, 2015).

Sistemas multiespectrais convencionais, como o sensor Landsat TM5, operam com bandas espectrais relativamente largas e espaçadas, tipicamente entre 6 a 12 bandas cobrindo o espectro eletromagnético de interesse. O sistema Landsat é o *Moderate Resolution Imaging Spectroradiometer* (MODIS) não permitem a percepção de feições de absorção estreitas. A figura 3.1, desenvolvida por (GREEN, 1997 apud LORENZZETTI, 2015), apresenta como o sensor Landsat TM5 captaria as feições de absorção de três minerais: hematita, caulinita e dolomita.

A caulinita apresenta sua feição espectral mais característica em $2,2 \mu\text{m}$. Já a dolomita, assim como a calcita, apresenta essa feição próxima para sua identificação, em $2,3 \mu\text{m}$. As feições espectrais utilizadas para identificação da caulinita e dolomita (ou da calcita, pois essas são semelhantes) não podem ser discriminadas, pois aparecem integradas na banda 7 ($2,08$ a $2,35 \mu\text{m}$) do sistema sensor TM5 do Landsat.

Aplicações Práticas: Agricultura de Precisão e Monitoramento Ambiental

As aplicações práticas do sensoriamento remoto hiperespectral em agricultura de precisão e monitoramento ambiental demonstram o potencial da tecnologia para resolver problemas reais com alta precisão e especificidade, constituindo um dos principais motivos para o desenvolvimento de sistemas embarcados eficientes.

Agricultura de Precisão:

Na agricultura de precisão, os sistemas hiperespectrais permitem o monitoramento detalhado da saúde vegetal, detecção precoce de estresses bióticos e abióticos, e estimativa de parâmetros biofísicos das culturas. A região do infravermelho próximo ($700\text{--}1000 \text{ nm}$) é particularmente importante devido à alta reflectância da clorofila, permitindo a avaliação do vigor vegetativo através de índices espectrais específicos.

As feições de absorção no SWIR (1400 nm e 1900 nm) são diagnósticas para o conteúdo de água nas plantas, facilitando o monitoramento de estresse hídrico em tempo real. Esta

capacidade é fundamental para sistemas embarcados em UAVs que operam em agricultura de precisão, permitindo tomada de decisões imediatas sobre irrigação e manejo de culturas.

A capacidade de discriminar espécies vegetais e estágios fenológicos através de suas assinaturas espectrais únicas representa um avanço significativo sobre os métodos convencionais. Sistemas hiperespectrais embarcados podem detectar variações sutis na composição bioquímica foliar, incluindo concentrações de clorofila, carotenoides, antocianinas e compostos estruturais como celulose e lignina.

Monitoramento Ambiental:

No monitoramento ambiental, a tecnologia hiperespectral oferece capacidades sem precedentes para a caracterização de materiais superficiais, qualidade da água e detecção de poluentes. A identificação de minerais específicos através de suas feições espectrais características permite o mapeamento geológico detalhado e a detecção de alterações hidrotermais associadas a depósitos minerais.

Para qualidade da água, os sensores hiperespectrais podem detectar e quantificar constituintes opticamente ativos como clorofila-a, sedimentos em suspensão, matéria orgânica dissolvida e diversos poluentes. As absorções características desses materiais em comprimentos de onda específicos permitem sua identificação e quantificação com precisão superior aos métodos convencionais.

A detecção de mudanças ambientais, sejam elas naturais ou antropogênicas, beneficia-se da alta sensibilidade espectral dos sistemas hiperespectrais. Alterações sutis na composição química ou física dos materiais superficiais, que seriam imperceptíveis em imagens multiespectrais, tornam-se detectáveis através da análise das variações nas assinaturas espectrais.

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo.

Aplicações Militares e de Defesa:

Grande parte das aplicações de sensoriamento remoto para fins militares é focada na detecção e classificação de alvos e no mapeamento de terrenos e instalações. Em geral, os dados obtidos (coletados por satélites ou por dispositivos aerotransportados) por aviões usados para aplicações militares são considerados como *classificados* (não disponíveis para terceiros) e de alta resolução espacial. Como definido por Simonett et al. (1983) e Jensen (2009), entende-se por resolução espacial, considera-se como resolução espacial de um sistema sensor a menor separação espacial angular ou linear entre dois objetos que podem ser detectados.

Um detalhamento mais aprofundado sobre o conceito de resolução pode ser encontrado em Forshaw et al. (1983) e Townshend (1980). Como uma imagem digital é constituída por *pixels*, costuma-se associar o tamanho do *pixel* para a resolução da imagem. Entretanto, essa definição dá a impressão de que somente podemos resolver objetos de tamanho maior, ou igual ao tamanho do *pixel*, o que nem sempre é verdade. A definição de alto contraste com pixels vizinhos, são mostrados por Schowengerdt (2007).

Sistemas de Sensoriamento Remoto: Componentes e Funcionamento:

A Figura 1.1 (LORENZZETTI, 2015) mostra esquematicamente como se processa a aquisição de informação sobre um alvo (geralmente, mas não sempre, na superfície da Terra) por meio da técnica de sensoriamento remoto. Os seguintes aspectos devem ser levados em conta:

1. As características da energia que incide sobre o alvo, quando proveniente de uma fonte tal qual o Sol, ou mesmo de uma antena de um sensor ativo como um radar, ou da energia do próprio alvo como no caso das aplicações de infravermelho termal (IVTI). Aí devemos levar em conta, por exemplo, a distribuição espectral, a intensidade e a polarização da radiação.
2. As características do meio em que essa energia se propaga (a atmosfera, ou coluna d'água para aplicações oceanográficas e limnológicas), isto é, as propriedades de absorção, espalhamento e emissão.
3. As propriedades do alvo (albedo, refletividade, rugosidade, emissividade etc.).
4. As próprias características do sensor (campo de visada, responsividade espectral, relação sinal/ruído, nível mínimo de resposta e variação ao grau de polarização (GDP) da radiação).

Para sensores ativos do tipo radar, em vez de fonte de energia ser o Sol, o próprio sensor emite pulsos de energia eletromagnética, que são parcialmente retroespalhados de volta ao sensor. Nesta situação específica de sensores remotos, os sistemas sensores são desenhados para receber prioritariamente a energia emitida pelo alvo, que é, entre vários fatores, dependente de sua temperatura (LORENZZETTI, 2015).

Desafios Técnicos e Limitações:

Os sistemas hiperespectrais enfrentam desafios únicos relacionados ao processamento de grandes volumes de dados em tempo real. A razão sinal/ruído (S/N) visa à obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes. A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície.

O teorema de Nyquist determina que o máximo de informação é obtido quando a amostragem espectral é igual à metade do FWHM; às vezes, porém, uma razão de amostragem diferente. Muitos dos espectrômetros modernos em uso (por exemplo, o AVIRIS) possuem um intervalo de amostragem de aproximadamente 10 nm e FWHM de 10 nm (CLARK, 1999 *apud* LORENZZETTI, 2015).

Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 *apud* LORENZZETTI, 2015). Esta limitação é particularmente relevante para sistemas embarcados, onde restrições de peso, energia e processamento computacional impõem desafios adicionais à manutenção de alta qualidade espectral.

Integração com Sistemas Embarcados:

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo. Os sistemas embarcados devem balancear os requisitos de alta resolução espectral com as limitações de processamento computacional, armazenamento de dados e consumo energético, especialmente em plataformas UAV onde peso e autonomia são fatores críticos.

Esta necessidade de otimização computacional motiva o desenvolvimento de algoritmos eficientes e arquiteturas de processamento especializadas, temas que serão abordados em detalhes nas próximas seções desta dissertação.

2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações

Esta seção apresenta uma análise abrangente das tecnologias de imageamento hiperespectral disponíveis, abordando desde os princípios de funcionamento até as aplicações práticas. O foco está nos sistemas comerciais representativos, suas características técnicas e adequação para diferentes tipos de aplicação, incluindo datasets públicos de referência utilizados para validação e benchmarking. As discussões são embasadas em referências bibliográficas relevantes, fornecendo um panorama atualizado do estado da arte.

2.2.1 Tipos de Sistemas de Imageamento Hiperespectral

Os sistemas de imageamento hiperespectral podem ser categorizados segundo diferentes modos de aquisição, cada um apresentando características específicas quanto à velocidade, qualidade e adequação para diferentes plataformas. Conforme estabelecido na literatura (Adão *et al.*, 2017a), os principais modos de aquisição são:

- **Pushbroom (varredura linear):** Captura uma linha completa de pixels simultaneamente, constituindo um cubo band-interleaved-by-line (BIL). É o tipo mais comum em plataformas aéreas e UAVs devido às características de tamanho compacto, baixo peso, operação simplificada e alta relação sinal/ruído (Adão *et al.*, 2017a);
- **Snapshot (imageamento instantâneo):** Adquire toda a informação espacial e espectral em uma única exposição dentro de um único período de integração. Representa uma tecnologia em desenvolvimento que ainda carece de suporte para resoluções espaciais mais altas (Adão *et al.*, 2017a).

A seleção do sistema adequado deve considerar os requisitos específicos da aplicação, incluindo resolução espacial e espectral, velocidade de aquisição, portabilidade e condições operacionais da plataforma.

2.2.2 Sensores e Sistemas Comerciais Representativos

O desenvolvimento de sistemas hiperespectrais comerciais tem apresentado avanços significativos nos últimos anos, com diferentes fabricantes oferecendo soluções adaptadas para aplicações específicas em agricultura de precisão, monitoramento ambiental, inspeção industrial e uso embarcado em VANTs. Fabricantes como Specim, Resonon, Cubert e Headwall oferecem soluções comerciais consolidadas para essas aplicações (Zhang *et al.*, 2024). A Tabela 2.2 apresenta uma análise detalhada dos principais sensores e sistemas disponíveis no mercado, suas características técnicas e aplicações práticas.

Conforme estabelecido na classificação apresentada na Subseção 2.2.1, os sistemas hiperespectrais dividem-se em diferentes tecnologias de aquisição. Entre os sistemas do tipo pushbroom, destacam-se o Specim FX10, amplamente empregado em aplicações embarcadas em UAVs devido ao seu baixo peso e alta taxa de aquisição, o Resonon Pika L, reconhecido por sua robustez em monitoramento de vegetação e qualidade da água, e o Headwall Nano-Hyperspec, notável pela adaptabilidade a plataformas compactas (Zhang *et al.*, 2024). No segmento dos sistemas snapshot, que realizam a captura

Tabela 2.2: Análise comparativa de sensores hiperespectrais baseada na literatura científica

Sensor/Sistema	Tecnologia de Aquisição	Faixa Espectral	Características Espectrais	Performance Reportada	Referência/Aplicação
Specim FX10	Pushbroom	400–1000 nm (VNIR)	224 bandas espectrais 1024 pixels espaciais	Taxa: até 330 FPS Throughput: 144,375 MB/s	Agricultura UAV Validação em campo (Zhang <i>et al.</i> , 2024)
Resonon Pika L	Pushbroom	400–1000 nm	281 bandas espectrais 900 pixels espaciais 12 bits/pixel	Taxa: 249 FPS Throughput: 94,45 MB/s Com binning 2 [×] : 47,22 MB/s	Aplicações em monitoramento de vegetação e qualidade da água (Adão <i>et al.</i> , 2017a)
Resonon PIKA-NIR-320	Pushbroom	900–1700 nm (NIR-SWIR)	164 bandas espectrais 320 pixels espaciais 168 canais totais	Taxa: até 520 Hz Pixel size: 30 μ m Line-scan operation	Deteção de resíduos marinhos flutuantes
Cubert S185 FirefEYE SE	Snapshot	450–950 nm	125 bandas espectrais 1 MP (1000 $\times$ 1000) 12/14 bits	Taxa: até 25 Hz 5 cubos hiperespectrais/s Throughput: 31,25 MB/s Consumo: 15 W, Peso: 490 g	Monitoramento de saúde vegetal e análise agrícola (Zhang <i>et al.</i> , 2024)
Headwall Nano-Hyperspec	Pushbroom	400–1000 nm	270 bandas espectrais 640 pixels espaciais	Taxa: 300 FPS Throughput: 103,68 MB/s Armazenamento: 480 GB	Pequenas plataformas UAV, excelente adaptabilidade (Adão <i>et al.</i> , 2017a)
Sistemas baseados em Filtros Fabry-Pérot	Snapshot (Captura única)	Variável conforme filtros	150+ bandas Filtros sintonizáveis	Performance variável dependente da aplicação	Tecnologia IMEC Imageamento instantâneo

simultânea de toda a cena espectral e espacial, sobressaem o Cubert S185 FireflEYE SE e soluções baseadas em filtros Fabry-Pérot, ambos voltados para aplicações que demandam imageamento instantâneo e portabilidade. A escolha entre esses modelos está diretamente relacionada ao tipo de aplicação, requisitos de portabilidade e necessidades de processamento em tempo real.

Um dos principais desafios no uso desses sistemas é o gerenciamento do alto volume de dados gerados. Os sensores hiperespectrais produzem throughput na faixa de 30 MB/s a 300 MB/s, exigindo interfaces de alta velocidade como USB 3.0, Camera Link ou GigE Vision, além de soluções de armazenamento local com capacidade e velocidade adequadas. Para ilustrar a magnitude desse desafio, sistemas operando em capacidade máxima podem gerar aproximadamente 4,15 TB de dados em 8 horas de operação contínua, ou até 6 GB por minuto quando embarcados em VANTs.

2.3 Técnicas de Processamento de Imagens Hiperespectrais

O processamento de imagens hiperespectrais envolve uma cadeia complexa de algoritmos especializados, desde o pré-processamento básico até técnicas avançadas de análise espectral. Esta seção apresenta as principais abordagens utilizadas na literatura, com foco nas técnicas que demonstram potencial para implementação em sistemas embarcados, consolidando metodologias validadas em diferentes contextos de aplicação.

2.3.1 Pré-processamento e Correção Radiométrica

O pré-processamento constitui etapa fundamental para garantir a qualidade dos dados hiperespectrais, especialmente em sistemas embarcados operando sob condições variáveis de iluminação e movimento. As operações de pré-processamento resultam em dados corrigidos que permitem comparações entre diferentes séries temporais e até mesmo dados adquiridos por diferentes sensores hiperespectrais (Adão *et al.*, 2017b).

As principais técnicas de pré-processamento incluem:

- **Calibração radiométrica:** Correção das variações de resposta do sensor através de ferramentas de software fornecidas pelos fabricantes de sensores hiperespectrais, que devem georreferenciar e converter cubos de dados DN brutos para radiância. Esta etapa é crítica para garantir a reprodutibilidade e comparabilidade dos dados (Adão *et al.*, 2017b);
- **Correção atmosférica:** Remoção dos efeitos de absorção e espalhamento atmosférico, particularmente crítica em aplicações aéreas. Algoritmos como ATCOR e FLAASH têm sido amplamente validados para esta finalidade;
- **Correção geométrica:** Compensação de distorções geométricas causadas pelo movimento da plataforma e geometria de aquisição, frequentemente combinando dados de orientação externa coletados durante o voo com modelo do sensor e modelo de elevação (Adão *et al.*, 2017b);
- **Redução de ruído espectral:** Aplicação de filtros adaptativos e técnicas de suavização espectral. A implementação de filtros Savitzky-Golay e técnicas baseadas em transformadas wavelets demonstram eficácia na preservação de características espectrais importantes enquanto reduzem componentes ruidosas;

- **Avaliação da qualidade:** A relação sinal-ruído (SNR) representa critério fundamental para caracterização da qualidade dos dados hiperespectrais, sendo essencial para análise quantitativa precisa (Adão *et al.*, 2017b).

2.3.2 Redução Dimensional e Seleção de Bandas

A alta dimensionalidade dos dados hiperespectrais (centenas de bandas espectrais) apresenta desafios computacionais significativos, tornando as técnicas de redução dimensional essenciais para sistemas embarcados. O fenômeno de Hughes, onde o desempenho de classificadores degrada com o aumento da dimensionalidade quando o número de amostras de treinamento é limitado, torna estas técnicas ainda mais críticas (Adão *et al.*, 2017b).

Técnicas Lineares de Redução Dimensional

- **Principal Component Analysis (PCA):** Técnica linear clássica que projeta os dados em subespaço de menor dimensionalidade preservando máxima variância. O PCA concentra a variância espectral e pode ser combinado com outros métodos como compressão wavelet, conseguindo retenção de 99% da variância original com redução de 80-90% das bandas (Adão *et al.*, 2017b);
- **Maximum Noise Fraction (MNF):** Método baseado em PCA que maximiza a relação sinal-ruído, destacado como capaz de alcançar boa performance na redução dimensional de dados hiperespectrais, especialmente eficaz para dados com alta correlação espectral (Adão *et al.*, 2017b);
- **Independent Component Analysis (ICA):** Decomposição em componentes estatisticamente independentes, adequada para separação de assinaturas espectrais sobrepostas e identificação de endmembers puros.

Métodos de Seleção de Bandas

- **Seleção baseada em entropia:** Algoritmos como EMCR (Entropy Multiple Correlation Ratio) conseguem reduzir 70-80% do processamento mantendo alta precisão de classificação, sendo computacionalmente eficientes para sistemas embarcados;
- **Algoritmos genéticos:** Otimização global para seleção de subconjuntos ótimos de bandas, com validação cruzada para evitar overfitting;
- **Métodos híbridos:** Combinação de técnicas de projeção com seleção de bandas, oferecendo balanceamento entre redução dimensional e preservação de informações discriminantes.

2.3.3 Algoritmos de Classificação Espectral

A classificação espectral representa uma das aplicações mais importantes do processamento hiperespectral, sendo fundamental para identificação e mapeamento de materiais. Frameworks de classificação baseados em características espectral-espaciais superam métodos que utilizam apenas informações espectrais (Adão *et al.*, 2017b).

Métodos Clássicos de Classificação

- **Support Vector Machines (SVM):** Classificadores robustos que demonstram excelente desempenho em dados hiperespectrais, com implementações otimizadas conseguindo precisões superiores a 95% em datasets de referência. A eficácia do SVM está relacionada à sua capacidade de lidar com alta dimensionalidade e pequenos conjuntos de treinamento;
- **Random Forest:** Métodos ensemble que combinam múltiplas árvores de decisão, oferecendo boa interpretabilidade e robustez a outliers, com tempos de treinamento significativamente menores que SVM;
- **Spectral Angle Mapper (SAM):** Classificação baseada em similaridade angular entre espectros, computacionalmente eficiente para implementações embarcadas e menos sensível a variações de iluminação.

Abordagens de Aprendizado Profundo

- **Redes Neurais Convolucionais (CNN):** Algoritmos discriminantes para características espectrais e CNNs para características espaciais formam frameworks de desempenho superior. Arquiteturas como ResNet e DenseNet adaptadas para dados hiperespectrais conseguem F1-scores superiores a 0,95 (Adão *et al.*, 2017b);
- **Redes residuais spectral-espaciais:** Frameworks de aprendizado profundo supervisionado capazes de discriminar características de assinaturas espectrais abundantes e contextos espaciais sem necessidade de engenharia manual de características (Adão *et al.*, 2017b);
- **Arquiteturas leves:** Desenvolvimento de redes neurais compactas adequadas para sistemas embarcados, como MobileNets e EfficientNets adaptadas, conseguindo redução de 90% nos parâmetros mantendo alta precisão (Adão *et al.*, 2017b);
- **Abordagens híbridas:** Fusão de perfis de atributos com aprendizado profundo, onde técnicas de perfilamento combinadas com CNN demonstram resultados superiores ao uso individual de cada abordagem (Adão *et al.*, 2017b).

2.3.4 Processamento de Sinais Espectrais Avançado

O processamento específico dos sinais espectrais envolve técnicas matemáticas especializadas para extração de informações dos dados hiperespectrais, incluindo métodos de análise no domínio da frequência e detecção de anomalias.

Análise Espectral no Domínio da Frequência

- **Transformadas Wavelet:** Aplicação de wavelets como Daubechies, Morlet e Biorthogonal para análise tempo-frequência de sinais espectrais. A escolha da wavelet-mãe deve considerar as características morfológicas do sinal, garantindo máxima correlação e preservação das informações espectrais relevantes;
- **Análise de derivadas espectrais:** Cálculo de derivadas primeira e segunda dos espectros para realçar características espectrais sutis e reduzir efeitos de variações

de linha de base. Técnicas como continuum removal são amplamente utilizadas em aplicações geológicas;

- **Transformadas de Fourier:** Análise no domínio da frequência para identificação de periodicidades espectrais e caracterização de ruídos sistemáticos.

Deteção de Anomalias e Alvos Específicos

- **Deteção baseada em CNN:** Para deteção de anomalias, redes neurais convolucionais demonstram superar métodos clássicos como abordagens baseadas em RX, conseguindo taxas de deteção superiores a 90% com baixas taxas de falsos positivos (Adão *et al.*, 2017b);
- **Algoritmos RX adaptivos:** Implementações otimizadas do detector RX com janelas adaptativas e processamento local, adequadas para deteção em tempo real;
- **Análise de mistura espectral:** Decomposição de pixels mistos em endmembers puros através de técnicas como Linear Spectral Unmixing e Non-negative Matrix Factorization, fundamental para mapeamento quantitativo de materiais;
- **Seleção de saliência:** Abordagens de classificação manifold estendidas para aprendizado profundo, apresentadas para deteção de saliência em relação à seleção de bandas em imagens hiperespectrais (Adão *et al.*, 2017b).

2.3.5 Considerações para Implementação Embarcada

A implementação de técnicas de processamento hiperespectral em sistemas embarcados requer considerações específicas quanto à eficiência computacional e restrições de recursos.

- **Otimização algorítmica:** Desenvolvimento de implementações paralelas e uso de operações matriciais otimizadas (BLAS, cuBLAS) para maximizar o throughput de processamento;
- **Arquiteturas heterogêneas:** Combinação de CPU, GPU e FPGA para otimização simultânea de desempenho e consumo energético. Sistemas CPU+FPGA conseguem melhorias de até 40x na eficiência energética;
- **Processamento em pipeline:** Implementação de pipelines de processamento que permitem operação contínua com baixa latência, essencial para aplicações de tempo real;
- **Compressão de dados:** Técnicas de compressão específicas para dados hiperespectrais, como JPEG2000 e compressão baseada em PCA, conseguindo taxas de compressão de 10:1 a 50:1 sem perda significativa de informação.

Em síntese, as técnicas de processamento de imagens hiperespectrais abrangem desde métodos fundamentais de pré-processamento até algoritmos avançados de aprendizado profundo. A escolha da técnica adequada depende da aplicação específica, recursos computacionais disponíveis e requisitos de precisão. A tendência atual aponta para abordagens híbridas que combinam múltiplas técnicas e arquiteturas heterogêneas que otimizam o balanceamento entre precisão, velocidade e eficiência energética (Adão *et al.*, 2017b).

2.4 Tipos de Processadores para Processamento Hiperespectral

A escolha adequada do tipo de processador é fundamental para o desenvolvimento de sistemas hiperespectrais embarcados eficientes. Esta seção analisa as características, vantagens e limitações dos principais tipos de processadores utilizados para processamento hiperespectral, considerando aspectos como desempenho computacional, consumo energético e adequação para diferentes tipos de algoritmos.

2.4.1 Processadores de Uso Geral (CPU)

As CPUs permanecem como componente central em sistemas hiperespectrais embarcados, especialmente adequadas para tarefas sequenciais e de controle. Conforme destacado por Vaithianathan (2025), as CPUs são projetadas para tarefas de propósito geral e se destacam no processamento sequencial, tornando-as ideais para aplicações que requerem alto desempenho em single-thread:

- **Arquiteturas ARM:** Processadores de baixo consumo como ARM Cortex-A series, amplamente utilizados em plataformas embarcadas devido ao excelente balanço desempenho/consumo. Martins et al. (2019) demonstraram a eficácia de processadores ARM operando a 800 MHz para processamento hiperespectral, com tempo de processamento de 0,75ms em implementações otimizadas
- **Arquiteturas x86:** Intel Atom e AMD embedded, oferecendo maior poder computacional com consumo moderado para aplicações que requerem compatibilidade com software legado. Sahovic e Quinten (2025) utilizaram Intel Core i9-9900K para coordenação de sistemas híbridos, demonstrando a importância das CPUs no gerenciamento de I/O e execução de lógica sequencial
- **Características para processamento hiperespectral:** Adequadas para tarefas de controle de fluxo, pré-processamento sequencial e algoritmos de classificação final. A arquitetura interna das CPUs, composta por unidades de controle que orquestram a execução de instruções, permite gerenciamento eficiente de pipelines complexos (Vaithianathan, 2025)
- **Limitações:** Baixo throughput para operações matriciais massivamente paralelas características do processamento hiperespectral. Estudos comparativos demonstram que CPUs apresentam desempenho até 27 vezes inferior aos FPGAs em tarefas de processamento digital de sinais (Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing, 2025)

2.4.2 Unidades de Processamento Gráfico (GPU)

As GPUs se destacam no processamento hiperespectral devido à natureza paralelizável das operações matriciais. Segundo Vaithianathan (2025), as GPUs são otimizadas para processamento paralelo, permitindo o manuseio de milhares de threads simultaneamente, característica particularmente benéfica para processamento de imagens e deep learning:

- **GPUs embarcadas NVIDIA:** Jetson series (Nano, TX2, Xavier, Orin) que combinam GPUs com CPUs ARM em single-board computers de baixo consumo.

Sahovic e Quinten (2025) implementaram com sucesso sistemas utilizando NVIDIA Quadro RTX 5000 para tarefas computacionalmente exigentes, incluindo cálculos baseados em FFT e correlação cruzada

- **Arquiteturas CUDA:** Milhares de cores especializados em operações de ponto flutuante, ideais para álgebra linear e operações matriciais. A arquitetura GPU é composta por múltiplos Streaming Multiprocessors (SMs), cada um contendo numerosas unidades funcionais capazes de executar operações paralelas (Vaithianathan, 2025)
- **Performance em processamento hiperespectral:** Demonstram throughput superior a 330 fps em compressão hiperespectral (Jetson TX2) e excelente desempenho em CNNs para classificação. As GPUs exploram paralelismo em nível de dados através de milhares de cores, tornando-as adequadas para processamento em lote e aplicações de alto throughput (Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing, 2025)
- **Consumo energético:** Faixa de 5-20W para modelos embarcados, adequado para aplicações UAV com restrições energéticas. Michon et al. (2025) destacam que, apesar do alto poder computacional, o consumo energético e a latência no acesso à memória podem ser fatores limitantes

2.4.3 Field-Programmable Gate Arrays (FPGA)

Os FPGAs oferecem a máxima flexibilidade para implementação de algoritmos hiperespectrais otimizados. Como ressaltado na análise comparativa de plataformas digitais (Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing, 2025), os FPGAs demonstram desempenho significativamente superior, sendo 27 vezes mais rápidos que CPUs e 2 vezes mais rápidos que GPUs, consumindo simultaneamente menos energia:

- **Paralelismo customizado:** Capacidade de implementar arquiteturas de processamento específicas para algoritmos hiperespectrais, como pipelines de seleção de bandas e classificação SVM. Martins et al. (2019) demonstraram implementações FPGA de classificadores SVM com precisão acima de 99%, atendendo aos requisitos de tempo real do AVIRIS
- **Eficiência energética:** Implementações otimizadas podem atingir melhorias energéticas de 43,5x comparado a implementações em software (codesign HW/SW). Os FPGAs são circuitos semicondutores programáveis compostos por blocos lógicos customizáveis conectados por interconexões programáveis (Vaithianathan, 2025)
- **Latência ultra-baixa:** Tempo de classificação de 0,1ms/pixel em implementações otimizadas de SVM com seleção EMCR. Martins et al. (2019) reportaram tempo de classificação de 0,50ms para implementação single-core e 0,10ms para design hexa-core, consumindo respectivamente 17% e 100% dos blocos DSP disponíveis
- **Adequação para pré-processamento:** Ideais para implementação de filtros, correções geométricas e operações de pipeline de baixa latência. Michon et al. (2025) enfatizam que a natureza reconfigurável dos FPGAs permite otimização

máxima adaptada a aplicações específicas, com níveis adaptáveis de paralelização e pipeline

2.5 Arquiteturas Heterogêneas de Processamento

As arquiteturas heterogêneas combinam diferentes tipos de processadores para otimizar simultaneamente desempenho, consumo energético e latência. Esta abordagem é particularmente relevante para processamento hiperspectral embarcado, onde diferentes estágios do pipeline computacional se beneficiam de tipos distintos de processadores.

2.5.1 Fundamentos de Computação Heterogênea

A computação heterogênea baseia-se no princípio de que diferentes tipos de processadores possuem eficiências variáveis para diferentes tipos de cargas computacionais. Segundo Vaithianathan (2025), a integração visa aproveitar os pontos fortes únicos de cada arquitetura, melhorando a eficiência computacional e o desempenho em vários domínios:

- **Especialização de processadores:** Cada tipo de processador (CPU, GPU, FPGA, DSP) apresenta vantagens específicas para determinados tipos de operações. Sahovic e Quinten (2025) demonstram explicitamente como FPGAs destacam-se em aquisição rápida de dados, CPUs em coordenação de sistema, e GPUs em computação massivamente paralela
- **Particionamento de algoritmos:** Divisão do pipeline de processamento em estágios adequados para cada tipo de processador. A alocação estratégica de tarefas de acordo com os pontos fortes de cada componente de hardware atende às demandas computacionais e de tempo real essenciais para monitoramento de fluxo multifásico (Sahovic; Quinten, 2025)
- **Otimização multi-objetivo:** Balanceamento simultâneo entre desempenho, consumo energético, latência e precisão. Vaithianathan (2025) destaca que a alocação dinâmica de tarefas para a unidade de processamento mais adequada otimiza a utilização de recursos e minimiza a latência
- **Codesign HW/SW:** Metodologia integrada de desenvolvimento que considera hardware e software simultaneamente. O codesign hardware- software enfatiza o desenvolvimento simultâneo de componentes de hardware e software para alcançar desempenho e eficiência ideais (Vaithianathan, 2025)

2.5.2 Arquiteturas CPU+GPU Integradas

A combinação de CPU e GPU em sistemas embarcados oferece flexibilidade e desempenho para processamento hiperspectral. Vaithianathan (2025) ressalta que arquiteturas de memória unificada facilitam o compartilhamento contínuo de dados entre CPUs e GPUs, reduzindo overhead e melhorando a velocidade computacional:

- **SoCs ARM+GPU:** Sistemas como NVIDIA Jetson que integram CPUs ARM com GPUs CUDA em single-package solutions. A tendência em direção a designs System

on Chip (SoC) permite a integração de múltiplos tipos de processadores dentro de um único chip, aprimorando ainda mais o desempenho em ambientes compactos (Vaithianathan, 2025)

- **Divisão de tarefas:** CPU responsável por controle, pré-processamento sequencial e classificação final; GPU para operações matriciais, filtragem e redes neurais. O controlador DMA atua como ponte entre CPU e GPU, facilitando transferência contínua de dados entre memória host e memória global da GPU (Vaithianathan, 2025)
- **Comunicação eficiente:** Memória compartilhada e interfaces de alta velocidade para minimizar overhead de transferência de dados. Tecnologias como AMD's Heterogeneous System Architecture (HSA) exemplificam esta tendência ao permitir acesso de memória compartilhada através de várias unidades de processamento (Vaithianathan, 2025)
- **Performance demonstrada:** Throughput >330 fps em compressão hiperespectral com consumo <20W. Estudos demonstram que GPUs fornecem forte capacidade paralela mas encontram ineficiências de transferência de dados (Sahovic; Quinten, 2025)

2.5.3 Sistemas CPU+FPGA

A combinação CPU+FPGA oferece máxima flexibilidade para otimização de algoritmos específicos. Martins et al. (2019) demonstraram implementações bem-sucedidas de aceleradores de hardware para classificação de imagens hiperespectrais em tempo real usando esta abordagem:

- **Aceleração customizada:** FPGA implementa algoritmos críticos como seleção de bandas EMCR e classificação SVM otimizada. A metodologia EMCR (Entropy and Mean Correlation Ratio) aumentou consideravelmente o poder de predição, alcançando níveis de precisão superiores a 99% (Martins; Faria; Prado, 2019)
- **Pipeline de baixa latência:** Processamento contínuo com latência determinística, adequado para aplicações de tempo real. FPGAs garantem baixo nível de latência contra GPUs e CPUs, pois trabalham em bare metal sem sistema operacional (Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing, 2025)
- **Eficiência energética:** Melhorias de até 43,5x no consumo energético através de codesign otimizado. A natureza reconfigurável dos FPGAs permite maximização da otimização adaptada a aplicações específicas (Michon *et al.*, 2025)
- **Flexibilidade de reconfiguração:** Capacidade de adaptar o hardware para diferentes algoritmos e requisitos de aplicação. Ao contrário de CPUs e GPUs, que são arquiteturas fixas programáveis por software, FPGAs são reconfiguráveis com engines computacionais definidos pelo usuário (Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing, 2025)

2.5.4 Arquiteturas Tri-híbridas CPU+GPU+FPGA

A integração de três tipos de processadores permite otimização máxima do pipeline hiperspectral. Sahovic e Quinten (2025) propuseram uma arquitetura computacional híbrida combinando componentes FPGA, CPU e GPU para superar limitações individuais:

- **Especialização por estágio:** FPGA para pré-processamento e seleção de bandas; GPU para reconstrução e operações matriciais; CPU para classificação final e controle. Inicialmente, um FPGA Xilinx Spartan-7 integrado realiza aquisição rápida de dados, filtragem de ruído e serialização estruturada. Subsequentemente, a CPU gerencia sincronização de dados e gerenciamento de memória. A GPU então aproveita seus milhares de cores paralelos para executar eficientemente operações computacionalmente intensivas (Sahovic; Quinten, 2025)
- **Balanceamento de carga:** Distribuição dinâmica de tarefas conforme disponibilidade de recursos e características dos dados. A atribuição estratégica de tarefas de acordo com os pontos fortes de cada componente de hardware garante precisão e desempenho confiável em tempo real (Sahovic; Quinten, 2025)
- **Metas quantitativas:** Potencial para atingir >30 fps em imagens $614 \times 512 \times 224$ com consumo $<15W$ e latência $<40ms$. Vaithianathan (2025) antecipa uma mudança em direção a sistemas de computação heterogênea hierárquica que utilizarão múltiplas arquiteturas não apenas dentro de um único nó, mas também através de sistemas distribuídos
- **Complexidade de implementação:** Requer metodologias avançadas de codesign e otimização multi-dimensional. O desenvolvimento de frameworks de programação unificados que simplificam o desenvolvimento e melhoram a interoperabilidade entre diferentes componentes de hardware é crucial para maximizar o potencial de sistemas de computação heterogênea (Vaithianathan, 2025)

2.6 Plataformas de Processamento para Sensoriamento Remoto

Esta seção apresenta as principais plataformas computacionais utilizadas especificamente para processamento hiperspectral em aplicações de sensoriamento remoto, com foco em sistemas embarcados para UAVs, satélites CubeSat e plataformas terrestres móveis.

2.6.1 Sistemas Embarcados Especializados

Plataformas desenvolvidas especificamente para aplicações de sensoriamento remoto e processamento hiperspectral:

- **SightLine Applications 4100-OEM:** Sistema baseado em Qualcomm QCS8250 para aplicações ISR (Intelligence, Surveillance, Reconnaissance), demonstrando arquitetura heterogênea comercial viável

- **Plataformas FPGA embarcadas:** Sistemas como Xilinx Zynq UltraScale+ que combinam ARM cores com FPGA fabric, adequados para implementações customizadas de alta eficiência
- **Single-board computers especializados:** Plataformas como RaspberryPi com aceleradores computacionais para aplicações de baixo custo e consumo ultra-baixo

2.6.2 Tendências Futuras

A análise do mercado atual indica tendências importantes para o desenvolvimento futuro de plataformas hiperspectrais:

- **Integração de NPU:** Crescente incorporação de unidades de processamento neural dedicadas para acelerar algoritmos de deep learning
- **Arquiteturas heterogêneas:** Evolução para sistemas que combinam múltiplos tipos de processadores em arquiteturas otimizadas
- **Edge computing inteligente:** Desenvolvimento de frameworks para processamento distribuído e colaborativo entre múltiplas plataformas
- **Otimização multi-objetivo:** Algoritmos avançados que otimizam simultaneamente precisão, consumo, latência e qualidade

Capítulo 3

Proposta e metodologia

Capítulo 4

Conclusões e trabalhos futuros

Referências

Adão, T. *et al.* Hyperspectral imaging: a review on UAV-based sensors, data processing and applications for agriculture and forestry. **Remote Sensing**, v. 9, n. 11, p. 1110, 2017. DOI: 10.3390/rs9111110.

Adão, T. *et al.* Hyperspectral imaging: a review on UAV-based sensors, data processing and applications for agriculture and forestry. **Remote Sensing**, v. 9, n. 11, p. 1110, 2017. DOI: 10.3390/rs9111110.

BAPTISTA, G. M. d. M. **Sensoriamento remoto hiperespectral**. 2. ed. Rio de Janeiro: Interciência, 2019. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing. Comparative analysis of FPGA, GPU, and CPU platforms for digital signal processing. **Journal of Low Power Electronics and Applications**, v. 15, n. 40, 2025.

LORENZZETTI, J. A. **Princípios físicos de sensoriamento remoto**. 1. ed. São Paulo: Blucher, 2015. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Martins, L. A.; Faria, F. A.; Prado, D. R. A hardware accelerator for real-time hyperspectral image classification using machine learning. *In*: PROCEEDINGS of the 32nd Symposium on Integrated Circuits and Systems Design. New York: ACM, 2019. p. 1–6.

Michon, R.; Shan, C.; Granzow, M.; Smith, J. O. Modal physical modelling on GPUs and FPGAs: a comparative study for real-time audio. **Frontiers in Signal Processing**, v. 1, p. 1522604, 2025.

Sahovic, B.; Quinten, M. Hybrid computational approach for WMS processing. **Results in Engineering**, v. 27, p. 106188, 2025.

Vaithianathan, M. The future of heterogeneous computing: integrating CPUs, GPUs, and FPGAs for high-performance applications. **International Journal of Emerging Trends in Computer Science and Information Technology**, v. 1, n. 1, p. 12–23, 2025.

Zhang, Z. *et al.* UAV hyperspectral remote sensing image classification: a systematic review. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, v. 18, p. 3099–3124, 2024. DOI: 10.1109/JSTARS.2024.3514789.