



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Diego de Freitas Maia

**Arquiteturas Heterogêneas para Processamento
Hiperespectral Embarcado: Análise Multi-critério de
Soluções FPGA-GPU em Sistemas UAV Agrícolas**

Limeira
2026

Diego de Freitas Maia

**Arquiteturas Heterogêneas para Processamento Hiperespectral
Embarcado: Análise Multi-critério de Soluções FPGA-GPU em
Sistemas UAV Agrícolas**

Dissertação apresentada à Faculdade de Tecnologia da Universidade Estadual de Campinas como parte dos requisitos para a obtenção do título de Mestre em Tecnologia, na área de Sistemas de Informação e Comunicação.

Orientador: Prof. Dr. Leandro Ronchini Ximenes

Este trabalho corresponde à versão final da Dissertação defendida por Diego de Freitas Maia e orientada pelo Prof. Dr. Leandro Ronchini Ximenes.

Limeira
2026

Na versão final, esta página será substituída pela ficha catalográfica no TCC, na dissertação de mestrado ou na tese de doutorado.

Caso não tenha ficha catalográfica, deixe essa página em branco conforme as instruções a seguir.

No arquivo principal (`tese.tex`), adicione o nome do arquivo PDF com a ficha catalográfica como parâmetro para o comando `\fichacatalografica{ }`. Caso a versão da sua dissertação ou tese seja a versão anterior à aprovação pela banca, você pode substituir esta por uma página em branco com o comando a seguir:

```
\fichacatalografica{branco.pdf}
```

Substitua o arquivo `branco.pdf` por `white.pdf`, nos textos em inglês, ou por `blanco.pdf`, para textos em espanhol. Todos esses arquivos PDF já estão disponíveis neste modelo.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão fazer referência ao apoio recebido e inserir esta informação na ficha catalográfica, além do nome da agência, o número do processo pelo qual recebeu o auxílio.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Prof. Dr. Leandro Ronchini Ximenes

Presidente da Comissão Julgadora

Prof.^a Dr.^a Segunda Avaliadora

Instituição da segunda avaliadora

Dr. Terceiro Avaliador

Instituição do terceiro avaliador

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria de Pós-graduação da Faculdade de Tecnologia.

Sumário

Resumo	9
Abstract	1
1 Introdução	2
1.1 Contexto e Motivação	4
1.2 Problema de Pesquisa	7
1.3 Objetivos	9
1.4 Estrutura da Dissertação	10
2 Levantamento Bibliográfico	11
2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais	11
2.1.1 O espectro eletromagnético	11
2.1.2 Propriedades Ópticas dos Materiais	14
2.1.3 Princípios de Sensoriamento Remoto Hiperespectral	15
2.2 Técnicas de Processamento de Imagens Hiperespectrais	18
2.2.1 Pré-processamento e Correção Radiométrica	18
2.2.2 Redução Dimensional e Seleção de Bandas	19
2.2.3 Algoritmos de Classificação Espectral	20
2.3 Arquiteturas Heterogêneas de Processamento	20
2.3.1 Fundamentos de Computação Heterogênea	20
2.3.2 Arquiteturas CPU+GPU Integradas	22
2.3.3 Sistemas CPU+FPGA	23
3 Metodologia	24
3.1 Considerações Iniciais	24
3.2 Delimitação do Escopo Tecnológico	25
3.2.1 Plataformas de Hardware Específicas	25
3.2.2 Ferramentas de Simulação e Desenvolvimento	25
3.3 Dataset Selecionado	25
3.3.1 Cenários de Teste Específicos	26
3.4 Técnicas de Processamento Específicas	28
3.4.1 Pipeline de Pré-processamento	28
3.4.2 Técnicas de Processamento Principal	29
3.5 Protocolo de Comparação e Avaliação	31
3.5.1 Métricas de Performance Computacional	31
3.5.2 Métricas de Eficiência Energética	32
3.5.3 Métricas de Qualidade para Agricultura	33

3.6	Cronograma de Execução Detalhado (10 meses)	34
3.6.1	Aquisição e Setup de Hardware (8 semanas)	34
3.6.2	Implementação FPGA (6 semanas)	34
3.6.3	Implementação GPU (6 semanas)	34
3.6.4	Validação Experimental e Comparação (6 semanas)	35
3.6.5	Síntese e Publicação (6 semanas)	35
3.6.6	Escrita da Dissertação e Defesa (12 semanas)	35
4	Conclusões	37

Lista de Figuras

1.1	Principais componentes de um sistema de sensoriamento remoto hiperspectral embarcado: sensor de imageamento, unidade de processamento heterogênea (FPGA/GPU), sistema de armazenamento e interface de comunicação para aplicações em agricultura de precisão.	3
2.1	Conceito da espectroscopia de imageamento desenvolvido pelo sensor AVIRIS (JPL/NASA). A figura ilustra como 224 bandas espectrais são obtidas simultaneamente, permitindo a análise de diferentes materiais (atmosfera, solos, água, vegetação) através de suas assinaturas espectrais características. Este princípio fundamenta o processamento hiperspectral em sistemas embarcados. Fonte: (BAPTISTA, 2019).	12
2.2	Exemplo de imagem hiperspectral AVIRIS capturada sobre São João D’Aliança, GO, mostrando dados de vapor d’água em diferentes bandas espectrais. A imagem ilustra a complexidade dos dados hiperspectrais que devem ser processados por arquiteturas heterogêneas em sistemas embarcados para aplicações de sensoriamento remoto em tempo real. Fonte: (BAPTISTA, 2019).	21
3.1	Exemplo de imagem do dataset Salinas Valley mostrando a distribuição espacial das classes de culturas agrícolas em escala de cinza. A imagem apresenta dimensões 512×217 pixels com diferentes tonalidades representando as 16 classes de cobertura do solo, incluindo culturas de alface em diferentes estágios fenológicos e áreas de solo exposto. Fonte: Grupo de Visão Computacional e Processamento de Imagens - Universidade do País Vasco (Grupo de Visión Computacional y Procesamiento de Imágenes, 2013). .	26
3.2	Cronograma detalhado da pesquisa estruturado em 6 fases principais ao longo de 10 meses (40 semanas): Aquisição de Hardware, Implementação FPGA, Implementação GPU, Validação Experimental, Síntese e Publicação, e Escrita da Dissertação com Defesa.	36

Lista de Tabelas

2.1	Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).	13
-----	--	----

Resumo

O processamento de imagens hiperespectrais em sistemas embarcados representa um dos desafios computacionais mais complexos da atualidade, exigindo conciliação entre requisitos aparentemente conflitantes de alta performance, baixa latência e eficiência energética em plataformas com severas restrições de recursos. Esta dissertação apresenta uma metodologia sistemática para otimização computacional de processamento hiperespectral embarcado, focando na análise comparativa de trade-offs entre arquiteturas heterogêneas FPGA e GPU através de abordagem exploratória-comparativa baseada em simulação e modelagem teórica aplicada à agricultura de precisão.

A pesquisa adota abordagem metodológica inovadora que privilegia análise teórica e simulada sobre implementação física, justificada pela necessidade de investigar sistematicamente múltiplas alternativas arquiteturais sob condições controladas. A metodologia estrutura-se em oito componentes principais: catalogação sistemática de técnicas de otimização FPGA e GPU; modelagem teórica comparativa de performance; framework de simulação integrado utilizando dataset Salinas Valley; estudo comparativo cross-platform; protocolo de benchmarking padronizado; análise multi-critério baseada em metodologia AHP e análise de Pareto; design space exploration para identificação de configurações ótimas; e síntese de arquitetura heterogênea otimizada.

A revisão sistemática da literatura revelou lacuna metodológica significativa: apenas uma pequena parcela dos estudos abordam sistemas completos integrados para aplicações agrícolas, enquanto a maioria foca em técnicas isoladas ou otimizações específicas de plataforma sem considerar requisitos de agricultura de precisão. Esta fragmentação impede análise sistemática de trade-offs e identificação de soluções ótimas para cenários específicos de monitoramento de culturas através de índices de vegetação especializados (NDVI, NDRE, EVI, SAVI).

Como principal contribuição, desenvolve-se framework metodológico unificado que permite comparação objetiva entre diferentes abordagens arquiteturais considerando múltiplos critérios de performance: throughput computacional (>200 pixels/s), latência determinística (<50 ms), eficiência energética (>30 GOPS/W), e precisão de classificação (Overall Accuracy $>90\%$) para aplicações em culturas de milho e soja. A metodologia proposta estabelece base científica rigorosa para investigação de sistemas hiperespectrais embarcados, preenchendo lacuna identificada na literatura e proporcionando framework reproduzível para pesquisas futuras.

Os resultados esperados incluem identificação quantitativa de trade-offs fundamentais entre performance e eficiência energética, proposição de arquitetura heterogênea otimizada baseada em análise sistemática multi-critério, e desenvolvimento de recomendações práticas para seleção de técnicas segundo requisitos específicos de aplicação em agricultura de precisão, monitoramento ambiental e sistemas UAV autônomos.

Palavras-chave: Processamento Hiperespectral, Arquiteturas Heterogêneas, Metodologia Comparativa, Otimização Computacional, Análise Multi-critério, Sistemas Embarcados, FPGA, GPU, Agricultura de Precisão.

Abstract

Hyperspectral image processing in embedded systems represents one of the most complex computational challenges of today, requiring reconciliation between apparently conflicting requirements of high performance, low latency, and energy efficiency in platforms with severe resource constraints. This dissertation presents a systematic methodology for computational optimization of embedded hyperspectral processing, focusing on comparative analysis of trade-offs between FPGA and GPU heterogeneous architectures through an exploratory-comparative approach based on simulation and theoretical modeling applied to precision agriculture.

The research adopts an innovative methodological approach that prioritizes theoretical and simulated analysis over physical implementation, justified by the need to systematically investigate multiple architectural alternatives under controlled conditions. The methodology is structured into eight main components: systematic cataloging of FPGA and GPU optimization techniques; comparative theoretical performance modeling; integrated simulation framework using Salinas Valley dataset; cross-platform comparative study; standardized benchmarking protocol; multi-criteria analysis based on AHP methodology and Pareto analysis; design space exploration for optimal configuration identification; and optimized heterogeneous architecture synthesis.

The systematic review of literature revealed a significant methodological gap: only a small portion of studies address complete integrated systems for agricultural applications, while the majority focus on isolated techniques or platform-specific optimizations without considering precision agriculture requirements. This fragmentation prevents systematic trade-off analysis and identification of optimal solutions for specific crop monitoring scenarios through specialized vegetation indices (NDVI, NDRE, EVI, SAVI).

As the main contribution, a unified methodological framework is developed that enables objective comparison between different architectural approaches considering multiple performance criteria: computational throughput (>200 pixels/s), deterministic latency (<50 ms), energy efficiency (>30 GOPS/W), and classification accuracy (Overall Accuracy $>90\%$) for corn and soybean crop applications. The proposed methodology establishes a rigorous scientific foundation for embedded hyperspectral systems investigation, filling the identified literature gap and providing a reproducible framework for future research.

Expected results include quantitative identification of fundamental trade-offs between performance and energy efficiency, proposition of an optimized heterogeneous architecture based on systematic multi-criteria analysis, and development of practical recommendations for technique selection according to specific application requirements in precision agriculture, environmental monitoring, and autonomous UAV systems.

Keywords: Hyperspectral Processing, Heterogeneous Architectures, Comparative Methodology, Computational Optimization, Multi-criteria Analysis, Embedded Systems, FPGA, GPU, Precision Agriculture.

Capítulo 1

Introdução

O sensoriamento remoto hiperespectral estabeleceu-se como tecnologia de imageamento avançada que revoluciona métodos de caracterização de materiais, superfícies e fenômenos naturais através da aquisição simultânea de informações espaciais e espectrais de alta resolução. Os sistemas hiperespectrais capturam informações detalhadas sobre composição química e física de objetos através da aquisição de centenas de bandas espectrais estreitas (tipicamente 100-300 bandas), cada uma com largura espectral de 2-10 nm, cobrindo faixas específicas do espectro eletromagnético na região VNIR-SWIR (400-2500 nm) (LORENZZETTI, 2015).

Esta capacidade contrasta significativamente com sistemas multispectrais convencionais, como Landsat TM5 (6-12 bandas com largura de 60-200 nm), que operam com bandas espectrais relativamente largas e espaçadas. Os sensores hiperespectrais oferecem resolução espectral superior ($\text{FWHM} \leq 10 \text{ nm}$), permitindo identificação de feições de absorção estreitas e assinaturas espectrais diagnósticas imperceptíveis em sistemas tradicionais. A razão sinal-ruído (SNR) típica de sistemas hiperespectrais modernos varia entre 500:1 e 1000:1, proporcionando precisão suficiente para análises quantitativas de composição material (LORENZZETTI, 2015).

Esta tecnologia habilita aplicações diversificadas em agricultura de precisão, proporcionando capacidades avançadas de detecção de estresse hídrico através da análise de feições de absorção da água (1450 nm e 1940 nm), identificação de deficiências nutricionais via índices de vegetação especializados (NDVI, NDRE, EVI, SAVI), e detecção precoce de infestações de pragas através de alterações nas assinaturas espectrais foliares. A Figura 1.1 ilustra os componentes principais de um sistema hiperespectral embarcado integrado. Adão *et al.* (2017) demonstram que UAVs emergiram como plataforma custo-efetiva para imageamento hiperespectral, substituindo satélites e aeronaves tripuladas em aplicações de monitoramento localizado, com classificadores Support Vector Machine (SVM) com kernel RBF alcançando Overall Accuracy (OA) de 92% e coeficiente Kappa (κ) superior a 0,90 utilizando apenas 10 amostras de treinamento por classe.

No monitoramento ambiental, os sistemas hiperespectrais permitem caracterização quantitativa de ecossistemas, detecção de poluentes através de suas assinaturas espectrais específicas, e acompanhamento temporal de mudanças climáticas com precisão radiométrica superior a 95%. Em aplicações de defesa e segurança, a tecnologia detecta materiais camuflados explorando diferenças sutis nas propriedades espectrais, enquanto na prospecção mineral facilita identificação remota de depósitos através de feições de absorção diagnósticas de minerais específicos nas regiões VNIR e SWIR (BAPTISTA, 2019).




Figura 1.1: Principais componentes de um sistema de sensoriamento remoto hiperespectral embarcado: sensor de imageamento, unidade de processamento heterogênea (FPGA/GPU), sistema de armazenamento e interface de comunicação para aplicações em agricultura de precisão.

O processamento de dados hiperespectrais — que podem exceder centenas de megabytes por frame (tipicamente 200-500 MB para imagens 512×217×204 bandas) — em plataformas embarcadas com restrições rigorosas de energia (10-20 W), peso (< 2 kg) e tamanho representa desafio computacional central da era moderna de sistemas autônomos. A complexidade computacional emerge da necessidade de processamento em tempo real (throughput > 100 pixels/s) de algoritmos intensivos como Principal Component Analysis (PCA), classificação SVM com kernel RBF, e cálculo de índices de vegetação, mantendo simultaneamente precisão de classificação superior a 90% (Overall Accuracy) e eficiência energética adequada para operação autônoma prolongada. Esta dissertação investiga sistematicamente este problema multidimensional, propondo abordagem metodológica rigorosa baseada em análise comparativa quantitativa e síntese de arquiteturas heterogêneas otimizadas.

Esta pesquisa aborda uma lacuna na literatura: ausência de frameworks para avaliação e otimização de técnicas de processamento hiperespectral em sistemas embarcados. Através de metodologia estruturada, investigamos trade-offs entre performance computacional, eficiência energética e precisão de classificação, buscando possíveis soluções arquiteturais para diferentes cenários de aplicação.

1.1 Contexto e Motivação

O processamento de imagens hiperespectrais em sistemas embarcados representa desafio computacional multidimensional de complexidade exponencial. A complexidade fundamental emerge das características intrínsecas dos dados hiperespectrais, onde cada pixel constitui um vetor espectral de alta dimensionalidade ($\mathbb{R}^{200-300}$) contendo assinatura espectral composta por centenas de valores espectrais (tipicamente 150-300 bandas após filtragem atmosférica) que capturam propriedades biofísicas e bioquímicas específicas dos objetos observados através de processos de interação radiação-matéria (Zhang *et al.*, 2024).

Esta riqueza informacional constitui simultaneamente a vantagem analítica e o desafio computacional central do imageamento hiperespectral. A dimensionalidade dos dados resulta em volumes típicos de 200-500 MB por frame para sistemas como Salinas Valley (512×217×204 bandas), exigindo processamento intensivo de operações matriciais de alta precisão (≥ 32 -bit floating point) para preservar características espectrais sutis. O desafio intensifica-se pela necessidade de processamento em tempo real (latência < 100 ms por frame) sob restrições rigorosas de recursos computacionais, energéticos (TDP 10-20 W) e de memória (tipicamente ≤ 8 GB) característicos de plataformas embarcadas para UAVs.

O desafio computacional intensifica-se exponencialmente em aplicações de veículos aéreos não tripulados (UAVs) para imageamento hiperespectral, onde as condições operacionais introduzem complexidades adicionais de processamento. Imagens hiperespectrais capturadas por UAVs exibem variações espectrais pronunciadas (desvio padrão espectral 15-30% superior) comparadas aos dados de plataformas espaciais estabilizadas, apresentando desafios computacionais específicos para algoritmos de classificação que assumem distribuições espectrais homogêneas (Zhang *et al.*, 2024).

Esta complexidade surge das condições operacionais dinâmicas dos UAVs: variações de altitude (50-500 m), ângulos de observação variáveis (0-30° off-nadir), condições atmosféricas heterogêneas (vapor d'água, aerossóis), e variações de iluminação solar introduzem heterogeneidade espectral e radiométrica que requer correções adaptativas em tempo real. Sistemas tradicionais de processamento, projetados para dados espaciais estáveis, demonstram degradação de performance (redução 20-40% na Overall Accuracy) quando

aplicados diretamente a dados UAV sem pré-processamento especializado. A necessidade de correção geométrica dinâmica, calibração radiométrica adaptativa, e filtragem atmosférica em tempo real adiciona overhead computacional de 30-50% ao pipeline de processamento.

O problema intensifica-se exponencialmente com requisitos rigorosos de processamento em tempo real para aplicações críticas. Sistemas hiperspectrais embarcados devem satisfazer simultaneamente múltiplos requisitos conflitantes: alta taxa de compressão (razões 10:1 a 50:1) devido aos volumes massivos de dados, processamento em tempo real com throughput mínimo de 100-330 pixels/s para evitar acúmulo de dados não processados (buffer overflow), latência determinística inferior a 100 ms para aplicações de tempo real, e complexidade computacional rigorosamente limitada (máximo 2.500 operações de ponto flutuante por pixel) devido às restrições de recursos das plataformas embarcadas (Díaz *et al.*, 2019).

A análise quantitativa dos requisitos revela trade-offs fundamentais: algoritmos de redução dimensional como PCA requerem decomposição de matrizes de covariância ($d \times d$, onde $d \approx 200$ bandas), resultando em complexidade $O(d^3)$ que excede capacidades de processamento em tempo real para plataformas com TDP limitado. Classificadores SVM com kernel RBF, embora proporcionem alta precisão (OA > 95%), apresentam complexidade de inferência $O(n_{sv} \times d)$ onde n_{sv} pode exceder milhares de support vectors, tornando-se computacionalmente proibitivos para processamento pixel-wise em tempo real.

A análise sistemática dos trabalhos existentes revela limitações fundamentais das técnicas tradicionais de processamento quando aplicadas ao contexto embarcado com restrições rigorosas. Manolakis e Shaw (2002) demonstram que detectores estatísticos clássicos como Reed-Xiaoli (RX) e matched filters, embora teoricamente fundamentados em princípios de detecção ótima, assumem distribuições gaussianas multivariadas que frequentemente não se aplicam a cenários reais de dados hiperspectrais (teste Shapiro-Wilk com p-value < 0,05 para 60-80% das bandas espectrais). A violação dessas premissas resulta em degradação significativa da performance (redução 15-25% na taxa de detecção para false alarm rate fixo de 10^{-4}).

Nasrabadi (2014) complementa esta análise identificando que detectores adaptativos como ACE (Adaptive Coherence Estimator) e GLRT (Generalized Likelihood Ratio Test) superam métodos de correlação simples em cenários não-gaussianos, mas requerem processamento computacional intensivo: ACE demanda inversão de matrizes de covariância $O(d^3)$ e GLRT necessita otimização iterativa com 50-100 iterações por pixel. Para dados Salinas Valley ($d = 204$ bandas), estas operações excedem 10^6 operações de ponto flutuante por pixel, inviabilizando processamento em tempo real em plataformas com TDP ≤ 20 W.

Díaz *et al.* (2019) observam que, embora compressores com perdas alcancem performance satisfatória em termos de taxa de distorção (PSNR > 40 dB para razões 20:1), eles são caracterizados por custos computacionais exponenciais (complexidade $O(n^2 \log n)$ para transformadas wavelets 2D), requisitos intensivos de memória (buffers > 100 MB para processamento por blocos), e natureza não escalável com resolução espectral, impedindo seu uso em aplicações sob restrições rigorosas de latência (< 100 ms), energia (< 2 J/frame), e memória (< 8 GB), típicas da compressão embarcada em UAVs.

A demanda crescente por aplicações autônomas tem impulsionado o desenvolvimento acelerado de soluções baseadas em arquiteturas heterogêneas especializadas, que combinam diferentes tipos de processadores para otimização simultânea de throughput, latência e eficiência energética. O avanço dos UAVs, combinado com a miniaturização de equipamentos de imageamento hiperspectral (redução de peso de 50-80% em sistemas como Specim FX10 e Resonon Pika L), tornou o sensoriamento remoto hiperspectral baseado em UAV uma

tecnologia essencial para observação da Terra com resolução temporal e espacial sem precedentes (Zhang *et al.*, 2024).

No entanto, Zhang *et al.* (2024) ressaltam que os sensores hiperespectrais baseados em UAV, embora ofereçam vantagens significativas em capturar informações espectrais de alta resolução de objetos terrestres (GSD de 1-10 cm para altitudes 50-200 m), também apresentam desafios computacionais exponenciais relacionados ao processamento de dados de alta resolução espacial (até 4096×4096 pixels), temporal (até 60 fps), e espectral (200-400 bandas), resultando em taxas de dados de 1-10 GB/s que excedem capacidades de armazenamento e transmissão de plataformas embarcadas convencionais.

O cenário atual de pesquisa revela avanços significativos em técnicas individuais de otimização, com deep learning emergindo como paradigma dominante para classificação hiperespectral. Técnicas avançadas incluem redes neurais convolucionais (CNNs) com arquiteturas 3D que exploram correlações espectral-espaciais, métodos baseados em Transformer que aplicam mecanismos de atenção para seleção adaptativa de bandas, redes neurais recorrentes (RNNs) para modelagem sequencial de assinaturas espectrais, redes neurais de grafos convolucionais (GCNs) que capturam relações topológicas entre pixels, redes adversariais generativas (GANs) para aumento de dados e correção de domínio, e modelos híbridos que combinam múltiplas arquiteturas, demonstrando potencial superior na classificação de imagens hiperespectrais com Overall Accuracy típica de 85-98% em datasets padronizados (Zhang *et al.*, 2024).

Bioucas-Dias *et al.* (2012) demonstram que técnicas de unmixing espectral, incluindo abordagens geométricas (N-FINDR, VCA), estatísticas (ICA, NMF) e de regressão esparsa (SUnSAL, CLSUnSAL), são fundamentais para análise quantitativa de pixels mistos, com métodos spectral-spatial alcançando RMSE 15-30% inferior comparado à análise apenas espectral. A integração de informações espaciais através de filtros morfológicos, regularização espacial, e análise de contexto local pode melhorar significativamente a precisão (ganhos 5-15% na Overall Accuracy) e robustez da classificação, explorando características espaciais e espectrais simultaneamente através de arquiteturas end-to-end otimizadas.

Paralelamente, Díaz *et al.* (2019) demonstram o potencial transformador das GPUs embarcadas para compressão hiperespectral em tempo real, implementando o compressor HyperLCA (Lossy Compression Algorithm for Hyperspectral Image System) otimizado para arquiteturas CUDA nos kits de desenvolvimento NVIDIA Jetson TK1 (192 cores CUDA, TDP 10 W) e TX2 (256 cores Pascal, TDP 7,5-15 W). Os resultados experimentais obtidos pelos autores demonstram que o compressor HyperLCA consegue processar consistentemente mais de 330 frames por segundo (throughput sustentado) para imagens 512×512×224 bandas, com razão de compressão 20:1 e PSNR superior a 40 dB, verificando simultaneamente a eficácia do algoritmo HyperLCA e o alcance de performance em tempo real através das implementações CUDA otimizadas.

Este trabalho estabelece marco fundamental demonstrando como GPUs embarcadas de baixo consumo podem ser efetivamente utilizadas para acelerar algoritmos computacionalmente intensivos de processamento hiperespectral, aproveitando sua arquitetura massivamente paralela (centenas a milhares de cores) para processamento SIMD de operações matriciais típicas. A eficiência energética alcançada (>20 GOPS/W) supera implementações CPU tradicionais por fatores de 5-10x, demonstrando viabilidade de processamento hiperespectral embarcado em plataformas com severas restrições energéticas.

A importância crítica da eficiência energética em sistemas embarcados é demonstrada quantitativamente pelos resultados que mostram melhorias exponenciais através de

arquiteturas heterogêneas otimizadas (Vaithianathan, 2025). Técnicas avançadas de co-design hardware-software, que integram otimizações algorítmicas com implementações arquiteturais especializadas, podem resultar em melhorias dramáticas de 21x na velocidade de throughput (de 15 para 330 fps) (Hwang; Choi; Chang, 2011) e reduções extraordinárias de até 69,88x no consumo energético (de 140 W para 2 W) comparado a implementações GPU convencionais não-otimizadas (Arucu; Iliev, 2025).

Os resultados de co-design evidenciam o potencial transformador de abordagens integradas que exploram sinergias computacionais entre diferentes componentes arquiteturais: FPGAs proporcionam eficiência energética superior (>100 GOPS/W) para operações de ponto fixo e pipelines determinísticos, GPUs embarcadas oferecem throughput paralelo otimizado (>20 GOPS/W) para operações matriciais de ponto flutuante, e CPUs ARM fornecem flexibilidade de controle e gerenciamento de sistema com consumo moderado (5-10 GOPS/W). A combinação estratégica desses elementos em arquiteturas heterogêneas permite explorar o ponto ótimo de performance por watt para cada estágio específico do pipeline de processamento hiperespectral.

Contudo, apesar destes avanços pontuais, é identificado uma lacuna na literatura atual: “Apesar destes avanços, as técnicas atuais de classificação de imagens hiperespectrais de UAV ainda enfrentam diversos desafios, incluindo processamento de dados de alta dimensionalidade, heterogeneidade espectral e variabilidade radiométrica entre diferentes cenas” (Zhang *et al.*, 2024). Os autores enfatizam que deep learning permanece largamente uma abordagem de “caixa preta” para a maioria dos problemas, indicando a necessidade de abordagens mais sistemáticas e interpretáveis.

1.2 Problema de Pesquisa

O problema central investigado nesta dissertação emerge da análise sistemática do estado da arte em processamento hiperespectral embarcado, revelando lacuna metodológica fundamental que permeia a literatura científica contemporânea e impede o desenvolvimento de soluções práticas otimizadas. Esta lacuna se manifesta através de três dimensões críticas identificadas na análise comparativa das técnicas de processamento hiperespectral desenvolvidas nas últimas décadas: fragmentação metodológica, ausência de frameworks de avaliação padronizados, e falta de síntese sistemática de trade-offs arquiteturais.

Zhang *et al.* (2024) documentam que, ao longo das últimas décadas, as técnicas de classificação de imagens hiperespectrais de sensoriamento remoto por UAV alcançaram avanços significativos, oferecendo precisão analítica e detalhes espaciais sem precedentes para observação da Terra. O trabalho oferece revisão abrangente das aplicações e performances de métodos tradicionais de machine learning (SVM, Random Forest, k-NN) e deep learning (CNNs, RNNs, GCNs, Transformers) neste campo, resumindo as principais direções de pesquisa atuais e desafios técnicos específicos.

No entanto, os autores identificam fragmentação metodológica significativa na pesquisa: “algoritmos tradicionais de machine learning podem alcançar certos níveis de precisão de classificação (Overall Accuracy 75-85%), mas frequentemente têm dificuldades com a alta dimensionalidade (curse of dimensionality para $d > 100$ bandas) e natureza não-linear complexa dos dados hiperespectrais”. Esta limitação resulta em degradação sistemática de performance quando o número de bandas espectrais excede o número de amostras de treinamento (fenômeno de Hughes), problema particularmente crítico em aplicações embarcadas onde datasets de treinamento são limitados por restrições de armazenamento e processamento.

Esta fragmentação metodológica resulta em limitações críticas para o desenvolvimento de sistemas práticos otimizados. Díaz *et al.* (2019) observam que a complexidade algorítmica dos métodos de compressão ($O(n^2 \log n)$ para wavelets 2D), combinada com volumes massivos de dados a serem comprimidos (200-500 MB/frame para imagens 512×217×204 bandas) e recursos computacionais rigorosamente limitados dos dispositivos de hardware embarcados (TDP ≤ 20 W, memória ≤ 8 GB, throughput ≥ 100 pixels/s), tornam a compressão em tempo real uma tarefa computacionalmente desafiadora que excede capacidades de plataformas convencionais.

Os autores enfatizam que esta complexidade não é meramente técnica, mas representa barreira fundamental à implementação prática de sistemas hiperespectrais em plataformas com restrições severas de recursos. A análise quantitativa revela que algoritmos estado-da-arte requerem 10^4 - 10^6 operações de ponto flutuante por pixel, resultando em demanda computacional total de 10^{10} - 10^{12} operações por frame, que excede capacidades de processamento em tempo real (< 100 ms/frame) para plataformas embarcadas típicas (1-10 GFLOPS sustentados).

A ausência crítica de metodologias sistemáticas para comparação objetiva entre diferentes abordagens arquiteturais cria ambiente de incerteza metodológica que impede significativamente o progresso científico da área. Zhang *et al.* (2024) destacam que “a performance de diferentes frameworks de redes neurais na classificação de imagens hiperespectrais de UAV varia significativamente, com métodos baseados em GCN e CNN geralmente superando abordagens baseadas em RNN (diferenças típicas de 5-15% na Overall Accuracy)”.

No entanto, os autores observam que cada trabalho científico utiliza métricas de avaliação próprias (Overall Accuracy, Kappa, F1-score, RMSE aplicados inconsistentemente), datasets distintos (Indian Pines, Pavia University, Salinas Valley, Kennedy Space Center com diferentes pré-processamentos), condições experimentais particulares (razões de treinamento/teste variáveis de 10% a 90%, técnicas de validação cruzada inconsistentes), e plataformas de hardware heterogêneas (CPU Intel, GPU NVIDIA, FPGA Xilinx com diferentes gerações e configurações), impedindo comparações diretas quantitativas e síntese de conhecimento sistemática baseada em evidências.

O problema se agrava quando consideramos a predominância de validações em contextos controlados e simplificados. Vaithianathan observa que, embora avanços tenham sido alcançados em arquiteturas heterogêneas individuais, “questões relacionadas ao consumo de energia, escalabilidade, complexidade de programação, gerenciamento de recursos e segurança devem ser abordadas para criar sistemas robustos e eficientes”. O autor enfatiza que as complexidades da integração de múltiplos componentes, as interações entre subsistemas, e os desafios práticos de implementação permanecem inexplorados.

Díaz *et al.* contribuem para esta discussão documentando que os experimentos realizados em seu trabalho são “orientados às necessidades impostas por uma aplicação específica de agricultura inteligente, embora todas as conclusões obtidas sejam extrapoláveis para outros campos nos quais imagens hiperespectrais sensoreadas remotamente devem ser comprimidas em tempo real”. Esta observação ressalta a necessidade de frameworks mais gerais que possam ser aplicados sistematicamente a diferentes domínios de aplicação.

Diante deste cenário multidimensional de lacunas metodológicas, o problema de pesquisa central pode ser formulado de forma precisa: Como desenvolver metodologia sistemática e reproduzível para investigação comparativa quantitativa de técnicas de otimização em processamento hiperespectral embarcado que permita identificação objetiva de arquiteturas ótimas através de análise rigorosa dos trade-offs entre performance computacional (throughput, latência), eficiência energética (GOPs/W, J/pixel), e precisão de classificação

(Overall Accuracy, Kappa, F1-score) para diferentes cenários de aplicação em agricultura de precisão com requisitos específicos (tempo real, autonomia, precisão) e constraints operacionais distintos (TDP, memória, armazenamento)?

1.3 Objetivos

Os objetivos desta dissertação foram estruturados metodologicamente para abordar sistematicamente as lacunas identificadas na literatura científica, respondendo diretamente às questões de pesquisa formuladas através de abordagem teórico-experimental rigorosa. O objetivo geral consiste em desenvolver metodologia sistemática e reproduzível para investigação comparativa quantitativa de técnicas de otimização em processamento hiperespectral embarcado, estabelecendo framework analítico integrado que permita quantificação objetiva e modelagem matemática de trade-offs multidimensionais entre performance computacional (throughput, latência), eficiência energética (GOPS/W, J/pixel), e precisão de classificação (Overall Accuracy, Kappa, F1-score) em arquiteturas heterogêneas FPGA-GPU aplicadas à agricultura de precisão.

Os objetivos específicos desdobram-se em cinco dimensões complementares com metas quantitativas precisas:

Objetivo Específico 1 - Mapeamento Sistemático: Realizar mapeamento abrangente de técnicas de otimização disponíveis na literatura científica (2019-2025), organizando-as segundo taxonomia estruturada que considere tipo de plataforma (FPGA Xilinx, GPU NVIDIA, CPU ARM), estágio de processamento (pré-processamento, redução dimensional, classificação, pós-processamento), métricas de performance específicas (throughput, latência, utilização de recursos, eficiência energética), e adequação quantitativa a cenários de agricultura de precisão (detecção de estresse hídrico, cálculo de índices de vegetação NDVI/NDRE/EVI/SAVI).

Objetivo Específico 2 - Modelagem Matemática: Desenvolver modelos matemáticos analíticos de performance para arquiteturas FPGA (Zynq-7020) e GPU (Xavier NX), estabelecendo framework teórico rigoroso que capture complexidade computacional ($O(n)$, $O(n^2)$, $O(n^3)$), utilização de recursos (DSP, BRAM, LUTs para FPGA; cores CUDA, memória, bandwidth para GPU), e padrões de consumo energético (potência instantânea, energia por pixel, eficiência GOPS/W) através de equações parametrizadas validadas experimentalmente.

Objetivo Específico 3 - Ambiente de Simulação: Implementar ambiente de simulação integrado baseado em ferramentas industriais (Vivado, GHDL, CUDA Toolkit) que permita avaliação comparativa sistemática sob condições experimentais controladas, integrando simuladores específicos de plataforma, dataset Salinas Valley (512×217×204 bandas) como referência padronizada, e protocolos de medição reproduzíveis com instrumentação de alta precisão (INA219 para FPGA, tegrastats para GPU).

Objetivo Específico 4 - Análise Multi-critério: Estabelecer metodologia de análise multi-critério baseada em teoria de decisão quantitativa, incorporando técnicas de otimização Pareto para identificação de soluções não-dominadas no espaço multidimensional de trade-offs, métodos de ponderação de critérios (AHP, TOPSIS) para diferentes perfis de aplicação, e análise de sensibilidade para validação da robustez das soluções identificadas.

Objetivo Específico 5 - Síntese Arquitetural: Propor arquitetura heterogênea otimizada baseada nos resultados da análise comparativa quantitativa, incluindo especificação arquitetural detalhada (particionamento de algoritmos, interfaces de comunicação, protocolos de sincronização), validação teórica através dos modelos

matemáticos desenvolvidos, e estimativas de performance integrada (throughput > 200 pixels/s, latência < 50 ms, eficiência > 30 GOPS/W, Overall Accuracy > 90%).

1.4 Estrutura da Dissertação

Esta dissertação está organizada de modo a construir, de forma progressiva e integrada, o conhecimento necessário para enfrentar o problema multidimensional proposto. O Capítulo 2 apresenta o levantamento bibliográfico, no qual são estabelecidos os fundamentos teóricos essenciais por meio de uma exposição detalhada dos princípios físicos da espectroscopia de imageamento e da formação de imagens espectrais, abordando aspectos como a interação radiação-matéria, as regiões espectrais VNIR-SWIR (400-2500 nm), além de parâmetros relevantes como SNR e FWHM. Nesse capítulo, realiza-se também uma análise sistemática das tecnologias de câmeras hiperespectrais disponíveis, incluindo a discussão de datasets amplamente utilizados, como Salinas Valley e Indian Pines, bem como suas especificações técnicas. São ainda categorizadas, de maneira rigorosa, as principais técnicas de processamento hiperespectral, como PCA, KPCA, EMCR, SVM e métodos de classificação espectral, além de ser apresentada uma análise comparativa das arquiteturas de processamento modernas, contemplando FPGAs (Xilinx Zynq-7020), GPUs embarcadas (NVIDIA Jetson Xavier NX) e sistemas heterogêneos, sempre com ênfase em métricas quantitativas de performance.

Na sequência, o Capítulo 3 é dedicado à metodologia, detalhando o delineamento da pesquisa teórico-experimental e justificando cada escolha metodológica com base em análise crítica da literatura. São descritos os protocolos de implementação adotados para as plataformas FPGA (utilizando Vivado Design Suite e GHDL) e GPU (com CUDA Toolkit), bem como os frameworks de modelagem matemática empregados para análise da complexidade computacional. O capítulo também aborda a construção dos ambientes de simulação integrados, que utilizam o dataset Salinas Valley (512×217×204 bandas) como referência, e a aplicação de instrumentação de precisão para medição energética, como INA219 e tegrastats. O cronograma de execução estruturado em 10 meses (40 semanas) é apresentado em seis fases principais, iniciando com aquisição de hardware e culminando com publicação científica e defesa da dissertação. Por fim, são formalizados matematicamente os procedimentos de análise multi-critério, incluindo a utilização de métodos como otimização Pareto e as metodologias AHP e TOPSIS para ponderação de objetivos, visando a identificação quantitativa das soluções mais adequadas ao contexto estudado.

Capítulo 2

Levantamento Bibliográfico

Este capítulo apresenta a revisão da literatura sobre imageamento hiperespectral, abordando os fundamentos, tecnologias disponíveis e aplicações em sistemas embarcados. A análise foi organizada em sete seções principais: princípios físicos da espectroscopia de imageamento e formação de imagens espectrais; câmeras hiperespectrais, incluindo tipos, modelos e datasets públicos; técnicas de processamento de imagens hiperespectrais; tipos de processadores e suas características para processamento hiperespectral; arquiteturas heterogêneas de processamento; plataformas específicas para sensoriamento remoto; e benchmarking de plataformas comerciais. A revisão abrange trabalhos fundamentais da área e publicações recentes sobre aplicações em agricultura de precisão, monitoramento ambiental e sistemas embarcados, com ênfase nos desafios computacionais do processamento de grandes volumes de dados e soluções para operação em tempo real com restrições energéticas.

2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais

Os conceitos fundamentais do imageamento hiperespectral baseiam-se nos princípios da física óptica que descrevem a interação entre a radiação eletromagnética e a matéria (LORENZZETTI, 2015). Esta seção examina as características das ondas eletromagnéticas e sua organização espectral, com foco particular na faixa de 400 a 2500 nm, que abrange as regiões do visível, infravermelho próximo e infravermelho de ondas curtas, essenciais para o sensoriamento remoto. As propriedades ópticas dos materiais são analisadas através dos fenômenos de reflectância, transmitância e absorção, processos físicos que originam as assinaturas espectrais únicas de cada substância e possibilitam sua identificação e caracterização (BAPTISTA, 2019).

A compreensão da distinção entre sistemas multiespectrais e hiperespectrais, quanto à resolução espectral e capacidade de discriminação, fundamenta a escolha da tecnologia adequada para cada aplicação. Esses princípios teóricos são demonstrados através de aplicações práticas em agricultura de precisão e monitoramento ambiental, evidenciando como o conhecimento dos fundamentos físicos é indispensável para o desenvolvimento de metodologias robustas de aquisição, processamento e análise de dados hiperespectrais.

2.1.1 O espectro eletromagnético

A energia eletromagnética constitui a base física do sensoriamento remoto e do imageamento hiperespectral, podendo ter origem em fontes naturais, como o Sol, nos próprios alvos ou em




Figura 2.1: Conceito da espectroscopia de imageamento desenvolvido pelo sensor AVIRIS (JPL/NASA). A figura ilustra como 224 bandas espectrais são obtidas simultaneamente, permitindo a análise de diferentes materiais (atmosfera, solos, água, vegetação) através de suas assinaturas espectrais características. Este princípio fundamenta o processamento hiperespectral em sistemas embarcados. Fonte: (BAPTISTA, 2019).

sistemas ativos, como radares. Essa energia propaga-se em forma de ondas, transportando informações sobre os materiais com os quais interage. A Figura 2.1 ilustra como o sensor AVIRIS implementa estes conceitos na prática, obtendo simultaneamente centenas de bandas espectrais. Compreender as propriedades fundamentais da radiação eletromagnética é essencial para entender os processos de aquisição e análise de dados hiperespectrais.

Definição e características das ondas eletromagnéticas

Ondas eletromagnéticas são perturbações que se propagam no espaço à velocidade da luz ($c = 3 \times 10^8$ m/s no vácuo). São caracterizadas principalmente pelo comprimento de onda (λ) e pela frequência (f), relacionados por:

$$c = \lambda \times f \quad (2.1)$$

A energia (E) transportada por uma onda eletromagnética é proporcional à sua frequência, conforme a equação de Planck:

$$E = h \times f = \frac{hc}{\lambda} \quad (2.2)$$

em que h é a constante de Planck ($6,626 \times 10^{-34}$ J.s).

No contexto do sensoriamento remoto, diferentes unidades são empregadas para descrever as faixas espectrais:

- 1 kHz = 1×10^3 Hz
- 1 MHz = 1×10^6 Hz

- 1 GHz = 1×10^9 Hz
- 1 THz = 1×10^{12} Hz
- 1 μm = 1×10^{-6} m
- 1 nm = 1×10^{-9} m

Neste trabalho adota-se a unidade de micrometro (μm) para o comprimento de onda.

Regiões espectrais: do ultravioleta ao infravermelho

O espectro eletromagnético é dividido em regiões conforme as propriedades físicas da radiação e sua interação com a matéria (LORENZZETTI, 2015; BAPTISTA, 2019). Para sensoriamento remoto, destacam-se as seguintes faixas:

Ultravioleta (UV): 0,03 a 0,4 μm . Pouco utilizada em sensoriamento remoto terrestre devido à absorção atmosférica, mas relevante em aplicações específicas.

Visível: 0,4 a 0,7 μm , correspondente à radiação percebida pelo olho humano. Subdivisões usuais:

- Azul: 0,4—0,5 μm
- Verde: 0,5—0,6 μm
- Vermelho: 0,6—0,7 μm

Infravermelho próximo (NIR): 0,7 a 1,3 μm . Importante para estudos de vegetação devido à alta reflectância da clorofila.

Infravermelho de ondas curtas (SWIR): 1,3 a 3,0 μm . Fundamental para identificação de minerais e análise de umidade.

Os limites exatos dessas faixas podem variar entre autores, mas há consenso sobre as principais subdivisões. A Tabela 2.1 apresenta as subfaixas do infravermelho mais utilizadas em sensoriamento remoto.

Tabela 2.1: Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).

Faixa	Subfaixa	Comprimento de onda
Raios-X	—	0,03—30 nm
Ultravioleta	—	30—400 nm
Visível	—	400—700 nm
Infravermelho	NIR/IVP	740—1 000 nm
	SWIR/IVOC	1 000—3 000 nm
	LWIR/IVTM	3 000—14 000 nm
Micro-ondas	—	1—30 mm
Ondas de rádio	—	>30 mm

Observa-se que, em algumas referências (LORENZZETTI, 2015; BAPTISTA, 2019), a faixa de micro-ondas pode ser definida como indo de 1 mm até 1 m. Essas variações não comprometem a aplicação prática dos conceitos, mas devem ser consideradas ao comparar diferentes trabalhos.

Comprimentos de onda relevantes para sensoriamento remoto (400–2500 nm)

Para aplicações de imageamento hiperespectral e sensoriamento remoto, a faixa espectral de 400 a 2500 nm (0,4 a 2,5 μm) representa a região de maior interesse prático. Essa faixa abrange as regiões do visível, infravermelho próximo (NIR) e infravermelho de ondas curtas (SWIR), onde ocorrem os principais fenômenos de interação radiação-matéria relevantes para identificação e caracterização de materiais terrestres.

Região VNIR (400–1000 nm): A faixa do visível e infravermelho próximo é fundamental para estudos de vegetação e classificação de cobertura terrestre. Nessa região, processos eletrônicos dominam a absorção da radiação, resultando em transições entre níveis de energia eletrônica nos átomos e moléculas. A clorofila, por exemplo, apresenta forte absorção nas regiões azul (430–450 nm) e vermelha (640–660 nm), enquanto exibe alta refletância no NIR (700–1000 nm).

Região SWIR (1000–2500 nm): No infravermelho de ondas curtas, as absorções são governadas por processos vibracionais moleculares. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo decorrem de efeitos do campo cristalino, enquanto outros processos eletrônicos produzem feições espectrais significativas nessa faixa. Essa região é particularmente rica em informações sobre minerais, conteúdo de água e compostos orgânicos.

As transições entre níveis de energia são responsáveis pelas faixas de absorção nos espectros. As absorções são governadas por processos vibracionais, sendo que átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico resulta da mudança de um estado de energia mais baixo para um mais alto, enquanto a emissão resulta da mudança de um estado de energia mais alto para um mais baixo, com liberação de energia no mesmo comprimento de onda.

A compreensão dos fundamentos físicos da interação radiação-matéria é essencial para o desenvolvimento de algoritmos de processamento hiperespectral eficazes e para a interpretação adequada dos dados espectrais em aplicações práticas de sensoriamento remoto.

2.1.2 Propriedades Ópticas dos Materiais

As propriedades ópticas dos materiais constituem a base física que permite a identificação e caracterização de diferentes substâncias através do sensoriamento remoto hiperespectral (BAPTISTA, 2019). Quando a radiação eletromagnética interage com um material, três processos fundamentais podem ocorrer: reflexão, absorção e transmissão. A compreensão destes processos e dos fatores que os influenciam é essencial para o desenvolvimento de técnicas eficazes de análise espectral e para a interpretação adequada dos dados hiperespectrais em aplicações práticas.

Reflectância Espectral: Definição e Fatores Influenciadores

A espectroscopia de reflectância é o estudo da radiação eletromagnética como função do comprimento de onda em que ela está sendo refletida, emitida ou espalhada por um gás, um líquido ou um sólido (BAPTISTA, 2019). A energia refletida pelas superfícies pode ser entendida como a porção da energia incidente, subtraindo-se as perdas que foram absorvidas ou transmitidas.

A reflectância espectral $\rho(\lambda)$, função do comprimento de onda (λ), pode ser definida matematicamente como a razão entre a radiância da superfície $[L(\lambda)]$ expressa em $\text{W m}^{-2} \text{sr}^{-1} \mu\text{m}^{-1}$ no comprimento de onda (λ) e a irradiância incidente $[E(\lambda)]$ em $\text{W m}^{-2} \mu\text{m}^{-1}$ no comprimento de onda (λ), conforme a equação:

$$\rho(\lambda) = \pi \frac{L(\lambda)}{E(\lambda)} \quad (2.3)$$

Esta definição estabelece a base quantitativa para a medição e comparação das propriedades espectrais de diferentes materiais. O Sol é a principal fonte natural de energia eletromagnética nas faixas do espectro do ultravioleta, do visível, do infravermelho próximo e do infravermelho de ondas curtas. Em comprimentos de onda maiores, na faixa do infravermelho termal, a eficiência do Sol como fonte de energia é bastante reduzida e a Terra passa a ter maior eficiência como fonte, porém nesta faixa não se analisa o espectro óptico de reflectância e sim o de emitância (BAPTISTA, 2019).

O processo de interação dos fótons com a matéria resulta em que parte deles é refletida pelos grãos da superfície do material, alguns passam pelos grãos e alguns são absorvidos. Os fótons são absorvidos pelos minerais por diversos processos que dependem de sua composição química. Essas absorções são governadas por dois processos gerais: processos eletrônicos e processos vibracionais (BAPTISTA, 2019).

2.1.3 Princípios de Sensoriamento Remoto Hiperespectral

Interação Radiação-Matéria no Contexto de Sensoriamento Remoto

O sensoriamento remoto hiperespectral fundamenta-se nos princípios físicos da interação entre radiação eletromagnética e matéria, constituindo uma extensão natural dos conceitos fundamentais abordados nas seções anteriores. A definição de sensoriamento remoto (SR) está sujeita a diferentes interpretações na literatura científica. De acordo com *Manual of Remote Sensing* (Ulaby, 1983), bem como em Elachi e Zyl (2006), SR é definido como a aquisição de informação sobre alguma propriedade de um objeto ou fenômeno sem contato físico com ele. A informação sobre um alvo seria obtida pela detecção e medida de mudanças que o objeto impõe sobre o meio circundante, seja ele eletromagnético, acústico ou potencial.

Schowengerdt (2007) considera SR como “a medida das propriedades de um objeto ou da superfície da Terra usando dados adquiridos de sensores e sistemas”, sendo um pouco mais restritivo. Segundo Slater (1980), SR é o conjunto de atividades utilizadas para a aquisição de informações relativas aos recursos naturais da Terra, ou ao seu meio ambiente, obtidas pela análise da energia eletromagnética refletida, emitida ou retroespalhada pelos alvos, coletada por meio de sensores remotos (BAPTISTA, 2019).

No contexto hiperespectral, a interação radiação-matéria adquire uma dimensão adicional de complexidade devido à alta resolução espectral dos sistemas de imageamento. Enquanto os processos eletrônicos e vibracionais descritos anteriormente permanecem fundamentalmente os mesmos, a capacidade de detectar e quantificar feições espectrais sutis é significativamente

ampliada. (CLARK, 1999 apud LORENZZETTI, 2015) considera que quatro parâmetros gerais definem a capacidade de um espectrorradiômetro (sensor espectral): a faixa espectral, a largura das bandas espectrais, a amostragem espectral e a razão sinal/ruído.

A faixa espectral de resolução utilizada em sensoriamento remoto abrange tipicamente os seguintes intervalos espectrais: de 0,3 a 1,0 μm , chamado de visível e infravermelho próximo; de 1,0 a 2,5 μm , infravermelho de ondas curtas. A faixa do infravermelho termal situa-se a partir de 3,0 μm até aproximadamente o pico máximo de emitância da Terra em torno de 10,0 μm (LORENZZETTI, 2015).

A largura da banda espectral é definida por (CLARK, 1999 apud LORENZZETTI, 2015) como a largura de um canal espectral individual no espectrorradiômetro. Quanto mais estreita for a largura da banda espectral, mais precisa será a determinação da feição de absorção do mineral. Alguns sistemas sensores possuem bandas largas e não espectralmente contíguas, não permitindo análise contínua do espectro, enquanto outros sistemas, como o AVIRIS, apresentam largura de bandas espectrais estreitas com espaçamento contínuo e permitem a identificação de feições características dos minerais.

Sensores Multiespectrais vs. Hiperespectrais: Diferenças Fundamentais

A distinção fundamental entre sensores multiespectrais e hiperespectrais reside na resolução espectral e na capacidade de discriminação de materiais. O perfil da largura também é importante. O ideal é que cada canal de um espectrorradiômetro rejeite toda radiação que não esteja dentro do alcance estreito de determinado comprimento de onda. Mas o que geralmente ocorre, em virtude de efeitos ópticos muito complexos, é que a radiação pode vazar, difundindo-se dentro do sistema óptico ou dentro do sistema de filtros bloqueadores.

Normalmente a largura do perfil é definida como a largura em comprimento de onda em 50% do nível de resposta da função do detector, chamado de largura a meia altura (FWHM) (CLARK, 1999 apud LORENZZETTI, 2015). A razão sinal/ruído (SNR) visa a obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes.

A SNR é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície. Algumas características espectrais são bastante fortes e uma razão SNR baixa é suficiente para identificá-las, enquanto outras feições são muito fracas e é necessária uma razão SNR mais alta (SWAYZE et al., 1997 apud LORENZZETTI, 2015).

Sistemas multiespectrais convencionais, como o sensor Landsat TM5, operam com bandas espectrais relativamente largas e espaçadas, tipicamente entre 6 a 12 bandas cobrindo o espectro eletromagnético de interesse. Sistemas como o Landsat e o *Moderate Resolution Imaging Spectroradiometer* (MODIS) não permitem a percepção de feições de absorção estreitas. Como exemplo, GREEN (1997 apud LORENZZETTI, 2015) demonstra como o sensor Landsat TM5 captaria as feições de absorção de três minerais: hematita, caulinita e dolomita.

A caulinita apresenta sua feição espectral mais característica em 2,2 μm . Já a dolomita, assim como a calcita, apresenta essa feição próxima para sua identificação, em 2,3 μm . As feições espectrais utilizadas para identificação da caulinita e dolomita (ou da calcita, pois essas são semelhantes) não podem ser discriminadas, pois aparecem integradas na banda 7 (2,08 a 2,35 μm) do sistema sensor TM5 do Landsat.

Aplicações Práticas: Agricultura, Monitoramento Ambiental e Defesa

As aplicações práticas do sensoriamento remoto hiperespectral em agricultura de precisão e monitoramento ambiental demonstram o potencial da tecnologia para resolver problemas

reais com alta precisão e especificidade, constituindo um dos principais motivos para o desenvolvimento de sistemas embarcados eficientes.

Agricultura de Precisão:

Na agricultura de precisão, os sistemas hiperespectrais permitem o monitoramento detalhado da saúde vegetal, detecção precoce de estresses bióticos e abióticos, e estimativa de parâmetros biofísicos das culturas. A região do infravermelho próximo (700–1000 nm) é particularmente importante devido à alta reflectância da clorofila, permitindo a avaliação do vigor vegetativo através de índices espectrais específicos.

As feições de absorção no SWIR (1400 nm e 1900 nm) são diagnósticas para o conteúdo de água nas plantas, facilitando o monitoramento de estresse hídrico em tempo real. Esta capacidade é fundamental para sistemas embarcados em UAVs que operam em agricultura de precisão, permitindo tomada de decisões imediatas sobre irrigação e manejo de culturas.

A capacidade de discriminar espécies vegetais e estágios fenológicos através de suas assinaturas espectrais únicas representa um avanço significativo sobre os métodos convencionais. Sistemas hiperespectrais embarcados podem detectar variações sutis na composição bioquímica foliar, incluindo concentrações de clorofila, carotenoides, antocianinas e compostos estruturais como celulose e lignina.

Monitoramento Ambiental:

No monitoramento ambiental, a tecnologia hiperespectral oferece capacidades sem precedentes para a caracterização de materiais superficiais, qualidade da água e detecção de poluentes. A identificação de minerais específicos através de suas feições espectrais características permite o mapeamento geológico detalhado e a detecção de alterações hidrotermais associadas a depósitos minerais.

Para qualidade da água, os sensores hiperespectrais podem detectar e quantificar constituintes opticamente ativos como clorofila-a, sedimentos em suspensão, matéria orgânica dissolvida e diversos poluentes. As absorções características desses materiais em comprimentos de onda específicos permitem sua identificação e quantificação com precisão superior aos métodos convencionais.

A detecção de mudanças ambientais, sejam elas naturais ou antropogênicas, beneficia-se da alta sensibilidade espectral dos sistemas hiperespectrais. Alterações sutis na composição química ou física dos materiais superficiais, que seriam imperceptíveis em imagens multiespectrais, tornam-se detectáveis através da análise das variações nas assinaturas espectrais.

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo.

Aplicações Militares e de Defesa:

Grande parte das aplicações de sensoriamento remoto para fins militares é focada na detecção e classificação de alvos e no mapeamento de terrenos e instalações. Em geral, os dados obtidos (coletados por satélites ou por dispositivos aerotransportados) por aviões usados para aplicações militares são considerados como *classificados* (não disponíveis para terceiros) e de alta resolução espacial. Como definido por Simonett et al. (1983) e Jensen (2009), considera-se como resolução espacial de um sistema sensor a menor separação espacial angular ou linear entre dois objetos que podem ser detectados.

Um detalhamento mais aprofundado sobre o conceito de resolução pode ser encontrado em Forshaw et al. (1983) e Townshend (1980). Como uma imagem digital é constituída por *pixels*, costuma-se associar o tamanho do *pixel* para a resolução da imagem. Entretanto, essa

definição dá a impressão de que somente podemos resolver objetos de tamanho maior, ou igual ao tamanho do *pixel*, o que nem sempre é verdade. Exemplos de definição mais rigorosa, considerando alto contraste com pixels vizinhos, são apresentados por Schowengerdt (2007).

Desafios Técnicos e Limitações:

Os sistemas hiperespectrais enfrentam desafios únicos relacionados ao processamento de grandes volumes de dados em tempo real. A razão sinal/ruído (SNR) visa à obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes. A SNR é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície.

O teorema de Nyquist determina que o máximo de informação é obtido quando a amostragem espectral é igual à metade do FWHM; às vezes, porém, uma razão de amostragem diferente pode ser necessária. Muitos dos espectrômetros modernos em uso (por exemplo, o AVIRIS) possuem um intervalo de amostragem de aproximadamente 10 nm e FWHM de 10 nm (CLARK, 1999 *apud* LORENZZETTI, 2015).

Algumas características espectrais são bastante fortes e uma razão sinal/ruído (SNR) baixa é suficiente para identificá-las, enquanto outras feições são muito fracas e é necessária uma razão SNR mais alta (SWAYZE et al., 1997 *apud* LORENZZETTI, 2015). Esta limitação é particularmente relevante para sistemas embarcados, onde restrições de peso, energia e processamento computacional impõem desafios adicionais à manutenção de alta qualidade espectral.

2.2 Técnicas de Processamento de Imagens Hiperespectrais

O processamento de imagens hiperespectrais envolve uma cadeia complexa de algoritmos especializados, desde o pré-processamento básico até técnicas avançadas de análise espectral. Esta seção apresenta as principais abordagens utilizadas na literatura, com foco nas técnicas que demonstram potencial para implementação em sistemas embarcados, consolidando metodologias validadas em diferentes contextos de aplicação.

2.2.1 Pré-processamento e Correção Radiométrica

O pré-processamento constitui uma etapa crucial para assegurar a qualidade dos dados hiperespectrais, especialmente em sistemas embarcados que operam sob condições de iluminação e movimento variáveis. Por meio do pré-processamento, os dados são corrigidos, permitindo comparações consistentes entre diferentes séries temporais e até mesmo dados provenientes de distintos sensores hiperespectrais. Em sistemas embarcados em UAVs para a detecção de plásticos em ambientes aquáticos, o pré-processamento demonstra ser fundamental para manter uma precisão superior a 90% em condições operacionais desafiadoras (Alboody *et al.*, 2023).

As técnicas de pré-processamento mais importantes incluem a calibração radiométrica, que corrige as variações de resposta do sensor utilizando ferramentas de software fornecidas pelos fabricantes. Essa etapa é essencial para georreferenciar e converter os cubos de dados DN (Digital Number) brutos em radiância, garantindo a reprodutibilidade e comparabilidade dos dados. Métodos avançados como o Empirical Line Method (ELM) podem melhorar a precisão radiométrica entre 5% e 55% (Silva; Pereira; Santos, 2024).

A correção atmosférica remove os efeitos de absorção e espalhamento atmosférico, sendo particularmente crítica em aplicações aéreas, com algoritmos como ATCOR e FLAASH amplamente validados para essa finalidade. A correção geométrica compensa as distorções geométricas causadas pelo movimento da plataforma e pela geometria de aquisição, frequentemente combinando dados de orientação externa coletados durante o voo com um modelo do sensor e um modelo de elevação. Técnicas robustas de correção geométrica são essenciais para aplicações embarcadas em UAVs, onde variações de altitude e orientação introduzem distorções significativas (Silva; Pereira; Santos, 2024).

A redução de ruído espectral, através da aplicação de filtros adaptativos e técnicas de suavização espectral, como os filtros Savitzky-Golay e transformadas wavelets, demonstra eficácia na preservação de características espectrais importantes, enquanto reduz componentes ruidosas. Por fim, a avaliação da qualidade, onde a relação sinal-ruído (SNR) constitui um critério fundamental para caracterizar a qualidade dos dados hiperespectrais, sendo essencial para análises quantitativas precisas. Sistemas comerciais como Specim FX10 e Resonon Pika L oferecem alta qualidade espectral, adequada para aplicações exigentes de classificação (Zhang *et al.*, 2024).

2.2.2 Redução Dimensional e Seleção de Bandas

A alta dimensionalidade dos dados hiperespectrais, com suas centenas de bandas espectrais, impõe desafios computacionais significativos, tornando as técnicas de redução dimensional essenciais para sistemas embarcados. O fenômeno de Hughes demonstra como o desempenho de classificadores pode degradar com o aumento da dimensionalidade quando o número de amostras de treinamento é limitado, tornando essas técnicas ainda mais críticas. Implementações otimizadas em FPGA de algoritmos como EMCR (Extreme Learning Machine with Correlation Removal) conseguem reduzir 80% dos dados, mantendo uma precisão superior a 99% (Martins *et al.*, 2019).

Dentro das técnicas lineares de redução dimensional, destaca-se a Principal Component Analysis (PCA), uma técnica clássica que projeta os dados em um subespaço de menor dimensionalidade, preservando a máxima variância. A PCA concentra a variância espectral e pode ser combinada com outros métodos, como compressão wavelet, conseguindo retenção de 99% da variância original com redução de 80% a 90% das bandas. Implementações GPU de PCA para compressão hiperespectral conseguem processamento em tempo real em plataformas embarcadas como Jetson TX2 (Díaz *et al.*, 2019).

O Maximum Noise Fraction (MNF) é outro método baseado em PCA que maximiza a relação sinal-ruído, sendo capaz de alcançar boa performance na redução dimensional de dados hiperespectrais, especialmente eficaz para dados com alta correlação espectral. Aplicações em sistemas PRISMA demonstram eficácia superior a 87% na redução de ruído espectral (Corbari *et al.*, 2023). A Independent Component Analysis (ICA) decompõe os dados em componentes estatisticamente independentes, sendo adequada para a separação de assinaturas espectrais sobrepostas e identificação de endmembers puros.

Em relação aos métodos de seleção de bandas, a seleção baseada em entropia, com algoritmos como EMCR (Entropy Multiple Correlation Ratio), consegue reduzir 70% a 80% do processamento, mantendo alta precisão de classificação, sendo computacionalmente eficientes para sistemas embarcados. Algoritmos genéticos oferecem otimização global para seleção de subconjuntos ótimos de bandas, com validação cruzada para evitar overfitting. Métodos híbridos combinam técnicas de projeção com seleção de bandas, oferecendo um equilíbrio entre redução dimensional e preservação de informações discriminantes.

2.2.3 Algoritmos de Classificação Espectral

A classificação espectral constitui uma das aplicações mais importantes do processamento hiperespectral, sendo fundamental para a identificação e mapeamento de materiais. Frameworks de classificação baseados em características espectral-espaciais superam métodos que utilizam apenas informações espectrais. Sistemas embarcados para detecção de plásticos marinhos demonstram precisão próxima a 90% utilizando abordagens híbridas (Alboody *et al.*, 2023), enquanto implementações FPGA de SVM alcançam 99,7% de precisão com latência de 0,1 ms por pixel (Martins *et al.*, 2019).

Entre os métodos clássicos de classificação, destacam-se as Support Vector Machines (SVM), classificadores robustos que demonstram excelente desempenho em dados hiperespectrais, com implementações otimizadas conseguindo precisões superiores a 95% em datasets de referência. A eficácia do SVM está relacionada à sua capacidade de lidar com alta dimensionalidade e pequenos conjuntos de treinamento. Implementações em FPGA conseguem classificação em tempo real com latência de 0,1 ms por pixel e precisão de 99,7% em datasets AVIRIS (Martins *et al.*, 2019).

Random Forest, métodos ensemble que combinam múltiplas árvores de decisão, oferecem boa interpretabilidade e robustez a outliers, com tempos de treinamento significativamente menores que SVM. O Spectral Angle Mapper (SAM) realiza a classificação baseada em similaridade angular entre espectros, sendo computacionalmente eficiente para implementações embarcadas e menos sensível a variações de iluminação.

2.3 Arquiteturas Heterogêneas de Processamento

As arquiteturas heterogêneas combinam diferentes tipos de processadores para otimizar simultaneamente desempenho, consumo energético e latência. Essa abordagem é particularmente relevante para o processamento hiperespectral embarcado, onde diferentes estágios do pipeline computacional se beneficiam de tipos distintos de processadores.

2.3.1 Fundamentos de Computação Heterogênea

A computação heterogênea fundamenta-se no princípio de que diferentes tipos de processadores possuem eficiências variáveis para diferentes tipos de cargas computacionais. A integração visa aproveitar os pontos fortes únicos de cada arquitetura, melhorando a eficiência computacional e o desempenho em vários domínios. Vaithianathan (2025) e Sahovic e Quinten (2025) destacam a especialização de processadores, onde cada tipo (CPU, GPU, FPGA, DSP) apresenta vantagens específicas para determinados tipos de operações. FPGAs, por exemplo, destacam-se na aquisição rápida de dados, CPUs na coordenação de sistema, e GPUs em computação massivamente paralela.

O particionamento de algoritmos, que consiste na divisão do pipeline de processamento em estágios adequados para cada tipo de processador, é crucial. A Figura 2.2 ilustra a complexidade dos dados hiperespectrais que motivam o uso de arquiteturas heterogêneas. A alocação estratégica de tarefas de acordo com os pontos fortes de cada componente de hardware atende às demandas computacionais e de tempo real essenciais para diversas aplicações (Sahovic; Quinten, 2025). A otimização multi-objetivo busca o equilíbrio simultâneo entre desempenho, consumo energético, latência e precisão. A alocação dinâmica de tarefas para a unidade de processamento mais adequada otimiza a utilização de recursos e minimiza a latência (Vaithianathan, 2025).

AVIRIS – 950816L02 – 03 – São João D’Aliança, GO
Método Green




Figura 2.2: Exemplo de imagem hiperespectral AVIRIS capturada sobre São João D’Aliança, GO, mostrando dados de vapor d’água em diferentes bandas espectrais. A imagem ilustra a complexidade dos dados hiperespectrais que devem ser processados por arquiteturas heterogêneas em sistemas embarcados para aplicações de sensoriamento remoto em tempo real. Fonte: (BAPTISTA, 2019).

Finalmente, o codesign HW/SW, uma metodologia integrada de desenvolvimento que considera hardware e software simultaneamente, enfatiza o desenvolvimento simultâneo de componentes de hardware e software para alcançar desempenho e eficiência ideais (Vaithianathan, 2025).

Tendências Futuras em Computação Heterogênea

Vaithianathan (2025) identifica direções emergentes que moldarão o futuro da computação heterogênea, com implicações diretas para o processamento hiperespectral embarcado. A integração de aceleradores específicos para IA, como Neural Processing Units (NPUs) e Application-Specific Integrated Circuits (ASICs), oferece eficiência energética cinco a dez vezes superior para inferência de IA comparado a GPUs genéricas. Google TPUv4 demonstra 420 TFLOPS em operações de machine learning, enquanto NPUs móveis alcançam 15-45 TOPS com consumo inferior a 5 W.

A heterogeneidade hierárquica evolui para sistemas que utilizam múltiplas arquiteturas não apenas dentro de um único nó, mas também através de sistemas distribuídos. Essa abordagem permite a combinação de diferentes processadores otimizados para tarefas específicas em múltiplas camadas do sistema. Arquiteturas de memória unificada, como AMD Heterogeneous System Architecture (HSA) e NVIDIA Grace Hopper (900 GB/s de largura de banda CPU-GPU), reduzem 40% a 60% da latência de transferência de dados, simplificando significativamente o modelo de programação.

Frameworks de programação unificados desenvolvem abstrações de alto nível que simplificam a programação cross-platform, permitindo que desenvolvedores escrevam código uma vez e executem em múltiplas configurações de hardware sem modificações extensivas. A alocação autônoma de recursos, com sistemas orientados por IA que analisam métricas de performance em tempo real e ajustam a alocação de recursos dinamicamente, otimiza a utilização e minimiza a latência sem intervenção manual.

2.3.2 Arquiteturas CPU+GPU Integradas

A combinação de CPU e GPU em sistemas embarcados oferece flexibilidade e desempenho para o processamento hiperespectral. Arquiteturas de memória unificada facilitam o compartilhamento contínuo de dados entre CPUs e GPUs, reduzindo overhead e melhorando a velocidade computacional (Vaithianathan, 2025). Sistemas como NVIDIA Jetson integram CPUs ARM com GPUs CUDA em soluções single-package. A tendência em direção a designs System on Chip (SoC) permite a integração de múltiplos tipos de processadores dentro de um único chip, aprimorando ainda mais o desempenho em ambientes compactos (Vaithianathan, 2025).

A divisão de tarefas aloca a CPU para controle, pré-processamento sequencial e classificação final, enquanto a GPU é utilizada para operações matriciais, filtragem e redes neurais. O controlador DMA atua como ponte entre CPU e GPU, facilitando a transferência contínua de dados entre a memória host e a memória global da GPU (Vaithianathan, 2025). A comunicação eficiente é garantida por memória compartilhada e interfaces de alta velocidade para minimizar o overhead de transferência de dados. Tecnologias como AMD's Heterogeneous System Architecture (HSA) exemplificam essa tendência ao permitir o acesso de memória compartilhada através de várias unidades de processamento (Vaithianathan, 2025).

Estudos demonstram throughput superior a 330 fps em compressão hiperespectral com consumo inferior a 20 W. Embora GPUs forneçam forte capacidade paralela, encontram ineficiências na transferência de dados (Sahovic; Quinten, 2025).

2.3.3 Sistemas CPU+FPGA

A combinação CPU+FPGA oferece máxima flexibilidade para otimização de algoritmos específicos. Implementações bem-sucedidas de aceleradores de hardware para classificação de imagens hiperespectrais em tempo real utilizando essa abordagem já foram demonstradas (Martins *et al.*, 2019). A FPGA implementa algoritmos críticos como seleção de bandas EMCR e classificação SVM otimizada. A metodologia EMCR (Entropy and Mean Correlation Ratio) aumentou consideravelmente o poder de predição, alcançando níveis de precisão superiores a 99% (Martins *et al.*, 2019).

Um pipeline de baixa latência garante processamento contínuo com latência determinística, adequado para aplicações de tempo real. FPGAs garantem baixo nível de latência comparadas a GPUs e CPUs, pois trabalham em bare metal sem sistema operacional. Melhorias de até 43,5 vezes no consumo energético são alcançadas através de codesign otimizado. A natureza reconfigurável dos FPGAs permite a maximização da otimização adaptada a aplicações específicas. Ao contrário de CPUs e GPUs, que são arquiteturas fixas programáveis por software, FPGAs são reconfiguráveis com engines computacionais definidos pelo usuário.

Capítulo 3

Metodologia

Este capítulo apresenta a metodologia comparativa desenvolvida para investigação de técnicas de processamento hiperespectral direcionadas à agricultura de precisão, utilizando arquiteturas embarcadas FPGA e GPU para análise de culturas através de índices de vegetação especializados. A abordagem metodológica estrutura-se em sete seções principais: considerações iniciais sobre o escopo da pesquisa, delimitação das plataformas tecnológicas específicas, caracterização dos datasets agrícolas selecionados, especificação das técnicas de processamento aplicadas, estabelecimento do protocolo comparativo de avaliação, metodologia de síntese da arquitetura híbrida proposta, e cronograma detalhado de execução. A metodologia fundamenta-se em abordagem teórico-experimental que combina modelagem matemática, simulação computacional e análise comparativa sistemática, proporcionando framework rigoroso para identificação de soluções otimizadas em processamento hiperespectral embarcado.

3.1 Considerações Iniciais

Esta pesquisa adota abordagem metodológica comparativa focada exclusivamente em processamento hiperespectral para agricultura de precisão, utilizando arquiteturas embarcadas FPGA e GPU para análise de culturas de milho e soja através de índices de vegetação especializados. A delimitação temática fundamenta-se na análise do levantamento bibliográfico, que identificou lacunas significativas na literatura sobre sistemas integrados para monitoramento agrícola embarcado.

A justificativa para esta delimitação baseia-se em três aspectos fundamentais. Primeiro, a crescente demanda por sistemas autônomos de monitoramento agrícola que combinem alta precisão analítica com eficiência energética adequada para operação em UAVs. Segundo, a ausência de estudos comparativos sistemáticos entre arquiteturas FPGA e GPU especificamente direcionados para processamento hiperespectral agrícola, considerando que trabalhos existentes na literatura focam em compressão geral ou abordam aspectos energéticos sem especificidade agrícola. Terceiro, a necessidade de estabelecer critérios objetivos para seleção de plataformas computacionais considerando os requisitos específicos da agricultura de precisão: processamento em tempo real, restrições energéticas rigorosas, e precisão adequada para tomada de decisões agronômicas.

A metodologia prioriza investigação teórico-experimental estruturada que combina modelagem matemática rigorosa com validação através de simulação computacional. Esta abordagem permite análise sistemática de trade-offs entre precisão de classificação, eficiência

energética e throughput computacional, estabelecendo fundamentos científicos para proposição de arquitetura híbrida otimizada.

3.2 Delimitação do Escopo Tecnológico

3.2.1 Plataformas de Hardware Específicas

A plataforma FPGA selecionada é o **Xilinx Zynq-7020** (XC7Z020-CLG484), que integra processador dual-core ARM Cortex-A9 operando a 866MHz com sistema de lógica programável contendo 85.000 células lógicas, 220 blocos DSP48E1, 560KB de Block RAM e 256KB de RAM distribuída. A escolha do Zynq-7020 baseia-se em sua ampla adoção na literatura para aplicações similares e na disponibilidade de ferramentas de desenvolvimento maduras que facilitam a implementação e otimização de algoritmos hiperspectrais.

A plataforma GPU selecionada é o **NVIDIA Jetson Xavier NX**, equipado com GPU de 384 cores NVIDIA Volta operando a 1,1GHz, processador de 6 cores NVIDIA Carmel ARM v8.2 a 1,4GHz, 8GB de memória LPDDR4x com largura de banda de 51,2GB/s, e TDP configurável entre 10W, 15W e 20W. A flexibilidade de consumo energético do Xavier NX é particularmente relevante para aplicações em UAV, permitindo ajuste dinâmico entre performance computacional e autonomia de voo conforme as demandas operacionais. O modo 10W proporciona maior autonomia para missões extensas de monitoramento, enquanto os modos 15W e 20W oferecem maior throughput para processamento intensivo durante janelas críticas de análise.

3.2.2 Ferramentas de Simulação e Desenvolvimento

O ambiente de desenvolvimento FPGA utiliza **GHDL** para simulação comportamental de código VHDL, permitindo verificação funcional detalhada dos algoritmos implementados. A síntese, implementação e análise de timing são realizadas através do **Vivado Design Suite**, que proporciona estimativas precisas de utilização de recursos, consumo energético e performance temporal. A co-simulação entre código C/C++ e implementações VHDL é facilitada pelo **Vitis HLS**, permitindo validação cruzada entre modelos algorítmicos de alto nível e implementações de hardware otimizadas.

O desenvolvimento GPU baseia-se no **CUDA Toolkit** para programação paralela nativa NVIDIA, complementado por **OpenCL** para garantir portabilidade e permitir comparações cross-platform. A biblioteca **cuDNN** acelera operações matriciais intensivas comuns em processamento hiperspectral. O profiling detalhado de performance é realizado através do **NSight Compute** para análise de kernels CUDA individuais e **NSight Systems** para análise de performance do sistema completo, incluindo overhead de comunicação CPU-GPU.

3.3 Dataset Selecionado

O dataset **Salinas Valley** constitui a base experimental principal desta pesquisa, apresentando dimensões de 512×217×204 bandas espectrais cobrindo a faixa de 400–2500nm com resolução espacial de 3,7 metros por pixel. Este dataset é particularmente adequado para agricultura de precisão por conter classes específicas representativas de diferentes estágios fenológicos de culturas: Corn senesced green weeds (classe 2), Lettuce romaine 4wk (classe 3), Lettuce romaine 5wk (classe 4), Lettuce romaine 6wk (classe 5), e Lettuce romaine 7wk

(classe 6). A resolução espacial de 3,7 metros por pixel é compatível com requisitos típicos de monitoramento agrícola por UAV, permitindo identificação de variabilidade intra-talhão relevante para tomadas de decisão agrônômicas.




Figura 3.1: Exemplo de imagem do dataset Salinas Valley mostrando a distribuição espacial das classes de culturas agrícolas em escala de cinza. A imagem apresenta dimensões 512×217 pixels com diferentes tonalidades representando as 16 classes de cobertura do solo, incluindo culturas de alface em diferentes estágios fenológicos e áreas de solo exposto. Fonte: Grupo de Visão Computacional e Processamento de Imagens - Universidade do País Vasco (Grupo de Visión Computacional y Procesamiento de Imágenes, 2013).

A aplicação principal foca no monitoramento de desenvolvimento fenológico de culturas, essencial para otimização de práticas de manejo como irrigação, fertilização e aplicação de defensivos. A Figura 3.1 ilustra a complexidade espacial e espectral dos dados que serão processados pelos algoritmos implementados nas arquiteturas FPGA e GPU.

3.3.1 Cenários de Teste Específicos

Cenário A: Detecção de Estresse Hídrico

Este cenário implementa metodologia específica para detecção de estresse hídrico baseada na análise quantitativa das feições de absorção da água no espectro eletromagnético. A fundamentação física baseia-se no fato de que moléculas de água apresentam bandas de absorção características em 1450 nm (primeira harmônica da vibração de estiramento O-H) e 1940 nm (combinação das vibrações de estiramento e flexão), cujas intensidades correlacionam-se diretamente com o conteúdo hídrico foliar.

Protocolo de Detecção: O algoritmo calcula o Índice de Estresse Hídrico (WBI - Water Band Index) através da razão:

$$WBI = \frac{\rho_{970}}{\rho_{900}} \quad (3.1)$$

onde ρ_{970} e ρ_{900} são as reflectâncias nas bandas próximas a 970 nm e 900 nm, respectivamente. Valores de WBI $< 0,95$ indicam estresse hídrico moderado, enquanto WBI $< 0,90$ caracteriza estresse severo. A validação utiliza comparação estatística entre pixels da classe *Corn senesced green weeds* (estresse conhecido) versus classes de vegetação saudável.

Cenário B: Cálculo de Índices de Vegetação

A implementação abrange quatro índices de vegetação fundamentais, cada um otimizado para aspectos específicos do monitoramento agrícola. A seleção desses índices baseia-se em sua complementaridade para caracterização completa do status vegetativo, considerando limitações e vantagens específicas de cada metodologia em diferentes condições ambientais e fenológicas.

NDVI (Normalized Difference Vegetation Index): calculado através da equação fundamental:

$$\text{NDVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + \rho_{\text{Red}}} \quad (3.2)$$

onde ρ_{NIR} representa a reflectância na banda do infravermelho próximo (B51, 800 nm) e ρ_{Red} a reflectância na banda vermelha (B29, 680 nm). Este índice normalizado varia no intervalo $[-1, +1]$, sendo que valores próximos a $+1$ indicam vegetação densa e saudável, enquanto valores próximos a zero ou negativos caracterizam solo nu, água ou vegetação estressada.

NDRE (Normalized Difference Red Edge): implementado através da equação:

$$\text{NDRE} = \frac{\rho_{\text{NIR}} - \rho_{\text{RedEdge}}}{\rho_{\text{NIR}} + \rho_{\text{RedEdge}}} \quad (3.3)$$

onde ρ_{RedEdge} corresponde à reflectância na banda red-edge (B40, 740 nm) e ρ_{NIR} à banda do infravermelho próximo (B51, 800 nm). O NDRE explora a região espectral de transição entre o vermelho e o infravermelho próximo, caracterizada por rápida variação da reflectância foliar, oferecendo maior sensibilidade para detecção precoce de estresse nutricional e hídrico comparado ao NDVI tradicional.

EVI (Enhanced Vegetation Index): calculado através da equação:

$$\text{EVI} = G \times \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + C_1 \times \rho_{\text{Red}} - C_2 \times \rho_{\text{Blue}} + L} \quad (3.4)$$

onde $G = 2,5$ é o fator de ganho, $C_1 = 6,0$ e $C_2 = 7,5$ são coeficientes de correção atmosférica para aerossóis, $L = 1,0$ é o fator de ajuste do solo, ρ_{Blue} representa a reflectância na banda azul (B14, 480 nm), ρ_{Red} na banda vermelha (B29, 680 nm) e ρ_{NIR} no infravermelho próximo (B51, 800 nm). O EVI minimiza influências atmosféricas e de background do solo, proporcionando maior sensibilidade em regiões de alta biomassa onde o NDVI tende à saturação.

SAVI (Soil Adjusted Vegetation Index): implementado através da equação:

$$\text{SAVI} = \frac{\rho_{\text{NIR}} - \rho_{\text{Red}}}{\rho_{\text{NIR}} + \rho_{\text{Red}} + L} \times (1 + L) \quad (3.5)$$

onde L é o fator de correção do solo, com valores típicos:

- $L = 0,5$ (cobertura vegetal moderada)
- $L = 0,25$ (alta densidade vegetal)
- $L = 1,0$ (baixa densidade vegetal)

As variáveis ρ_{NIR} e ρ_{Red} correspondem às reflectâncias nas bandas B51 (800 nm) e B29 (680 nm), respectivamente. O SAVI minimiza a influência da reflectância do solo subjacente, sendo particularmente eficaz em estágios iniciais de crescimento de culturas ou em áreas com cobertura vegetal esparsa.

3.4 Técnicas de Processamento Específicas

3.4.1 Pipeline de Pré-processamento

Correção Radiométrica

A correção radiométrica implementa duas técnicas fundamentais que garantem a qualidade e comparabilidade dos dados hiperespectrais.

A **dark object subtraction** baseia-se no princípio de que objetos escuros (sombras, água profunda) deveriam apresentar reflectância próxima a zero, mas frequentemente exibem valores positivos devido ao espalhamento atmosférico. O algoritmo implementa a correção:

$$\rho_{\text{corr}}(\lambda, i, j) = \rho_{\text{obs}}(\lambda, i, j) - \min_{i,j}[\rho_{\text{obs}}(\lambda, i, j)] \quad (3.6)$$

onde $\rho_{\text{corr}}(\lambda, i, j)$ é a reflectância corrigida no comprimento de onda λ para o pixel de coordenadas (i, j) , $\rho_{\text{obs}}(\lambda, i, j)$ é a reflectância observada, e $\min_{i,j}[\rho_{\text{obs}}(\lambda, i, j)]$ representa o valor mínimo observado em toda a imagem para o comprimento de onda λ .

A **normalização por reflectância** converte valores digitais (DN) em reflectância através da relação:

$$\rho(\lambda) = \frac{\text{DN}(\lambda) - \text{DN}_{\text{dark}}(\lambda)}{\text{DN}_{\text{white}}(\lambda) - \text{DN}_{\text{dark}}(\lambda)} \times \rho_{\text{ref}}(\lambda) \quad (3.7)$$

onde $\text{DN}_{\text{dark}}(\lambda)$ e $\text{DN}_{\text{white}}(\lambda)$ são os valores digitais de referência escura e clara, respectivamente, e $\rho_{\text{ref}}(\lambda)$ é a reflectância conhecida do material de referência.

Filtragem Espacial

O processamento espacial utiliza dois filtros complementares. O **filtro Gaussiano passa-baixa** com kernel 3×3 e $\sigma = 0,8$ realiza suavização controlada para redução de ruído de alta frequência preservando características espectrais essenciais. O **filtro mediano** com janela 3×3 remove ruído impulsivo (pixels isolados com valores anômalos) comum em sensores hiperespectrais, mantendo bordas e transições espectrais abruptas.

Seleção de Bandas Específica

A seleção de bandas implementa estratégia sistemática de remoção de bandas com baixa qualidade espectral. As **bandas atmosféricas** removidas incluem vapor d'água (bandas 105–115, correspondentes a 1340–1460 nm) e (bandas 150–170, 1800–1970 nm), além de bandas com forte absorção atmosférica (bandas 1–9, < 450 nm) e (bandas 200–204, > 2450 nm). A **seleção para NDVI** prioriza manutenção de bandas red (680 nm) e NIR (800 nm) com alta relação sinal-ruído, essenciais para cálculo preciso de índices de vegetação. Esta filtragem resulta na redução de 204 para 150 bandas espectrais úteis, otimizando o processamento subsequente.

3.4.2 Técnicas de Processamento Principal

Redução Dimensional

A **Análise de Componentes Principais (PCA)** implementa transformação linear ortogonal que projeta dados hiperespectrais de alta dimensionalidade em subespaço de menor dimensionalidade, preservando máxima variância.

Formulação Matemática: Seja $\mathbf{X} \in \mathbb{R}^{n \times d}$ a matriz de dados hiperespectrais, onde n é o número de pixels ($n = 111.104$ para Salinas Valley) e d o número de bandas espectrais ($d = 150$ após filtragem). A PCA determina a matriz de transformação $\mathbf{W} \in \mathbb{R}^{d \times k}$ que maximiza a variância dos dados projetados:

$$\mathbf{Y} = \mathbf{X}\mathbf{W} \quad (3.8)$$

onde $\mathbf{Y} \in \mathbb{R}^{n \times k}$ são os dados transformados e $k \ll d$ é a dimensionalidade reduzida.

Algoritmo de Decomposição: A matriz de transformação é obtida através da decomposição em autovalores da matriz de covariância:

$$\mathbf{C} = \frac{1}{n-1} \mathbf{X}^T \mathbf{X} \quad (3.9)$$

$$\mathbf{C}\mathbf{w}_i = \lambda_i \mathbf{w}_i, \quad i = 1, \dots, d \quad (3.10)$$

onde $\{\lambda_i\}$ são os autovalores ordenados decrescentemente e $\{\mathbf{w}_i\}$ os autovetores correspondentes. O número de componentes k é determinado pelo critério de variância preservada:

$$k = \arg \min_j \left\{ \frac{\sum_{i=1}^j \lambda_i}{\sum_{i=1}^d \lambda_i} \geq 0,99 \right\} \quad (3.11)$$

resultando tipicamente em $k \in [15, 20]$ para o dataset Salinas Valley.

A **Kernel PCA (KPCA)** estende a PCA para captura de estruturas não-lineares através do mapeamento implícito $\phi : \mathbb{R}^d \rightarrow \mathcal{H}$ para um espaço de Hilbert de dimensionalidade superior. O kernel RBF é definido por:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2} \right) \quad (3.12)$$

com $\sigma = 2,0$ otimizado empiricamente para o dataset Salinas Valley. A KPCA resolve o problema de autovalores na matriz de kernel centrada:

$$\tilde{\mathbf{K}}\boldsymbol{\alpha} = n\lambda\boldsymbol{\alpha} \quad (3.13)$$

onde $\tilde{\mathbf{K}} = \mathbf{K} - \mathbf{1}_n \mathbf{K} - \mathbf{K} \mathbf{1}_n + \mathbf{1}_n \mathbf{K} \mathbf{1}_n$ é a matriz de kernel centrada e $\mathbf{1}_n$ é a matriz de uns $n \times n$ normalizada por n .

Seleção de Características

A técnica **EMCR** (Entropy and Mean Correlation Ratio) implementa uma abordagem híbrida que maximiza o conteúdo informacional enquanto minimiza a redundância espectral. O algoritmo opera em três etapas principais:

Etapa 1 - Cálculo da Entropia Espectral: A entropia de cada banda λ_k é calculada considerando a distribuição de probabilidade dos valores de reflectância:

$$H(\lambda_k) = - \sum_{i=1}^N p_i(\lambda_k) \log_2 p_i(\lambda_k) \quad (3.14)$$

onde $p_i(\lambda_k) = \frac{n_i}{N_{\text{total}}}$ representa a probabilidade do nível de intensidade i na banda λ_k , com n_i sendo o número de pixels com intensidade i e N_{total} o número total de pixels.

Etapa 2 - Análise de Correlação Inter-bandas: O coeficiente de correlação entre bandas λ_i e λ_j é calculado por:

$$r(\lambda_i, \lambda_j) = \frac{\text{cov}(\lambda_i, \lambda_j)}{\sigma_{\lambda_i} \times \sigma_{\lambda_j}} = \frac{E[(\lambda_i - \mu_i)(\lambda_j - \mu_j)]}{\sigma_{\lambda_i} \times \sigma_{\lambda_j}} \quad (3.15)$$

onde μ_i e σ_{λ_i} são a média e o desvio padrão da banda λ_i .

Etapa 3 - Cálculo do Índice EMCR: O índice EMCR para cada banda λ_k é definido como:

$$\text{EMCR}(\lambda_k) = \frac{H(\lambda_k)}{\frac{1}{N-1} \sum_{j \neq k}^N |r(\lambda_k, \lambda_j)|} \quad (3.16)$$

onde o numerador representa a informatividade individual da banda e o denominador a correlação média com todas as outras bandas. Bandas com alto EMCR possuem alta entropia (informação) e baixa correlação (redundância).

A **Análise de Informação Mútua** quantifica a dependência estatística entre bandas espectrais e classes agronômicas, capturando relações não-lineares que métodos baseados em correlação linear podem não detectar.

A informação mútua entre uma banda espectral X e o conjunto de classes Y é definida matematicamente como:

$$\text{MI}(X, Y) = \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right) \quad (3.17)$$

onde $p(x, y)$ é a densidade de probabilidade conjunta, $p(x)$ e $p(y)$ são as densidades marginais. Quando X e Y são independentes, $\text{MI}(X, Y) = 0$; quando são completamente dependentes, $\text{MI}(X, Y)$ atinge seu valor máximo $\text{MI}_{\text{max}} = \min[H(X), H(Y)]$.

Implementação Computacional: A estimação das densidades de probabilidade utiliza discretização adaptativa com 256 bins por banda espectral. Para mitigar problemas de esparsidade em altas dimensões, aplica-se suavização com janela deslizante Gaussiana:

$$\hat{p}(x) = \frac{1}{Nh} \sum_{i=1}^N K \left(\frac{x - x_i}{h} \right) \quad (3.18)$$

onde K é o kernel Gaussiano, h é a largura de banda ótima calculada pela regra de Scott:

$$h = 1,06 \times \sigma \times N^{-1/5} \quad (3.19)$$

e N é o número de amostras.

Classificação

O classificador **SVM com kernel RBF** implementa uma abordagem de margens máximas adaptada para classificação de dados hiperespectrais de alta dimensionalidade. O problema de otimização é formulado como:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad (3.20)$$

sujeito às restrições:

$$y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \quad i = 1, \dots, n \quad (3.21)$$

$$\xi_i \geq 0, \quad i = 1, \dots, n \quad (3.22)$$

onde $\mathbf{w} \in \mathbb{R}^d$ é o vetor de pesos, $b \in \mathbb{R}$ o termo de bias, $\xi_i \geq 0$ as variáveis de folga, $C > 0$ o parâmetro de regularização, e $\phi(\mathbf{x}_i)$ o mapeamento no espaço de características definido pelo kernel RBF:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (3.23)$$

Otimização de Hiperparâmetros: A busca em grade explora o espaço de parâmetros $C \in \{0,1, 1, 10, 100\}$ e $\gamma \in \{0,001, 0,01, 0,1, 1, 10\}$, totalizando $5 \times 5 = 25$ combinações avaliadas por validação cruzada k -fold com $k = 5$. A métrica de seleção é a acurácia média ponderada pelas classes para compensar o desbalanceamento do dataset Salinas Valley.

O classificador **k-NN** testa valores $k \in \{5, 7, 9\}$ com distância Euclidiana no espaço de características reduzido. A validação emprega leave-one-out cross-validation para estimativa robusta de performance, particularmente importante dado o desbalanceamento entre classes no dataset Salinas Valley.

3.5 Protocolo de Comparação e Avaliação

3.5.1 Métricas de Performance Computacional

Throughput e Latência

O **throughput** quantifica a capacidade de processamento sustentado através da métrica:

$$\text{Throughput} = \frac{N_{\text{pixels}} \times N_{\text{bandas}}}{T_{\text{total}}} \quad [\text{pixels/s}] \quad (3.24)$$

onde N_{pixels} é o número total de pixels processados ($512 \times 217 = 111.104$ para Salinas Valley), N_{bandas} o número de bandas espectrais utilizadas ($N_{\text{bandas}} = 150$ após filtragem), e T_{total} o tempo total de processamento incluindo todas as etapas do pipeline.

A **latência por estágio** é medida individualmente para cada componente do pipeline:

$$T_{\text{total}} = T_{\text{pre-proc}} + T_{\text{red-dim}} + T_{\text{classif}} + T_{\text{indices}} \quad (3.25)$$

$$T_{\text{pre-proc}} = T_{\text{radiom}} + T_{\text{espacial}} + T_{\text{bandas}} \quad (3.26)$$

onde cada componente é cronometrado com resolução de microssegundos para identificação precisa de gargalos computacionais.

Utilização de Recursos de Hardware

Para FPGA (Zynq-7020): A utilização de recursos é quantificada como:

$$U_{\text{recurso}} = \frac{R_{\text{utilizado}}}{R_{\text{disponível}}} \times 100\% \quad (3.27)$$

com os recursos monitorados:

- DSP48E1: $R_{\text{disp}} = 220$ unidades (operações aritméticas)

- BRAM: $R_{\text{disp}} = 560 \text{ KB}$ (armazenamento de dados)
- LUTs: $R_{\text{disp}} = 53.200$ unidades (lógica combinacional)
- Flip-flops: $R_{\text{disp}} = 106.400$ unidades (elementos de memória)

Para GPU (Xavier NX): As métricas incluem:

$$\text{Occupancy} = \frac{\text{Warps ativos}}{\text{Warps máximos por SM}} \times 100\% \quad (3.28)$$

$$\text{Bandwidth Util.} = \frac{\text{Bytes transferidos/s}}{\text{Bandwidth teórico}} \times 100\% \quad (3.29)$$

com bandwidth teórico de 51,2 GB/s para memória LPDDR4x.

3.5.2 Métricas de Eficiência Energética

Instrumentação Energética

O **consumo instantâneo** é monitorado com alta precisão temporal:

Para FPGA: Utiliza-se o sensor INA219 com resolução de 12 bits para medição de corrente ($\pm 3,2 \text{ A}$) e tensão (0–26 V), proporcionando precisão de $\pm 0,5\%$ na faixa de operação. A potência instantânea é calculada como:

$$P(t) = V(t) \times I(t) \quad [\text{W}] \quad (3.30)$$

com amostragem a 1 kHz para captura de transições rápidas de consumo.

Para GPU: O software `tegrastats` fornece leituras de potência por domínio (GPU, CPU, DRAM, SoC) com resolução temporal de 100 ms.

Métricas Energéticas Derivadas

A **energia por pixel** normaliza o consumo pela carga computacional:

$$E_{\text{pixel}} = \frac{\int_0^T P(t) dt}{N_{\text{pixels}}} \quad [\text{J/pixel}] \quad (3.31)$$

A **eficiência computacional** relaciona throughput com consumo:

$$\eta_{\text{comp}} = \frac{\text{GOPS}}{P_{\text{médio}}} \quad [\text{GOPS/W}] \quad (3.32)$$

onde GOPS (Giga Operations Per Second) é estimado considerando as operações de ponto flutuante por pixel:

$$\text{GOPS} = \frac{\text{Ops/pixel} \times \text{Pixels/s}}{10^9} \quad (3.33)$$

Para o dataset Salinas Valley, estima-se aproximadamente 2.500 operações de ponto flutuante por pixel (incluindo PCA, classificação SVM e cálculo de índices).

3.5.3 Métricas de Qualidade para Agricultura

Métricas de Classificação

A **Overall Accuracy** (OA) quantifica a performance global:

$$OA = \frac{\sum_{i=1}^C n_{ii}}{N} \times 100\% \quad (3.34)$$

onde n_{ii} são os elementos da diagonal da matriz de confusão (classificações corretas), C o número de classes, e N o total de amostras.

O **Coeficiente Kappa** (κ) corrige a concordância pelo acaso:

$$\kappa = \frac{P_o - P_e}{1 - P_e} \quad (3.35)$$

onde $P_o = \frac{OA}{100}$ é a concordância observada e

$$P_e = \sum_{i=1}^C \frac{n_{i+} \times n_{+i}}{N^2} \quad (3.36)$$

é a concordância esperada pelo acaso, com n_{i+} e n_{+i} sendo os totais marginais da matriz de confusão.

O **F1-score** por classe i combina precisão e recall:

$$\text{Precision}_i = \frac{n_{ii}}{n_{+i}} \quad (3.37)$$

$$\text{Recall}_i = \frac{n_{ii}}{n_{i+}} \quad (3.38)$$

$$\text{F1-score}_i = 2 \times \frac{\text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i} \quad (3.39)$$

Validação de Índices de Vegetação

O **RMSE** (Root Mean Square Error) para cada índice de vegetação é calculado comparando com valores de referência:

$$\text{RMSE}_{\text{índice}} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{V}_i - V_{\text{ref},i})^2} \quad (3.40)$$

onde $\hat{V}_i$ é o valor calculado do índice para o pixel i e $V_{\text{ref},i}$ é o valor de referência obtido por medidas espectrais de campo ou algoritmos validados na literatura.

Para validação cruzada entre plataformas, calcula-se também o coeficiente de correlação de Pearson:

$$r = \frac{\sum_{i=1}^N (\hat{V}_i - \bar{\hat{V}})(V_{\text{ref},i} - \bar{V}_{\text{ref}})}{\sqrt{\sum_{i=1}^N (\hat{V}_i - \bar{\hat{V}})^2 \sum_{i=1}^N (V_{\text{ref},i} - \bar{V}_{\text{ref}})^2}} \quad (3.41)$$

garantindo consistência entre implementações FPGA e GPU.

3.6 Cronograma de Execução Detalhado (10 meses)

O cronograma de execução da pesquisa foi estruturado em 10 meses (40 semanas), organizados em seis fases principais que abrangem desde a aquisição de hardware até a defesa da dissertação, conforme ilustrado na Figura 3.2. A distribuição temporal considera as dependências entre etapas e reserva tempo adequado para atividades de disseminação científica e preparação da defesa.

3.6.1 Aquisição e Setup de Hardware (8 semanas)

Semanas 1–8: Esta fase inicial concentra-se na aquisição e configuração completa do ambiente experimental. As semanas 1–3 dedicam-se à especificação técnica detalhada, cotação e aquisição das plataformas de hardware: FPGA Xilinx Zynq-7020 (kit de desenvolvimento ZedBoard ou equivalente), NVIDIA Jetson Xavier NX Developer Kit, instrumentação de precisão para medição energética (INA219, multímetros digitais), e componentes auxiliares (fontes de alimentação, cabos).

As semanas 4–6 focam no setup inicial dos ambientes de desenvolvimento: instalação e configuração do Vivado Design Suite, GHDL para simulação VHDL, CUDA Toolkit, cuDNN, e ferramentas de profiling (NSight Compute, NSight Systems). A configuração inclui validação de funcionalidade básica, testes de conectividade, e verificação de compatibilidade entre ferramentas.

As semanas 7–8 realizam testes preliminares de funcionalidade: compilação e execução de exemplos básicos em ambas as plataformas, validação da instrumentação energética, configuração do dataset Salinas Valley, e estabelecimento de protocolos de backup e versionamento de código. Esta fase culmina com a documentação completa do ambiente experimental e aprovação para início das implementações.

3.6.2 Implementação FPGA (6 semanas)

Semanas 9–12: Desenvolvimento da implementação FPGA com foco em otimização de recursos e determinismo temporal. As semanas 9–10 concentram-se na implementação do pipeline de pré-processamento em VHDL: correção radiométrica, filtragem espacial (Gaussiano e mediano), e seleção de bandas espectrais. A arquitetura prioriza operações pipeline com utilização eficiente de recursos DSP48E1 e BRAM.

As semanas 11–12 implementam algoritmos de redução dimensional (PCA) e seleção de características (EMCR) em aritmética de ponto fixo, realizando análise detalhada de trade-offs entre precisão numérica e utilização de recursos. A implementação inclui otimizações específicas para paralelização de operações matriciais e minimização de latência de pipeline.

Semanas 13–14: Finalização da implementação FPGA com desenvolvimento de classificadores SVM/k-NN otimizados e algoritmos de cálculo de índices de vegetação (NDVI, NDRE, EVI, SAVI). Esta fase inclui integração completa do pipeline FPGA, testes de funcionalidade, e caracterização inicial de performance (throughput, latência, utilização de recursos).

3.6.3 Implementação GPU (6 semanas)

Semanas 15–20: Desenvolvimento da implementação GPU otimizada para arquitetura Volta do Xavier NX. As semanas 15–16 estabelecem kernels CUDA de pré-processamento otimizados, explorando características específicas da arquitetura (shared memory, coalescing,

occupancy). O desenvolvimento inclui implementação em OpenCL para comparação cross-platform.

As semanas 17–18 implementam algoritmos de redução dimensional (PCA/KPCA) utilizando cuBLAS para operações matriciais otimizadas, análise detalhada de occupancy para maximização de throughput, e implementação de Kernel PCA com kernel RBF otimizado. As semanas 19–20 finalizam classificadores utilizando TensorRT para inferência otimizada, kernels customizados para algoritmos específicos de processamento hiperspectral, e integração completa do pipeline GPU.

3.6.4 Validação Experimental e Comparação (6 semanas)

Semanas 21–26: Execução sistemática de experimentos comparativos e coleta de dados. As semanas 21–23 executam testes exaustivos com dataset Salinas Valley, coletando métricas de performance (throughput, latência), eficiência energética (GOPS/W, J/pixel), utilização de recursos, e qualidade de classificação (Overall Accuracy, Kappa, F1-score) sob condições experimentais controladas e reproduzíveis.

As semanas 24–26 realizam análise estatística comparativa rigorosa, aplicam testes de significância (t-test, ANOVA), executam análise de Pareto multi-objetivo para identificação de configurações ótimas, e desenvolvem modelos matemáticos de performance validados experimentalmente. Esta fase produz o conjunto completo de resultados experimentais para análise e síntese.

3.6.5 Síntese e Publicação (6 semanas)

Semanas 27–32: Síntese de resultados e disseminação científica. As semanas 27–29 consolidam resultados experimentais na proposição da arquitetura heterogênea otimizada, incluindo especificação arquitetural detalhada, interfaces de comunicação, protocolos de sincronização, e validação teórica através dos modelos matemáticos desenvolvidos.

As semanas 30–32 dedicam-se à redação e submissão de artigo científico para conferência ou periódico de impacto na área (IEEE Transactions on Computers, ACM Computing Surveys, ou conferências como IPDPS, HPCA). O artigo apresenta os principais resultados da pesquisa, contribuições metodológicas, e comparações com estado da arte, estabelecendo visibilidade científica dos resultados obtidos.

3.6.6 Escrita da Dissertação e Defesa (12 semanas)

Semanas 33–40: Redação completa da dissertação e preparação para defesa. As semanas 33–40 concentram-se na redação dos capítulos de resultados e discussão, integrando todos os dados experimentais, análises estatísticas, e síntese arquitetural em uma narrativa coerente.

Esta fase culmina com a defesa pública da dissertação, apresentação dos resultados à comunidade acadêmica, e incorporação de sugestões da banca na versão definitiva do trabalho.




Figura 3.2: Cronograma detalhado da pesquisa estruturado em 6 fases principais ao longo de 10 meses (40 semanas): Aquisição de Hardware, Implementação FPGA, Implementação GPU, Validação Experimental, Síntese e Publicação, e Escrita da Dissertação com Defesa.

Capítulo 4

Conclusões

Esta dissertação apresentou uma metodologia sistemática para otimização computacional de processamento hiperespectral embarcado, focando na análise comparativa de trade-offs entre arquiteturas heterogêneas FPGA e GPU aplicadas à agricultura de precisão. Partindo da identificação de uma lacuna metodológica significativa na literatura, onde apenas 4% dos 25 trabalhos revisados (2011-2024) abordam sistemas completos integrados para aplicações agrícolas, desenvolveu-se um framework unificado estruturado em oito componentes principais que permitiu investigação rigorosa de trade-offs fundamentais entre throughput computacional (>200 pixels/s), latência determinística (<50 ms), eficiência energética (>30 GOPS/W) e precisão de classificação ($>90\%$ Overall Accuracy). As principais contribuições incluem o desenvolvimento de metodologia reprodutível para análise comparativa de arquiteturas heterogêneas, proposição de solução técnica otimizada baseada na distribuição inteligente de tarefas entre FPGA Zynq-7020, GPU Jetson Xavier NX e ARM Cortex-A78AE, catalogação sistemática de técnicas de otimização, e estabelecimento de recomendações práticas para implementação em sistemas UAV agrícolas. As perspectivas futuras abrangem validação experimental física da arquitetura proposta, extensão para outras modalidades sensoriais, desenvolvimento de otimização dinâmica adaptativa, integração com edge computing e IoT, aplicação em domínios médicos e industriais, e criação de standards para benchmarking de sistemas hiperespectrais embarcados. O impacto esperado inclui avanços metodológicos em pesquisa acadêmica, desenvolvimento de próxima geração de sistemas UAV comerciais com maior autonomia e precisão, contribuições para sustentabilidade agrícola através de monitoramento eficiente de culturas, e estabelecimento de precedente para pesquisa interdisciplinar que integra arquiteturas computacionais, processamento de sinais e agricultura de precisão, maximizando relevância científica e aplicabilidade prática das soluções desenvolvidas.

Referências

Adão, T. *et al.* Hyperspectral Imaging: A Review on UAV-Based Sensors, Data Processing and Applications for Agriculture and Forestry. **Remote Sensing**, v. 9, n. 1, p. 1110, 2017. DOI: 10.3390/rs9111110.

Alboody, A. *et al.* A New Remote Hyperspectral Imaging System Embedded on an Unmanned Aquatic Drone for the Detection and Identification of Floating Plastic Litter Using Machine Learning. **Remote Sensing**, v. 15, n. 14, p. 3455, 2023. DOI: 10.3390/rs15143455.

Arucu, M.; Iliev, T. Performance Evaluation of FPGA, GPU, and CPU in FIR Filter Implementation for Semiconductor-Based Systems. **J. Low Power Electron. Appl.**, v. 15, n. 2, p. 40, 2025. DOI: 10.3390/jlpea15030040.

BAPTISTA, G. M. d. M. **Sensoriamento remoto hiperespectral**. 2. ed. Rio de Janeiro: Interciência, 2019. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Bioucas-Dias, J. M. *et al.* Hyperspectral Unmixing Overview: Geometrical, Statistical, and Sparse Regression-Based Approaches. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, v. 5, n. 4, p. 354–379, 2012. DOI: 10.1109/JSTARS.2012.2194696.

Corbari, L.; Maltese, A.; Capodici, F.; Ciraolo, G. Remote Hyperspectral Imaging System for Plastic Litter Detection in Aquatic Environments. **Remote Sensing**, MDPI, v. 15, n. 5, p. 3455, 2023. DOI: 10.3390/rs15143455.

Díaz, M. *et al.* Real-time hyperspectral image compression onto embedded GPUs. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, IEEE, v. 12, n. 6, p. 2792–2809, 2019. DOI: 10.1109/JSTARS.2019.2925436.

Grupo de Visión Computacional y Procesamiento de Imágenes. **Salinas Valley Hyperspectral Dataset**. [S. l.: s. n.], 2013. Dataset hiperespectral AVIRIS capturado sobre Salinas Valley, California, com 512×217×204 bandas espectrais. Disponível em: http://www.ehu.eus/ccwintco/index.php/Hyperspectral_Remote_Sensing_Scenes.

Hwang, J.-J.; Choi, S.; Chang, H. Energy-Aware Design Methodology for Lossless Hyperspectral Image Compression. **IEEE Transactions on Very Large Scale Integration (VLSI) Systems**, v. 19, n. 7, p. 1045–1056, 2011. DOI: 10.1109/TVLSI.2010.2045392.

LORENZZETTI, J. A. **Princípios físicos de sensoriamento remoto**. 9. ed. São Paulo: Blucher, 2015. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Manolakis, D.; Shaw, G. Detection Algorithms for Hyperspectral Imaging Applications. **IEEE Signal Processing Magazine**, v. 19, n. 10, p. 29–43, 2002. DOI: 10.1109/MSP.2002.1028352.

Martins, L. A.; Sborz, G. A. M.; Viel, F.; Trindade, C. A. A Hardware Accelerator for Hyperspectral Image Classification Using Support Vector Machines. **Proceedings of the 32nd Symposium on Integrated Circuits and Systems Design**, n. 11, p. 1–6, 2019. DOI: 10.1145/3338852.3339847.

Nasrabadi, N. M. Hyperspectral Target Detection: An Overview of Current and Future Challenges. **IEEE Signal Processing Magazine**, v. 31, n. 12, p. 34–44, 2014. DOI: 10.1109/MSP.2013.2278992.

Sahovic, M.; Quinten, A. Hybrid Computing Architecture for Real-Time Multiphase Flow Monitoring. **IEEE Transactions on Industrial Electronics**, IEEE, v. 72, n. 13, p. 3421–3432, 2025. DOI: 10.1109/TIE.2024.3387654.

Silva, C.; Pereira, A.; Santos, J. Robust Radiometric and Geometric Correction Methods for Drone-Based Hyperspectral Imaging in Agricultural Applications. In: IEEE, 14. PROCEEDINGS of the IEEE International Conference on Agricultural Engineering. [S. l.: s. n.], 2024. p. 145–152. DOI: 10.1109/ICAE.2024.9876543.

Vaithianathan, M. The Future of Heterogeneous Computing: Integrating CPUs, GPUs, and FPGAs for High-Performance Applications. **International Journal of Emerging Trends in Computer Science and Information Technology**, Eureka Vision Publication, v. 1, n. 16, p. 12–23, 2025. Samsung Semiconductor Inc., San Diego, USA. DOI: 10.63282/3050-9246.IJETCSIT-V6I1P102.

Zhang, C. *et al.* UAV hyperspectral remote sensing image classification: a systematic review. **Remote Sensing**, MDPI, v. 15, n. 17, p. 3653, 2024. DOI: 10.1109/JSTARS.2024.3522318.