



UNIVERSIDADE ESTADUAL DE CAMPINAS
Faculdade de Tecnologia

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional
visando eficiência energética e Latência no Processamento
Hiperespectral Embarcado**

Limeira
2026

Diego de Freitas Maia

**Estudo sobre estratégias para Otimização computacional visando
eficiência energética e Latência no Processamento Hiperespectral
Embarcado**

Dissertação apresentada à Faculdade de
Tecnologia da Universidade Estadual de
Campinas como parte dos requisitos para a
obtenção do título de Mestre em Tecnologia, na
área de Sistemas de Informação e Comunicação.

Orientador: Prof. Dr. Leandro Ronchini Ximenes

Este trabalho corresponde à versão final da
Dissertação defendida por Diego de Freitas
Maia e orientada pelo Prof. Dr. Leandro
Ronchini Ximenes.

Limeira
2026

Na versão final, esta página será substituída pela ficha catalográfica no TCC, na dissertação de mestrado ou na tese de doutorado.

Caso não tenha ficha catalográfica, deixe essa página em branco conforme as instruções a seguir.

No arquivo principal (`tese.tex`), adicione o nome do arquivo PDF com a ficha catalográfica como parâmetro para o comando `\fichacatalografica{}`. Caso a versão da sua dissertação ou tese seja a versão anterior à aprovação pela banca, você pode substituir esta por uma página em branco com o comando a seguir:

`\fichacatalografica{branco.pdf}`

Substitua o arquivo `branco.pdf` por `white.pdf`, nos textos em inglês, ou por `blanco.pdf`, para textos em espanhol. Todos esses arquivos PDF já estão disponíveis neste modelo.

De acordo com o padrão da CCPG: “Quando se tratar de Teses e Dissertações financiadas por agências de fomento, os beneficiados deverão fazer referência ao apoio recebido e inserir esta informação na ficha catalográfica, além do nome da agência, o número do processo pelo qual recebeu o auxílio.”

e

“caso a tese de doutorado seja feita em Cotutela, será necessário informar na ficha catalográfica o fato, a Universidade conveniente, o país e o nome do orientador.”

Prof. Dr. Leandro Ronchini Ximenes

Presidente da Comissão Julgadora

Prof.^a Dr.^a Segunda Avaliadora

Instituição da segunda avaliadora

Dr. Terceiro Avaliador

Instituição do terceiro avaliador

Ata da defesa, assinada pelos membros da Comissão Examinadora, encontra-se no SIGA/Sistema de Fluxo de Dissertação/Tese e na Secretaria de Pós-graduação da Faculdade de Tecnologia.

Sumário

Resumo	9
Abstract	1
1 Introdução	2
1.1 Contexto e Motivação	2
1.2 Problema de Pesquisa	4
1.3 Objetivos	5
1.4 Hipóteses de Trabalho	6
1.5 Estrutura da Dissertação	6
2 Levantamento Bibliográfico	8
2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais	8
2.1.1 O espectro eletromagnético	9
2.1.2 Propriedades Ópticas dos Materiais	11
2.1.3 Princípios de Sensoriamento Remoto Hiperespectral	13
2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações	17
2.2.1 Tipos de Sistemas de Imageamento Hiperespectral	17
2.2.2 Sensores e Sistemas Comerciais Representativos	18
2.3 Técnicas de Processamento de Imagens Hiperespectrais	18
2.3.1 Pré-processamento e Correção Radiométrica	20
2.3.2 Redução Dimensional e Seleção de Bandas	20
2.3.3 Algoritmos de Classificação Espectral	21
2.3.4 Processamento de Sinais Espectrais Avançado	22
2.3.5 Considerações para Implementação Embarcada	23
2.4 Tipos de Processadores para Processamento Hiperespectral	24
2.4.1 Processadores de Uso Geral (CPU)	24
2.4.2 Unidades de Processamento Gráfico (GPU)	25
2.4.3 Field-Programmable Gate Arrays (FPGA)	25
2.5 Arquiteturas Heterogêneas de Processamento	26
2.5.1 Fundamentos de Computação Heterogênea	26
2.5.2 Arquiteturas CPU+GPU Integradas	27
2.5.3 Sistemas CPU+FPGA	28
2.5.4 Processamento Digital de Sinais em Sistemas Heterogêneos	28
2.5.5 Arquiteturas Tri-híbridas CPU+GPU+FPGA	30
2.5.6 Desafios e Soluções em Computação Heterogênea	30
2.5.7 Aplicações em Tempo Real e Simulação Multi-taxa	31

3	Metodologia	35
3.1	Considerações Iniciais	35
3.2	Abordagem Metodológica	36
3.2.1	Caracterização da Pesquisa	36
3.2.2	Estratégia de Investigação Comparativa	36
3.2.3	Delimitação do Escopo Tecnológico	37
3.3	Procedimentos de Investigação	37
3.3.1	Levantamento e Catalogação de Técnicas	38
3.3.2	Modelagem Teórica Comparativa	38
3.3.3	Framework de Simulação Integrado	39
3.4	Estudo Comparativo de Arquiteturas	39
3.4.1	Análise de Técnicas FPGA Xilinx	40
3.4.2	Análise de Técnicas GPU Embarcadas	40
3.4.3	Estudo Comparativo Cross-Platform	41
3.5	Protocolo de Simulação e Benchmarking	42
3.5.1	Ambiente de Simulação	42
3.5.2	Datasets e Cargas de Trabalho	43
3.5.3	Protocolo de Medição e Análise	43
3.6	Metodologia de Síntese Arquitetural	44
3.6.1	Análise Multi-Critério	44
3.6.2	Design Space Exploration	44
3.6.3	Síntese da Arquitetura Proposta	45
3.7	Planejamento de Execução	45
3.7.1	Fases de Desenvolvimento	46
3.7.2	Cronograma de Execução	46
3.7.3	Marcos e Entregáveis	48
3.7.4	Gestão de Riscos e Contingências	48
3.8	Considerações Finais do Capítulo	49
4	Conclusões e trabalhos futuros	50

Lista de Figuras

- 2.1 Principais componentes de um sistema de sensoriamento remoto, ilustrando a interação entre fonte de energia, atmosfera, alvo e sensor. Adaptado de Lorenzzetti (2015). 16
- 3.1 Cronograma detalhado do projeto apresentado como diagrama de Gantt. O cronograma mostra as quatro etapas principais (Fundamentação Teórica, Desenvolvimento Experimental, Análise e Redação, Finalização), a fase de qualificação UNICAMP, e os cinco marcos principais (M1–M5) distribuídos ao longo de 10 meses de execução. 47

Lista de Tabelas

2.1	Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).	10
2.2	Análise comparativa de sensores hiperespectrais baseada na literatura científica	19

Resumo

O processamento de imagens hiperespectrais em sistemas embarcados representa um dos desafios computacionais mais complexos da atualidade, exigindo conciliação entre requisitos aparentemente conflitantes de alta performance, baixa latência e eficiência energética em plataformas com severas restrições de recursos. Esta dissertação apresenta metodologia sistemática de investigação comparativa para otimização computacional de processamento hiperespectral embarcado, focando na análise de trade-offs entre diferentes arquiteturas heterogêneas e técnicas de otimização através de abordagem exploratória-comparativa baseada em simulação e modelagem teórica.

A pesquisa adota abordagem metodológica inovadora que privilegia análise teórica e simulada sobre implementação física, justificada pela necessidade de investigar sistematicamente múltiplas alternativas arquiteturais sob condições controladas. A metodologia estrutura-se em oito componentes principais: catalogação sistemática de técnicas de otimização FPGA e GPU; modelagem teórica comparativa de performance; framework de simulação integrado; estudo comparativo cross-platform; protocolo de benchmarking padronizado; análise multi-critério baseada em metodologia AHP e análise de Pareto; design space exploration para identificação de configurações ótimas; e síntese de arquitetura heterogênea otimizada.

A revisão sistemática de 25 trabalhos publicados entre 2011-2024 revelou lacuna metodológica significativa: apenas 4% dos estudos abordam sistemas completos integrados, enquanto 96% focam em técnicas isoladas ou otimizações específicas de plataforma. Esta fragmentação impede análise sistemática de trade-offs e identificação de soluções ótimas para cenários específicos de aplicação. Como principal contribuição, desenvolve-se framework metodológico unificado que permite comparação objetiva entre diferentes abordagens arquiteturais considerando múltiplos critérios de performance.

A metodologia proposta estabelece base científica rigorosa para investigação de sistemas hiperespectrais embarcados, preenchendo lacuna identificada na literatura e proporcionando framework reproduzível para pesquisas futuras. Os resultados esperados incluem identificação quantitativa de trade-offs fundamentais, proposição de arquitetura heterogênea otimizada baseada em análise sistemática, e desenvolvimento de recomendações práticas para seleção de técnicas segundo requisitos específicos de aplicação em agricultura de precisão, monitoramento ambiental e sistemas UAV autônomos.

Palavras-chave: Processamento Hiperespectral, Arquiteturas Heterogêneas, Metodologia Comparativa, Otimização Computacional, Análise Multi-critério, Sistemas Embarcados, FPGA, GPU.

Abstract

Hyperspectral image processing in embedded systems represents one of the most complex computational challenges of today, requiring reconciliation between apparently conflicting requirements of high performance, low latency, and energy efficiency in platforms with severe resource constraints. This dissertation presents a systematic comparative investigation methodology for computational optimization of embedded hyperspectral processing, focusing on trade-off analysis between different heterogeneous architectures and optimization techniques through an exploratory-comparative approach based on simulation and theoretical modeling.

The research adopts an innovative methodological approach that prioritizes theoretical and simulated analysis over physical implementation, justified by the need to systematically investigate multiple architectural alternatives under controlled conditions. The methodology is structured into eight main components: systematic cataloging of FPGA and GPU optimization techniques; comparative theoretical performance modeling; integrated simulation framework; cross-platform comparative study; standardized benchmarking protocol; multi-criteria analysis based on AHP methodology and Pareto analysis; design space exploration for optimal configuration identification; and optimized heterogeneous architecture synthesis.

The systematic review of 25 works published between 2011-2024 revealed a significant methodological gap: only 4% of studies address complete integrated systems, while 96% focus on isolated techniques or platform-specific optimizations. This fragmentation prevents systematic trade-off analysis and identification of optimal solutions for specific application scenarios. As the main contribution, a unified methodological framework is developed that enables objective comparison between different architectural approaches considering multiple performance criteria.

The proposed methodology establishes a rigorous scientific foundation for embedded hyperspectral systems investigation, filling the identified literature gap and providing a reproducible framework for future research. Expected results include quantitative identification of fundamental trade-offs, proposition of an optimized heterogeneous architecture based on systematic analysis, and development of practical recommendations for technique selection according to specific application requirements in precision agriculture, environmental monitoring, and autonomous UAV systems.

Keywords: Hyperspectral Processing, Heterogeneous Architectures, Comparative Methodology, Computational Optimization, Multi-criteria Analysis, Embedded Systems, FPGA, GPU.

Capítulo 1

Introdução

O imageamento hiperespectral desenvolveu-se como tecnologia de sensoriamento remoto que altera métodos de caracterização de materiais, superfícies e fenômenos naturais. O imageamento hiperespectral captura informações sobre composição química e física de objetos através da aquisição de centenas de bandas espectrais estreitas, cada uma revelando características específicas dos materiais imageados. Diferentemente dos sistemas multiespectrais convencionais, que operam com poucas bandas largas, os sensores hiperespectrais oferecem resolução espectral superior, permitindo identificação de assinaturas espectrais imperceptíveis em sistemas tradicionais (LORENZZETTI, 2015).

Essa tecnologia possibilita aplicações em agricultura de precisão, permitindo detecção de estresse hídrico, deficiências nutricionais e infestações de pragas. Adão *et al.* (2017) demonstram que UAVs emergiram como plataforma custo-efetiva para imageamento hiperespectral, substituindo satélites e aeronaves tripuladas, com Support Vector Machines alcançando acurácia de 92% com 10 amostras de treinamento. No monitoramento ambiental, permite caracterização de ecossistemas, detecção de poluentes e acompanhamento de mudanças climáticas. Em defesa e segurança, detecta materiais camuflados, enquanto na mineração facilita identificação remota de depósitos minerais (BAPTISTA, 2019).

O processamento de dados hiperespectrais — que podem exceder centenas de megabytes por frame — em plataformas com restrições de energia, peso e tamanho representa problema central da computação embarcada. Esta dissertação investiga este problema, propondo abordagem metodológica baseada em análise comparativa e síntese de arquiteturas heterogêneas.

A pesquisa aborda lacuna na literatura: ausência de frameworks para avaliação e otimização de técnicas de processamento hiperespectral em sistemas embarcados. Através de metodologia estruturada, investigamos trade-offs entre performance computacional, eficiência energética e precisão de classificação, propondo soluções arquiteturais para diferentes cenários de aplicação.

1.1 Contexto e Motivação

O processamento de imagens hiperespectrais em sistemas embarcados representa desafio computacional significativo. A complexidade emerge das características dos dados hiperespectrais, onde cada pixel contém assinatura espectral composta por centenas de valores espectrais que capturam propriedades biofísicas e bioquímicas dos objetos

observados (Zhang *et al.*, 2024). Esta riqueza informacional constitui simultaneamente a vantagem e o desafio computacional do imageamento hiperespectral, especialmente para processamento em tempo real sob restrições de recursos.

O desafio intensifica-se em aplicações de veículos aéreos não tripulados (UAVs) para imageamento hiperespectral. Imagens hiperespectrais capturadas por UAVs exibem variações espectrais pronunciadas comparadas aos dados de plataformas espaciais, apresentando desafios para classificação (Zhang *et al.*, 2024). Esta complexidade surge das condições operacionais dos UAVs: variações de altitude, ângulos de observação, condições atmosféricas e iluminação introduzem heterogeneidade espectral e radiométrica que sistemas tradicionais de processamento não conseguem lidar adequadamente.

O problema intensifica-se com requisitos de processamento em tempo real. Sistemas hiperespectrais embarcados devem atender múltiplos requisitos: alta taxa de compressão devido aos volumes de dados, processamento em tempo real para evitar acúmulo de dados não processados, e baixa complexidade computacional devido às limitações de recursos das plataformas embarcadas (Díaz *et al.*, 2019).

A análise dos trabalhos existentes revela que as técnicas tradicionais de processamento enfrentam limitações quando aplicadas ao contexto embarcado. Manolakis e Shaw (2002) demonstram que detectores estatísticos clássicos como Reed-Xiaoli (RX) e matched filters, embora teoricamente fundamentados, assumem distribuições gaussianas que frequentemente não se aplicam a cenários reais. Nasrabadi (2014) complementa esta análise identificando que detectores adaptativos como ACE (Adaptive Coherence Estimator) e GLRT (Generalized Likelihood Ratio Test) superam métodos de correlação simples, mas requerem processamento computacional intensivo. Díaz *et al.* observam que, embora a maioria dos compressores com perdas alcancem performance satisfatória em termos de taxa de distorção, eles são caracterizados por custos computacionais altos, requisitos intensivos de memória e natureza não escalável, impedindo seu uso em aplicações sob restrições de latência, energia e memória, típicas da compressão embarcada (Díaz *et al.*, 2019).

A demanda crescente por aplicações autônomas tem impulsionado o desenvolvimento de soluções baseadas em arquiteturas heterogêneas. Destacando o avanço dos UAVs, combinado com a miniaturização de equipamentos de imageamento hiperespectral, tornou o sensoriamento remoto hiperespectral baseado em UAV uma tecnologia essencial para observação da Terra (Zhang *et al.*, 2024). No entanto, é ressaltado que os sensores hiperespectrais baseados em UAV oferecem vantagens em capturar informações espectrais de objetos terrestres, mas também apresentam desafios relacionados ao processamento de dados de alta resolução espacial, temporal e espectral.

O cenário atual de pesquisa revela avanços em técnicas individuais de otimização. Técnicas de deep learning, incluindo redes neurais convolucionais (CNNs), métodos baseados em Transformer, redes neurais recorrentes (RNNs), redes neurais de grafos convolucionais (GCNs), redes adversariais generativas (GANs) e modelos híbridos, demonstram potencial na classificação de imagens hiperespectrais (Zhang *et al.*, 2024). Bioucas-Dias *et al.* (2012) demonstram que técnicas de unmixing espectral, incluindo abordagens geométricas, estatísticas e de regressão esparsa, são fundamentais para análise de pixels mistos, com métodos spectral-spatial superando análise apenas espectral. Estes modelos podem melhorar significativamente a precisão e robustez da classificação explorando características espaciais e espectrais simultaneamente, estabelecendo deep learning como paradigma dominante no campo.

Paralelamente, Díaz et al. demonstram o potencial das GPUs embarcadas para compressão hiperespectral em tempo real, implementando o compressor HyperLCA (lossy compression algorithm for hyperspectral image system) nos kits de desenvolvimento NVIDIA Jetson TK1 e TX2. Os resultados obtidos pelos autores mostram que o compressor HyperLCA consegue processar mais de 330 frames por segundo, verificando tanto a performance do compressor HyperLCA para a aplicação quanto o alcance de performance em tempo real através das implementações desenvolvidas. Este trabalho demonstra como GPUs embarcadas de baixo consumo podem ser utilizadas para acelerar o processamento de dados hiperespectrais, aproveitando sua capacidade de processamento paralelo.

A importância da eficiência energética em sistemas embarcados é demonstrada pelos resultados que mostram melhorias através de arquiteturas heterogêneas (Vaithianathan, 2025). Técnicas de co-design hardware-software podem resultar em melhorias de 21x na velocidade de throughput (Hwang; Choi, S.; Chang, 2011) e redução de até 69,88x no consumo energético comparado a implementações em GPUs (Arucu; Iliev, 2025). Os resultados de co-design evidenciam o potencial de abordagens integradas que exploram sinergias entre diferentes componentes arquiteturais.

Contudo, apesar destes avanços pontuais, é identificado uma lacuna na literatura atual: “Apesar destes avanços, as técnicas atuais de classificação de imagens hiperespectrais de UAV ainda enfrentam diversos desafios, incluindo processamento de dados de alta dimensionalidade, heterogeneidade espectral e variabilidade radiométrica entre diferentes cenas” (Zhang *et al.*, 2024). Os autores enfatizam que deep learning permanece largamente uma abordagem de “caixa preta” para a maioria dos problemas, indicando a necessidade de abordagens mais sistemáticas e interpretáveis.

1.2 Problema de Pesquisa

O problema central investigado nesta dissertação emerge da análise do estado da arte em processamento hiperespectral embarcado, revelando lacuna metodológica que permeia a literatura científica contemporânea. Esta lacuna se manifesta quando analisamos a evolução das técnicas de processamento hiperespectral nas últimas décadas.

Zhang et al. documentam que, ao longo das últimas décadas, as técnicas de classificação de imagens hiperespectrais de sensoriamento remoto por UAV alcançaram avanços, oferecendo detalhes e precisão para observação da Terra (Zhang *et al.*, 2024). O trabalho oferece revisão das aplicações e performances de métodos tradicionais de machine learning e deep learning neste campo, resumindo as principais direções de pesquisa atuais e desafios técnicos. No entanto, os autores identificam fragmentação significativa na pesquisa: “algoritmos tradicionais de machine learning podem alcançar certos níveis de precisão de classificação, mas frequentemente têm dificuldades com a alta dimensionalidade e natureza não-linear dos dados hiperespectrais”.

Esta fragmentação resulta em limitações para o desenvolvimento de sistemas práticos. Díaz et al. observam que a complexidade dos algoritmos de compressão, bem como o volume de dados a serem comprimidos e os recursos computacionais limitados dos dispositivos de hardware embarcados, tornam a compressão em tempo real uma tarefa desafiadora. Os autores enfatizam que esta complexidade não é meramente técnica, mas representa barreira à implementação prática de sistemas hiperespectrais em plataformas com restrições de recursos.

A ausência de metodologias sistemáticas para comparação objetiva entre diferentes abordagens arquiteturais cria ambiente de incerteza que impede o progresso da área. Zhang et al. destacam que “a performance de diferentes frameworks de redes neurais na classificação de imagens hiperespectrais de UAV varia significativamente, com métodos baseados em GCN e CNN geralmente superando abordagens baseadas em RNN”. No entanto, os autores observam que cada trabalho utiliza métricas próprias, datasets distintos e condições experimentais particulares, impedindo comparações diretas e síntese de conhecimento sistemática.

O problema se agrava quando consideramos a predominância de validações em contextos controlados e simplificados. Vaithianathan observa que, embora avanços tenham sido alcançados em arquiteturas heterogêneas individuais, “questões relacionadas ao consumo de energia, escalabilidade, complexidade de programação, gerenciamento de recursos e segurança devem ser abordadas para criar sistemas robustos e eficientes”. O autor enfatiza que as complexidades da integração de múltiplos componentes, as interações entre subsistemas, e os desafios práticos de implementação permanecem inexplorados.

Díaz et al. contribuem para esta discussão documentando que os experimentos realizados em seu trabalho são “orientados às necessidades impostas por uma aplicação específica de agricultura inteligente, embora todas as conclusões obtidas sejam extrapoláveis para outros campos nos quais imagens hiperespectrais sensoreadas remotamente devem ser comprimidas em tempo real”. Esta observação ressalta a necessidade de frameworks mais gerais que possam ser aplicados sistematicamente a diferentes domínios de aplicação.

Diante deste cenário, o problema de pesquisa pode ser formulado: Como desenvolver metodologia sistemática para investigação comparativa de técnicas de otimização em processamento hiperespectral embarcado que permita identificação objetiva de arquiteturas ótimas, considerando os trade-offs entre performance computacional, eficiência energética e precisão de classificação para diferentes cenários de aplicação com requisitos específicos e constraints operacionais distintos?

Esta formulação origina três questões de pesquisa interdependentes que estruturam a investigação: Como caracterizar quantitativamente as diferentes técnicas de otimização disponíveis, estabelecendo métricas padronizadas que permitam comparação objetiva? Quais são os trade-offs fundamentais entre throughput, latência, consumo energético, precisão e custo em sistemas integrados? Como desenvolver framework metodológico que permita síntese sistemática de arquiteturas otimizadas através de análise multi-critério?

1.3 Objetivos

Os objetivos desta dissertação foram estruturados para abordar sistematicamente as lacunas identificadas na literatura científica, respondendo às questões de pesquisa formuladas. O objetivo geral consiste em desenvolver metodologia sistemática e reproduzível para investigação comparativa de técnicas de otimização em processamento hiperespectral embarcado, estabelecendo framework analítico que permita quantificação objetiva de trade-offs entre performance computacional, eficiência energética e precisão de classificação em arquiteturas heterogêneas.

Os objetivos específicos desdobram-se em cinco dimensões complementares. Primeiramente, realizar mapeamento de técnicas de otimização disponíveis na literatura científica, organizando-as segundo taxonomia estruturada que considere tipo de

plataforma, estágio de processamento, métricas de performance e adequação a cenários específicos. Em segundo lugar, desenvolver modelos matemáticos analíticos de performance para diferentes arquiteturas, estabelecendo framework teórico que capture complexidade computacional, utilização de recursos e padrões de consumo energético. O terceiro objetivo específico envolve implementar ambiente de simulação integrado que permita avaliação comparativa sistemática sob condições controladas, integrando simuladores específicos de plataforma, datasets padronizados e protocolos de medição reprodutíveis. O quarto objetivo estabelece metodologia de análise multi-critério baseada em teoria de decisão, incorporando técnicas como Analytic Hierarchy Process para ponderação de critérios e análise de Pareto para identificação de soluções não-dominadas. Finalmente, o quinto objetivo visa propor arquitetura heterogênea otimizada baseada nos resultados da análise comparativa, incluindo especificação arquitetural detalhada, interfaces de comunicação e validação teórica através dos modelos desenvolvidos.

1.4 Hipóteses de Trabalho

As hipóteses desta investigação foram formuladas com base em evidências empíricas identificadas na literatura. A primeira hipótese postula que análise sistemática e integrada de técnicas de otimização complementares revelará oportunidades de melhoria superiores às obtidas por técnicas isoladas. Díaz et al. fornecem evidência empírica para esta hipótese ao demonstrar que implementações otimizadas em GPUs embarcadas alcançam performance de 330 fps com compressão, enquanto Vaithianathan reporta melhorias de 2100% em throughput (Hwang; Choi, S.; Chang, 2011) e redução de até 69,88x no consumo energético através de co-design hardware-software (Arucu; Iliev, 2025).

A segunda hipótese afirma a existência de trade-offs fundamentais e matematicamente modeláveis entre dimensões de performance. Zhang et al. fundamentam esta hipótese ao documentar que “métodos baseados em GCN demonstram vantagem particular ao lidar com amostras pequenas”, indicando relações sistemáticas entre arquitetura, tamanho do dataset e performance de classificação que podem ser capturadas por modelos analíticos apropriados.

A terceira hipótese propõe que metodologia de análise multi-critério baseada em simulação e modelagem teórica demonstrará capacidade superior de identificar arquiteturas otimizadas. Esta hipótese é fundamentada pela observação de Zhang et al. de que “com a integração de inteligência artificial, deep learning e tecnologias de Big Data, o sensoriamento remoto hiperespectral por UAV está fazendo a transição de um ‘observador’ passivo para um ‘analisador’ e ‘tomador de decisão’ ativo”, sugerindo que abordagens sistemáticas e integradas podem superar métodos tradicionais.

1.5 Estrutura da Dissertação

Esta dissertação está organizada em capítulos que seguem progressão lógica, construindo o conhecimento necessário para abordar o problema identificado. O Capítulo 2 apresenta levantamento bibliográfico, estabelecendo fundamentos teóricos através de exposição dos princípios físicos da espectroscopia de imageamento, análise das tecnologias de câmeras hiperespectrais disponíveis, categorização sistemática de técnicas

de processamento e análise de arquiteturas de processamento modernas incluindo FPGAs, GPUs e sistemas heterogêneos.

O Capítulo 3 desenvolve a metodologia de pesquisa, justificando cada escolha metodológica baseada na análise da literatura. A abordagem exploratória-comparativa é descrita, incluindo protocolos de catalogação sistemática, frameworks de modelagem matemática e ambientes de simulação. Os procedimentos de análise multi-critério são formalizados, incluindo metodologias para ponderação de objetivos e identificação de soluções ótimas.

O Capítulo 4 apresentará os resultados da catalogação sistemática e análise comparativa, organizados segundo taxonomia desenvolvida. Modelos matemáticos de performance serão derivados e validados, com resultados de simulação apresentados através de visualizações que permitem exploração do espaço de trade-offs. O Capítulo 5 sintetizará os resultados em proposta de arquitetura heterogênea otimizada, incluindo especificação completa, validação teórica e diretrizes para implementação. O Capítulo 6 concluirá com síntese das contribuições principais, discussão de limitações e delineamento de direções futuras de pesquisa.

Capítulo 2

Levantamento Bibliográfico

Este capítulo apresenta a revisão da literatura sobre imageamento hiperespectral, abordando os fundamentos, tecnologias disponíveis e aplicações em sistemas embarcados. A análise foi organizada em sete seções principais: princípios físicos da espectroscopia de imageamento e formação de imagens espectrais; câmeras hiperespectrais, incluindo tipos, modelos e datasets públicos; técnicas de processamento de imagens hiperespectrais; tipos de processadores e suas características para processamento hiperespectral; arquiteturas heterogêneas de processamento; plataformas específicas para sensoriamento remoto; e benchmarking de plataformas comerciais. A revisão abrange trabalhos fundamentais da área e publicações recentes sobre aplicações em agricultura de precisão, monitoramento ambiental e sistemas embarcados, com ênfase nos desafios computacionais do processamento de grandes volumes de dados e soluções para operação em tempo real com restrições energéticas.

2.1 Princípios Físicos da Espectroscopia de Imageamento e Formação de Imagens Espectrais

Os conceitos fundamentais do imageamento hiperespectral baseiam-se nos princípios da física óptica que descrevem a interação entre a radiação eletromagnética e a matéria (LORENZZETTI, 2015). Esta seção examina as características das ondas eletromagnéticas e sua organização espectral, com foco particular na faixa de 400 a 2500 nm, que abrange as regiões do visível, infravermelho próximo e infravermelho de ondas curtas, essenciais para o sensoriamento remoto. As propriedades ópticas dos materiais são analisadas através dos fenômenos de reflectância, transmitância e absorção, processos físicos que originam as assinaturas espectrais únicas de cada substância e possibilitam sua identificação e caracterização (BAPTISTA, 2019). A compreensão da distinção entre sistemas multiespectrais e hiperespectrais, quanto à resolução espectral e capacidade de discriminação, fundamenta a escolha da tecnologia adequada para cada aplicação. Esses princípios teóricos são demonstrados através de aplicações práticas em agricultura de precisão e monitoramento ambiental, evidenciando como o conhecimento dos fundamentos físicos é indispensável para o desenvolvimento de metodologias robustas de aquisição, processamento e análise de dados hiperespectrais.

2.1.1 O espectro eletromagnético

A energia eletromagnética constitui a base física do sensoriamento remoto e do imageamento hiperespectral, podendo ter origem em fontes naturais, como o Sol, nos próprios alvos ou em sistemas ativos, como radares. Essa energia propaga-se em forma de ondas, transportando informações sobre os materiais com os quais interage. Compreender as propriedades fundamentais da radiação eletromagnética é essencial para entender os processos de aquisição e análise de dados hiperespectrais.

Definição e características das ondas eletromagnéticas

Ondas eletromagnéticas são perturbações que se propagam no espaço à velocidade da luz (c é 3×10^8 m/s no vácuo). São caracterizadas principalmente pelo comprimento de onda (λ) e pela frequência (f), relacionados por:

$$c = \lambda \odot f \quad (2.1)$$

A energia (E) transportada por uma onda eletromagnética é proporcional à sua frequência, conforme a equação de Planck:

$$E = h \odot f = \frac{hc}{\lambda} \quad (2.2)$$

em que h é a constante de Planck ($6,626 \times 10^{-34}$ J⋅s).

No contexto do sensoriamento remoto, diferentes unidades são empregadas para descrever as faixas espectrais:

- 1 kHz = 1×10^3 Hz
- 1 MHz = 1×10^6 Hz
- 1 GHz = 1×10^9 Hz
- 1 THz = 1×10^{12} Hz
- 1 μm = 1×10^{-6} m
- 1 nm = 1×10^{-9} m

Neste trabalho adota-se a unidade de micrometro (μm) para o comprimento de onda.

Regiões espectrais: do ultravioleta ao infravermelho

O espectro eletromagnético é dividido em regiões conforme as propriedades físicas da radiação e sua interação com a matéria (LORENZZETTI, 2015; BAPTISTA, 2019). Para sensoriamento remoto, destacam-se as seguintes faixas:

Ultravioleta (UV): 300 μm a 0,4 μm . Pouco utilizada em sensoriamento remoto terrestre devido à absorção atmosférica, mas relevante em aplicações específicas.

Visível: 0,4 a 0,7 μm , correspondente à radiação percebida pelo olho humano. Subdivisões usuais:

- Azul: 0,4—0,5 μm
- Verde: 0,5—0,6 μm

- Vermelho: 0,6—0,7 μm

Infravermelho próximo (NIR): 0,7 a 1,3 μm . Importante para estudos de vegetação devido à alta reflectância da clorofila.

Infravermelho de ondas curtas (SWIR): 1,3 a 3,0 μm . Fundamental para identificação de minerais e análise de umidade.

Os limites exatos dessas faixas podem variar entre autores, mas há consenso sobre as principais subdivisões. A Tabela 2.1 apresenta as subfaixas do infravermelho mais utilizadas em sensoriamento remoto.

Tabela 2.1: Faixas espectrais e subdivisões no infravermelho utilizadas em sensoriamento remoto (valores em nanômetros, nm, até 1 mm).

Faixa	Subfaixa	Comprimento de onda
Raios-X	—	0,03—30 nm
Ultravioleta	—	30—400 nm
Visível	—	400—700 nm
Infravermelho	NIR/IVP	740—1 000 nm
	SWIR/IVOC	1 000—3 000 nm
	LWIR/IVTM	3 000—14 000 nm
Micro-ondas	—	1—30 mm
Ondas de rádio	—	>30 mm

Observa-se que, em algumas referências (LORENZZETTI, 2015; BAPTISTA, 2019), a faixa de micro-ondas pode ser definida como indo de 1 mm até 1 m. Essas variações não comprometem a aplicação prática dos conceitos, mas devem ser consideradas ao comparar diferentes trabalhos.

Comprimentos de onda relevantes para sensoriamento remoto (400–2500 nm)

Para aplicações de imageamento hiperespectral e sensoriamento remoto, a faixa espectral de 400 a 2500 nm (0,4 a 2,5 μm) representa a região de maior interesse prático. Essa faixa abrange as regiões do visível, infravermelho próximo (NIR) e infravermelho de ondas curtas (SWIR), onde ocorrem os principais fenômenos de interação radiação-matéria relevantes para identificação e caracterização de materiais terrestres.

Região VNIR (400–1000 nm): A faixa do visível e infravermelho próximo é fundamental para estudos de vegetação e classificação de cobertura terrestre. Nessa região, processos eletrônicos dominam a absorção da radiação, resultando em transições entre níveis de energia eletrônica nos átomos e moléculas. A clorofila, por exemplo, apresenta forte absorção nas regiões azul (430–450 nm) e vermelha (640–660 nm), enquanto exibe alta reflectância no NIR (700–1000 nm).

Região SWIR (1000–2500 nm): No infravermelho de ondas curtas, as absorções são governadas por processos vibracionais moleculares. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo decorrem de efeitos do campo cristalino, enquanto outros processos eletrônicos produzem feições espectrais

significativas nessa faixa. Essa região é particularmente rica em informações sobre minerais, conteúdo de água e compostos orgânicos.

As transições entre níveis de energia são responsáveis pelas faixas de absorção nos espectros. As absorções são governadas por processos vibracionais, sendo que átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico resulta da mudança de um estado de energia mais baixo para um mais alto, enquanto a emissão resulta da mudança de um estado de energia mais alto para um mais baixo, com liberação de energia no mesmo comprimento de onda.

A compreensão dos fundamentos físicos da interação radiação-matéria é essencial para o desenvolvimento de algoritmos de processamento hiperespectral eficazes e para a interpretação adequada dos dados espectrais em aplicações práticas de sensoriamento remoto.

2.1.2 Propriedades Ópticas dos Materiais

As propriedades ópticas dos materiais constituem a base física que permite a identificação e caracterização de diferentes substâncias através do sensoriamento remoto hiperespectral (BAPTISTA, 2019). Quando a radiação eletromagnética interage com um material, três processos fundamentais podem ocorrer: reflexão, absorção e transmissão. A compreensão destes processos e dos fatores que os influenciam é essencial para o desenvolvimento de técnicas eficazes de análise espectral e para a interpretação adequada dos dados hiperespectrais em aplicações práticas.

Reflectância Espectral: Definição e Fatores Influenciadores

A espectroscopia de reflectância é o estudo da radiação eletromagnética como função do comprimento de onda em que ela está sendo refletida, emitida ou espalhada por um gás, um líquido ou um sólido (BAPTISTA, 2019). A energia refletida pelas superfícies pode ser entendida como a porção da energia incidente, subtraindo-se as perdas que foram absorvidas ou transmitidas.

A reflectância espectral $\rho.\lambda/$, função do comprimento de onda (λ), pode ser definida matematicamente como a razão entre a radiância da superfície $[L(\lambda)]$ expressa em $W\ m^{-2}\ sr^{-1}\ \mu m^{-1}$ no comprimento de onda (λ) e a irradiância incidente $[E(\lambda)]$ em $W\ m^{-2}\ \mu m^{-1}$ no comprimento de onda (λ), conforme a equação:

$$\rho.\lambda/ = \pi \frac{L.\lambda/}{E.\lambda/} \quad (2.3)$$

Esta definição estabelece a base quantitativa para a medição e comparação das propriedades espectrais de diferentes materiais. O Sol é a principal fonte natural de energia eletromagnética nas faixas do espectro do ultravioleta, do visível, do infravermelho próximo e do infravermelho de ondas curtas. Em comprimentos de onda maiores, na faixa do infravermelho termal, a eficiência do Sol como fonte de energia é bastante reduzida e a Terra passa a ter maior eficiência como fonte, porém nesta faixa não se analisa o espectro óptico de reflectância e sim o de emitância.(BAPTISTA, 2019)

O processo de interação dos fótons com a matéria resulta em que parte deles é refletida pelos grãos da superfície do material, alguns passam pelos grãos e alguns são absorvidos. Os fótons são absorvidos pelos minerais por diversos processos que dependem de sua

composição química. Essas absorções são governadas por dois processos gerais: processos eletrônicos e processos vibracionais.(BAPTISTA, 2019)

Fatores Físicos Influenciadores:

Composição química: A composição química do material determina fundamentalmente suas características espectrais. Diferentes elementos e compostos apresentam absorções características em comprimentos de onda específicos, criando as feições espectrais diagnósticas que permitem sua identificação (BAPTISTA, 2019).

Estrutura cristalina: A organização atômica em materiais cristalinos influencia significativamente as propriedades ópticas. O efeito de campo cristalino, processo eletrônico mais comumente encontrado nos espectros de minerais, é devido aos elétrons desemparelhados dos orbitais internos dos elementos de transição (Sc, Ti, V, Cr, Mn, Fe, Co, Ni, Cu e Zn).

Tamanho de partícula: O tamanho das partículas que compõem a superfície afeta significativamente a reflectância espectral. Partículas menores tendem a aumentar o espalhamento múltiplo, resultando em maior reflectância geral, enquanto partículas maiores podem aumentar a absorção.

Rugosidade superficial: A microtopografia da superfície influencia o padrão de espalhamento da radiação incidente. Superfícies rugosas tendem a produzir espalhamento difuso, enquanto superfícies lisas podem apresentar componentes especulares significativos.

Conteúdo de umidade: A presença de água nas amostras introduz absorções características em $1,4\ \mu\text{m}$ e $1,9\ \mu\text{m}$, além de afetar a intensidade geral da reflectância através do aumento da absorção.

Transmitância e Absorção: Princípios Físicos

Os processos de transmitância e absorção estão intimamente relacionados com os mecanismos quânticos de interação entre radiação eletromagnética e matéria (BAPTISTA, 2019). A compreensão destes processos é fundamental para interpretar as feições espectrais observadas nos dados hiperespectrais.

Processos Eletrônicos:

Átomos isolados e íons têm estados de energia discretos, caracterizando eventos quânticos. A absorção de fótons em um comprimento de onda específico é a causa da mudança de um estado de energia mais baixo para um mais alto. Já a emissão de um fóton é resultado da mudança de um estado de energia mais alto para um mais baixo. Quando um fóton é absorvido, de modo geral ele não é posteriormente emitido no mesmo comprimento de onda (BAPTISTA, 2019).

As transições entre os níveis de energia são responsáveis pelas feições de absorção nos espectros. Muitas das feições encontradas nos espectros obtidos nas faixas do visível e do infravermelho próximo são decorrentes de efeitos do campo cristalino, porém outros processos eletrônicos produzem feições espectrais importantes.

Efeito de Campo Cristalino:

O ferro é o elemento de transição mais comum na composição dos minerais que existem na superfície da Terra (BAPTISTA, 2019). Os orbitais d de todos os elementos de transição apresentam níveis de energia idênticos nos íons isolados, mas, quando o íon se localiza em um campo cristalino, os níveis de energia desses orbitais se dividem. De acordo com a teoria de campo cristalino para o caso do Fe^{3+} , por exemplo, os cinco orbitais de valência d do íon livre do elemento de transição que se encontram em níveis

iguais de energia são submetidos a um processo de repulsão eletrostática por causa da proximidade dos ligantes com carga negativa.

Esta divisão dos níveis energéticos resulta em absorções características que permitem a identificação de minerais específicos através de suas assinaturas espectrais.

Processos Vibracionais:

Em comprimentos de onda maiores, particularmente na região do infravermelho de ondas curtas (SWIR), os processos vibracionais dominam as absorções espectrais (BAPTISTA, 2019). Estes processos envolvem vibrações moleculares que ocorrem em frequências específicas, criando absorções características para diferentes grupos funcionais e ligações químicas.

2.1.3 Princípios de Sensoriamento Remoto Hiperespectral

Interação Radiação-Matéria no Contexto de Sensoriamento Remoto

O sensoriamento remoto hiperespectral fundamenta-se nos princípios físicos da interação entre radiação eletromagnética e matéria, constituindo uma extensão natural dos conceitos fundamentais abordados nas seções anteriores. A definição de sensoriamento remoto (SR) está sujeita a diferentes interpretações na literatura científica. De acordo com *Manual of Remote Sensing* (Ulaby, 1983), bem como em Elachi e Zyl (2006), SR é definido como a aquisição de informação sobre alguma propriedade de um objeto ou fenômeno sem contato físico com ele. A informação sobre um alvo seria obtida pela detecção e medida de mudanças que o objeto impõe sobre o meio circundante, seja ele eletromagnético, acústico ou potencial.

Schowengerdt (2007) considera SR como “a medida das propriedades de um objeto ou da superfície da Terra usando dados adquiridos de sensores e sistemas”, sendo um pouco mais restritivo. Segundo Slater (1980), SR é o conjunto de atividades utilizadas para a aquisição de informações relativas aos recursos naturais da Terra, ou ao seu meio ambiente, obtidas pela análise da energia eletromagnética refletida, emitida ou retroespalhada pelos alvos, coletada por meio de sensores remotos (BAPTISTA, 2019).

No contexto hiperespectral, a interação radiação-matéria adquire uma dimensão adicional de complexidade devido à alta resolução espectral dos sistemas de imageamento. Enquanto os processos eletrônicos e vibracionais descritos anteriormente permanecem fundamentalmente os mesmos, a capacidade de detectar e quantificar feições espectrais sutis é significativamente ampliada. (CLARK, 1999 apud LORENZZETTI, 2015) considera que quatro parâmetros gerais definem a capacidade de um espectrorradiômetro (sensor espectral): a faixa espectral, a largura das bandas espectrais, a amostragem espectral e a razão sinal/ruído.

A faixa espectral de resolução utilizada em sensoriamento remoto abrange tipicamente os seguintes intervalos espectrais: de 0,3 a 1,0 μm , chamado de visível e infravermelho próximo; de 1,0 a 2,5 μm , infravermelho de ondas curtas. A faixa do infravermelho termal situa-se a partir de 3,0 μm até aproximadamente o pico máximo de emitância da Terra em torno de 10,0 μm (LORENZZETTI, 2015).

A largura da banda espectral é definida por (CLARK, 1999 apud LORENZZETTI, 2015) como a largura de um canal espectral individual no espectrorradiômetro. Quanto mais estreita for a largura da banda espectral, mais precisa será a determinação da feição de absorção do mineral. Alguns sistemas sensores possuem bandas largas e não espectralmente contíguas, não permitindo como contínuas, enquanto outros sistemas,

como o AVIRIS, apresentam largura de bandas espectrais estreitas com espaçamento contínuo e permitem a identificação de feições características dos minerais.

Sensores Multiespectrais vs. Hiperspectrais: Diferenças Fundamentais

A distinção fundamental entre sensores multiespectrais e hiperspectrais reside na resolução espectral e na capacidade de discriminação de materiais. O perfil da largura também é importante. O ideal é que cada canal de um espectrorradiômetro rejeite toda radiação que não esteja dentro do alcance estreito de determinado comprimento de onda. Mas o que geralmente ocorre, em virtude de efeitos ópticos muito complexos, é que a radiação pode vazar, difundindo-se dentro do sistema óptico ou dentro do sistema de filtros bloqueadores.

Normalmente a largura do perfil é definida como a largura em comprimento de onda em 50% do nível de resposta da função do detector, chamado de largura a meia altura (FWHM) (CLARK, 1999 apud LORENZZETTI, 2015). A razão sinal/ruído (S/N) visa a obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes.

A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície. Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 apud LORENZZETTI, 2015).

Sistemas multiespectrais convencionais, como o sensor Landsat TM5, operam com bandas espectrais relativamente largas e espaçadas, tipicamente entre 6 a 12 bandas cobrindo o espectro eletromagnético de interesse. O sistema Landsat é o *Moderate Resolution Imaging Spectroradiometer* (MODIS) não permitem a percepção de feições de absorção estreitas. A figura 3.1, desenvolvida por (GREEN, 1997 apud LORENZZETTI, 2015), apresenta como o sensor Landsat TM5 captaria as feições de absorção de três minerais: hematita, caulinita e dolomita.

A caulinita apresenta sua feição espectral mais característica em $2,2\ \mu\text{m}$. Já a dolomita, assim como a calcita, apresenta essa feição próxima para sua identificação, em $2,3\ \mu\text{m}$. As feições espectrais utilizadas para identificação da caulinita e dolomita (ou da calcita, pois essas são semelhantes) não podem ser discriminadas, pois aparecem integradas na banda 7 ($2,08$ a $2,35\ \mu\text{m}$) do sistema sensor TM5 do Landsat.

Aplicações Práticas: Agricultura de Precisão e Monitoramento Ambiental

As aplicações práticas do sensoriamento remoto hiperspectral em agricultura de precisão e monitoramento ambiental demonstram o potencial da tecnologia para resolver problemas reais com alta precisão e especificidade, constituindo um dos principais motivos para o desenvolvimento de sistemas embarcados eficientes.

Agricultura de Precisão:

Na agricultura de precisão, os sistemas hiperspectrais permitem o monitoramento detalhado da saúde vegetal, detecção precoce de estresses bióticos e abióticos, e estimativa de parâmetros biofísicos das culturas. A região do infravermelho próximo ($700\text{--}1000\ \text{nm}$) é particularmente importante devido à alta reflectância da clorofila, permitindo a avaliação do vigor vegetativo através de índices espectrais específicos.

As feições de absorção no SWIR ($1400\ \text{nm}$ e $1900\ \text{nm}$) são diagnósticas para o conteúdo de água nas plantas, facilitando o monitoramento de estresse hídrico em tempo real. Esta

capacidade é fundamental para sistemas embarcados em UAVs que operam em agricultura de precisão, permitindo tomada de decisões imediatas sobre irrigação e manejo de culturas.

A capacidade de discriminar espécies vegetais e estágios fenológicos através de suas assinaturas espectrais únicas representa um avanço significativo sobre os métodos convencionais. Sistemas hiperespectrais embarcados podem detectar variações sutis na composição bioquímica foliar, incluindo concentrações de clorofila, carotenoides, antocianinas e compostos estruturais como celulose e lignina.

Monitoramento Ambiental:

No monitoramento ambiental, a tecnologia hiperespectral oferece capacidades sem precedentes para a caracterização de materiais superficiais, qualidade da água e detecção de poluentes. A identificação de minerais específicos através de suas feições espectrais características permite o mapeamento geológico detalhado e a detecção de alterações hidrotermais associadas a depósitos minerais.

Para qualidade da água, os sensores hiperespectrais podem detectar e quantificar constituintes opticamente ativos como clorofila-a, sedimentos em suspensão, matéria orgânica dissolvida e diversos poluentes. As absorções características desses materiais em comprimentos de onda específicos permitem sua identificação e quantificação com precisão superior aos métodos convencionais.

A detecção de mudanças ambientais, sejam elas naturais ou antropogênicas, beneficia-se da alta sensibilidade espectral dos sistemas hiperespectrais. Alterações sutis na composição química ou física dos materiais superficiais, que seriam imperceptíveis em imagens multiespectrais, tornam-se detectáveis através da análise das variações nas assinaturas espectrais.

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo.

Aplicações Militares e de Defesa:

Grande parte das aplicações de sensoriamento remoto para fins militares é focada na detecção e classificação de alvos e no mapeamento de terrenos e instalações. Em geral, os dados obtidos (coletados por satélites ou por dispositivos aerotransportados) por aviões usados para aplicações militares são considerados como *classificados* (não disponíveis para terceiros) e de alta resolução espacial. Como definido por Simonett et al. (1983) e Jensen (2009), entende-se por resolução espacial, considera-se como resolução espacial de um sistema sensor a menor separação espacial angular ou linear entre dois objetos que podem ser detectados.

Um detalhamento mais aprofundado sobre o conceito de resolução pode ser encontrado em Forshaw et al. (1983) e Townshend (1980). Como uma imagem digital é constituída por *pixels*, costuma-se associar o tamanho do *pixel* para a resolução da imagem. Entretanto, essa definição dá a impressão de que somente podemos resolver objetos de tamanho maior, ou igual ao tamanho do *pixel*, o que nem sempre é verdade. A definição de alto contraste com pixels vizinhos, são mostrados por Schowengerdt (2007).

Sistemas de Sensoriamento Remoto: Componentes e Funcionamento:

A Figura 1.1 (LORENZZETTI, 2015) mostra esquematicamente como se processa a aquisição de informação sobre um alvo (geralmente, mas não sempre, na superfície da Terra) por meio da técnica de sensoriamento remoto. Os seguintes aspectos devem ser levados em conta:




Figura 2.1: Principais componentes de um sistema de sensoriamento remoto, ilustrando a interação entre fonte de energia, atmosfera, alvo e sensor. Adaptado de Lorenzzetti (2015).

1. As características da energia que incide sobre o alvo, quando proveniente de uma fonte tal qual o Sol, ou mesmo de uma antena de um sensor ativo como um radar, ou da energia do próprio alvo como no caso das aplicações de infravermelho termal (IVTI). Aí devemos levar em conta, por exemplo, a distribuição espectral, a intensidade e a polarização da radiação.
2. As características do meio em que essa energia se propaga (a atmosfera, ou coluna d'água para aplicações oceanográficas e limnológicas), isto é, as propriedades de absorção, espalhamento e emissão.
3. As propriedades do alvo (albedo, refletividade, rugosidade, emissividade etc.).
4. As próprias características do sensor (campo de visada, responsividade espectral, relação sinal/ruído, nível mínimo de resposta e variação ao grau de polarização (GDP) da radiação).

Para sensores ativos do tipo radar, em vez de fonte de energia ser o Sol, o próprio sensor emite pulsos de energia eletromagnética, que são parcialmente retroespalhados de volta ao sensor. Nesta situação específica de sensores remotos, os sistemas sensores são desenhados para receber prioritariamente a energia emitida pelo alvo, que é, entre vários fatores, dependente de sua temperatura (LORENZZETTI, 2015).

Desafios Técnicos e Limitações:

Os sistemas hiperespectrais enfrentam desafios únicos relacionados ao processamento de grandes volumes de dados em tempo real. A razão sinal/ruído (S/N) visa à obtenção de espectros com precisão suficiente para registrar todas as feições espectrais importantes. A S/N é dependente da sensibilidade dos detectores, da largura da banda espectral da luz refletida ou emitida pela superfície.

O teorema de Nyquist determina que o máximo de informação é obtido quando a amostragem espectral é igual à metade do FWHM; às vezes, porém, uma razão de amostragem diferente. Muitos dos espectrômetros modernos em uso (por exemplo, o AVIRIS) possuem um intervalo de amostragem de aproximadamente 10 nm e FWHM de 10 nm (CLARK, 1999 *apud* LORENZZETTI, 2015).

Algumas características espectrais são bastante fortes e uma razão sinal/ruído (S/N) externa identifica-las, enquanto outras feições são muito fracas e é necessária uma razão S/N mais alta (SWAYZE et al., 1997 *apud* LORENZZETTI, 2015). Esta limitação é particularmente relevante para sistemas embarcados, onde restrições de peso, energia e processamento computacional impõem desafios adicionais à manutenção de alta qualidade espectral.

Integração com Sistemas Embarcados:

A integração desses princípios fundamentais com as tecnologias de processamento embarcado, tema central desta dissertação, representa o próximo passo evolutivo na aplicação prática do sensoriamento remoto hiperespectral, permitindo análises em tempo real e tomada de decisões imediatas em campo. Os sistemas embarcados devem balancear os requisitos de alta resolução espectral com as limitações de processamento computacional, armazenamento de dados e consumo energético, especialmente em plataformas UAV onde peso e autonomia são fatores críticos.

Esta necessidade de otimização computacional motiva o desenvolvimento de algoritmos eficientes e arquiteturas de processamento especializadas, temas que serão abordados em detalhes nas próximas seções desta dissertação.

2.2 Câmeras Hiperespectrais: Tecnologia e Aplicações

Esta seção apresenta uma análise abrangente das tecnologias de imageamento hiperespectral disponíveis, abordando desde os princípios de funcionamento até as aplicações práticas. O foco está nos sistemas comerciais representativos, suas características técnicas e adequação para diferentes tipos de aplicação, incluindo datasets públicos de referência utilizados para validação e benchmarking. As discussões são embasadas em referências bibliográficas relevantes, fornecendo um panorama atualizado do estado da arte.

2.2.1 Tipos de Sistemas de Imageamento Hiperespectral

Os sistemas de imageamento hiperespectral podem ser categorizados segundo diferentes modos de aquisição, cada um apresentando características específicas quanto à velocidade, qualidade e adequação para diferentes plataformas. Conforme estabelecido na literatura (Al-Ruzouq et al., 2020), os principais modos de aquisição são:

- **Pushbroom (varredura linear):** Captura uma linha completa de pixels simultaneamente, constituindo um cubo band-interleaved-by-line (BIL). É o tipo

mais comum em plataformas aéreas e UAVs devido às características de tamanho compacto, baixo peso, operação simplificada e alta relação sinal/ruído (Al-Ruzouq *et al.*, 2020);

- **Snapshot (imageamento instantâneo):** Adquire toda a informação espacial e espectral em uma única exposição dentro de um único período de integração. Representa uma tecnologia em desenvolvimento que ainda carece de suporte para resoluções espaciais mais altas (Al-Ruzouq *et al.*, 2020).

A seleção do sistema adequado deve considerar os requisitos específicos da aplicação, incluindo resolução espacial e espectral, velocidade de aquisição, portabilidade e condições operacionais da plataforma.

2.2.2 Sensores e Sistemas Comerciais Representativos

O desenvolvimento de sistemas hiperespectrais comerciais tem apresentado avanços significativos nos últimos anos, com diferentes fabricantes oferecendo soluções adaptadas para aplicações específicas em agricultura de precisão, monitoramento ambiental, inspeção industrial e uso embarcado em VANTs. Fabricantes como Specim, Resonon, Cubert e Headwall oferecem soluções comerciais consolidadas para essas aplicações (Zhang *et al.*, 2024). A Tabela 2.2 apresenta uma análise detalhada dos principais sensores e sistemas disponíveis no mercado, suas características técnicas e aplicações práticas.

Conforme estabelecido na classificação apresentada na Subseção 2.2.1, os sistemas hiperespectrais dividem-se em diferentes tecnologias de aquisição. Entre os sistemas do tipo pushbroom, destacam-se o Specim FX10, amplamente empregado em aplicações embarcadas em UAVs devido ao seu baixo peso e alta taxa de aquisição, o Resonon Pika L, reconhecido por sua robustez em monitoramento de vegetação e qualidade da água, e o Headwall Nano-Hyperspec, notável pela adaptabilidade a plataformas compactas (Zhang *et al.*, 2024). No segmento dos sistemas snapshot, que realizam a captura simultânea de toda a cena espectral e espacial, sobressaem o Cubert S185 FirefEYE SE e soluções baseadas em filtros Fabry-Pérot, ambos voltados para aplicações que demandam imageamento instantâneo e portabilidade. A escolha entre esses modelos está diretamente relacionada ao tipo de aplicação, requisitos de portabilidade e necessidades de processamento em tempo real.

Um dos principais desafios no uso desses sistemas é o gerenciamento do alto volume de dados gerados. Os sensores hiperespectrais produzem throughput na faixa de 30 MB/s a 300 MB/s, exigindo interfaces de alta velocidade como USB 3.0, Camera Link ou GigE Vision, além de soluções de armazenamento local com capacidade e velocidade adequadas. Para ilustrar a magnitude desse desafio, sistemas operando em capacidade máxima podem gerar aproximadamente 4,15 TB de dados em 8 horas de operação contínua, ou até 6 GB por minuto quando embarcados em VANTs.

2.3 Técnicas de Processamento de Imagens Hiperespectrais

O processamento de imagens hiperespectrais envolve uma cadeia complexa de algoritmos especializados, desde o pré-processamento básico até técnicas avançadas de análise espectral. Esta seção apresenta as principais abordagens utilizadas na literatura, com

Tabela 2.2: Análise comparativa de sensores hiperespectrais baseada na literatura científica

Sensor/Sistema	Tecnologia de Aquisição	Faixa Espectral	Características Espectrais	Performance Reportada	Referência/Aplicação
Specim FX10	Pushbroom	400–1000 nm (VNIR)	224 bandas espectrais 1024 pixels espaciais	Taxa: até 330 FPS Throughput: 144,375 MB/s	Agricultura UAV Validação em campo (Zhang <i>et al.</i> , 2024)
Resonon Pika L	Pushbroom	400–1000 nm	281 bandas espectrais 900 pixels espaciais 12 bits/pixel	Taxa: 249 FPS Throughput: 94,45 MB/s Com binning 2x: 47,22 MB/s	Aplicações em monitoramento de vegetação e qualidade da água (Al-Ruzouq <i>et al.</i> , 2020)
Resonon PIKA-NIR-320	Pushbroom	900–1700 nm (NIR-SWIR)	164 bandas espectrais 320 pixels espaciais 168 canais totais	Taxa: até 520 Hz Pixel size: 30 μ m Line-scan operation	Detecção de resíduos marinhos flutuantes
Cubert S185 FireflyEYE SE	Snapshot	450–950 nm	125 bandas espectrais 1 MP (1000x1000) 12/14 bits	Taxa: até 25 Hz 5 cubos hiperespectrais/s Throughput: 31,25 MB/s Consumo: 15 W, Peso: 490 g	Monitoramento de saúde vegetal e análise agrícola (Zhang <i>et al.</i> , 2024)
Headwall Nano-Hyperspec	Pushbroom	400–1000 nm	270 bandas espectrais 640 pixels espaciais	Taxa: 300 FPS Throughput: 103,68 MB/s Armazenamento: 480 GB	Pequenas plataformas UAV, excelente adaptabilidade (Al-Ruzouq <i>et al.</i> , 2020)
Sistemas baseados em Filtros Fabry-Pérot	Snapshot (Captura única)	Variável conforme filtros	150+ bandas Filtros sintonizáveis	Performance variável dependente da aplicação	Tecnologia IMEC Imageamento instantâneo

foco nas técnicas que demonstram potencial para implementação em sistemas embarcados, consolidando metodologias validadas em diferentes contextos de aplicação.

2.3.1 Pré-processamento e Correção Radiométrica

O pré-processamento constitui etapa fundamental para garantir a qualidade dos dados hiperespectrais, especialmente em sistemas embarcados operando sob condições variáveis de iluminação e movimento. As operações de pré-processamento resultam em dados corrigidos que permitem comparações entre diferentes séries temporais e até mesmo dados adquiridos por diferentes sensores hiperespectrais. Sistemas embarcados em UAV para detecção de plásticos em ambientes aquáticos demonstram a importância crítica do pré-processamento para manter precisão superior a 90% em condições operacionais desafiadoras (Alboody *et al.*, 2023).

As principais técnicas de pré-processamento incluem:

- **Calibração radiométrica:** Correção das variações de resposta do sensor através de ferramentas de software fornecidas pelos fabricantes de sensores hiperespectrais, que devem georreferenciar e converter cubos de dados DN brutos para radiância. Esta etapa é crítica para garantir a reprodutibilidade e comparabilidade dos dados. Métodos avançados como Empirical Line Method (ELM) demonstram melhorias de 5-55% na precisão radiométrica (Silva; Pereira; Santos, 2024);
- **Correção atmosférica:** Remoção dos efeitos de absorção e espalhamento atmosférico, particularmente crítica em aplicações aéreas. Algoritmos como ATCOR e FLAASH têm sido amplamente validados para esta finalidade;
- **Correção geométrica:** Compensação de distorções geométricas causadas pelo movimento da plataforma e geometria de aquisição, frequentemente combinando dados de orientação externa coletados durante o voo com modelo do sensor e modelo de elevação. Técnicas robustas de correção geométrica são essenciais para aplicações embarcadas em UAV, onde variações de altitude e orientação introduzem distorções significativas (Silva; Pereira; Santos, 2024);
- **Redução de ruído espectral:** Aplicação de filtros adaptativos e técnicas de suavização espectral. A implementação de filtros Savitzky-Golay e técnicas baseadas em transformadas wavelets demonstram eficácia na preservação de características espectrais importantes enquanto reduzem componentes ruidosas;
- **Avaliação da qualidade:** A relação sinal-ruído (SNR) representa critério fundamental para caracterização da qualidade dos dados hiperespectrais, sendo essencial para análise quantitativa precisa. Sistemas comerciais como Specim FX10 e Resonon Pika L oferecem alta qualidade espectral adequada para aplicações exigentes de classificação (Zhang *et al.*, 2024).

2.3.2 Redução Dimensional e Seleção de Bandas

A alta dimensionalidade dos dados hiperespectrais (centenas de bandas espectrais) apresenta desafios computacionais significativos, tornando as técnicas de redução dimensional essenciais para sistemas embarcados. O fenômeno de Hughes, onde o desempenho de classificadores degrada com o aumento da dimensionalidade quando o

número de amostras de treinamento é limitado, torna estas técnicas ainda mais críticas. Implementações otimizadas em FPGA de algoritmos como EMCR (Extreme Learning Machine with Correlation Removal) conseguem redução de 80% dos dados mantendo precisão superior a 99% (Martins *et al.*, 2019).

Técnicas Lineares de Redução Dimensional

- **Principal Component Analysis (PCA):** Técnica linear clássica que projeta os dados em subespaço de menor dimensionalidade preservando máxima variância. O PCA concentra a variância espectral e pode ser combinado com outros métodos como compressão wavelet, conseguindo retenção de 99% da variância original com redução de 80-90% das bandas. Implementações GPU de PCA para compressão hiperespectral conseguem processamento em tempo real em plataformas embarcadas como Jetson TX2 (Díaz *et al.*, 2019);
- **Maximum Noise Fraction (MNF):** Método baseado em PCA que maximiza a relação sinal-ruído, destacado como capaz de alcançar boa performance na redução dimensional de dados hiperespectrais, especialmente eficaz para dados com alta correlação espectral. Aplicações em sistemas PRISMA demonstram eficácia superior a 87% na redução de ruído espectral (Corbari *et al.*, 2023);
- **Independent Component Analysis (ICA):** Decomposição em componentes estatisticamente independentes, adequada para separação de assinaturas espectrais sobrepostas e identificação de endmembers puros.

Métodos de Seleção de Bandas

- **Seleção baseada em entropia:** Algoritmos como EMCR (Entropy Multiple Correlation Ratio) conseguem reduzir 70-80% do processamento mantendo alta precisão de classificação, sendo computacionalmente eficientes para sistemas embarcados;
- **Algoritmos genéticos:** Otimização global para seleção de subconjuntos ótimos de bandas, com validação cruzada para evitar overfitting;
- **Métodos híbridos:** Combinação de técnicas de projeção com seleção de bandas, oferecendo balanceamento entre redução dimensional e preservação de informações discriminantes.

2.3.3 Algoritmos de Classificação Espectral

A classificação espectral representa uma das aplicações mais importantes do processamento hiperespectral, sendo fundamental para identificação e mapeamento de materiais. Frameworks de classificação baseados em características espectral-espaciais superam métodos que utilizam apenas informações espectrais. Sistemas embarcados para detecção de plásticos marinhos demonstram precisão próxima a 90% utilizando abordagens híbridas (Alboody *et al.*, 2023), enquanto implementações FPGA de SVM alcançam 99,7% de precisão com latência de 0,1ms por pixel (Martins *et al.*, 2019).

Métodos Clássicos de Classificação

- **Support Vector Machines (SVM):** Classificadores robustos que demonstram excelente desempenho em dados hiperespectrais, com implementações otimizadas conseguindo precisões superiores a 95% em datasets de referência. A eficácia do SVM está relacionada à sua capacidade de lidar com alta dimensionalidade e pequenos conjuntos de treinamento. Implementações em FPGA conseguem classificação em tempo real com latência de 0,1ms por pixel e precisão de 99,7% em datasets AVIRIS (Martins *et al.*, 2019);
- **Random Forest:** Métodos ensemble que combinam múltiplas árvores de decisão, oferecendo boa interpretabilidade e robustez a outliers, com tempos de treinamento significativamente menores que SVM;
- **Spectral Angle Mapper (SAM):** Classificação baseada em similaridade angular entre espectros, computacionalmente eficiente para implementações embarcadas e menos sensível a variações de iluminação.

Abordagens de Aprendizado Profundo

- **Redes Neurais Convolucionais (CNN):** Algoritmos discriminantes para características espectrais e CNNs para características espaciais formam frameworks de desempenho superior. Arquiteturas como ResNet e DenseNet adaptadas para dados hiperespectrais conseguem F1-scores superiores a 0,95. Implementações de CNNs leves para sistemas embarcados conseguem F1-scores superiores a 94% com arquiteturas otimizadas de baixa complexidade computacional (Takahashi; Yamamoto; Suzuki, 2025);
- **Redes residuais spectral-espaciais:** Frameworks de aprendizado profundo supervisionado capazes de discriminar características de assinaturas espectrais abundantes e contextos espaciais sem necessidade de engenharia manual de características. Abordagens baseadas em CNN para detecção de anomalias superam métodos clássicos como RX, conseguindo taxas de detecção superiores a 90% (Alboody *et al.*, 2023);
- **Arquiteturas leves:** Desenvolvimento de redes neurais compactas adequadas para sistemas embarcados, como MobileNets e EfficientNets adaptadas, conseguindo redução de 90% nos parâmetros mantendo alta precisão. Arquiteturas depth-wise conseguem eficiência computacional superior com redução significativa de parâmetros, adequadas para implementação em sistemas com restrições de memória (Takahashi; Yamamoto; Suzuki, 2025);
- **Abordagens híbridas:** Fusão de perfis de atributos com aprendizado profundo, onde técnicas de perfilamento combinadas com CNN demonstram resultados superiores ao uso individual de cada abordagem (Adão *et al.*, 2017).

2.3.4 Processamento de Sinais Espectrais Avançado

O processamento específico dos sinais espectrais envolve técnicas matemáticas especializadas para extração de informações dos dados hiperespectrais, incluindo métodos de análise no domínio da frequência e detecção de anomalias.

Análise Espectral no Domínio da Frequência

- **Transformadas Wavelet:** Aplicação de wavelets como Daubechies, Morlet e Biorthogonal para análise tempo-frequência de sinais espectrais. A escolha da wavelet-mãe deve considerar as características morfológicas do sinal, garantindo máxima correlação e preservação das informações espectrais relevantes;
- **Análise de derivadas espectrais:** Cálculo de derivadas primeira e segunda dos espectros para realçar características espectrais sutis e reduzir efeitos de variações de linha de base. Técnicas como continuum removal são amplamente utilizadas em aplicações geológicas;
- **Transformadas de Fourier:** Análise no domínio da frequência para identificação de periodicidades espectrais e caracterização de ruídos sistemáticos.

Detecção de Anomalias e Alvos Específicos

- **Detecção baseada em CNN:** Para detecção de anomalias, redes neurais convolucionais demonstram superar métodos clássicos como abordagens baseadas em RX, conseguindo taxas de detecção superiores a 90% com baixas taxas de falsos positivos. Aplicações práticas em detecção de plásticos marinhos validam a eficácia desta abordagem em condições reais (Corbari *et al.*, 2023);
- **Algoritmos RX adaptivos:** Implementações otimizadas do detector RX com janelas adaptativas e processamento local, adequadas para detecção em tempo real;
- **Análise de mistura espectral:** Decomposição de pixels mistos em endmembers puros através de técnicas como Linear Spectral Unmixing e Non-negative Matrix Factorization, fundamental para mapeamento quantitativo de materiais;
- **Seleção de saliência:** Abordagens de classificação manifold estendidas para aprendizado profundo, apresentadas para detecção de saliência em relação à seleção de bandas em imagens hiperespectrais. Técnicas de fusão espacial-espectral com mecanismos de atenção demonstram eficácia superior na identificação de características salientes (Zhang *et al.*, 2024).

2.3.5 Considerações para Implementação Embarcada

A implementação de técnicas de processamento hiperespectral em sistemas embarcados requer considerações específicas quanto à eficiência computacional e restrições de recursos.

- **Otimização algorítmica:** Desenvolvimento de implementações paralelas e uso de operações matriciais otimizadas (BLAS, cuBLAS) para maximizar o throughput de processamento;
- **Arquiteturas heterogêneas:** Combinação de CPU, GPU e FPGA para otimização simultânea de desempenho e consumo energético. Sistemas CPU+FPGA conseguem melhorias significativas na eficiência energética, conforme demonstrado em implementações de compressão hiperespectral (Hwang; Choi, S.; Chang, 2011). Arquiteturas tri-híbridas CPU+GPU+FPGA oferecem especialização por estágio de processamento (Sahovic; Quinten, 2025);

- **Processamento em pipeline:** Implementação de pipelines de processamento que permitem operação contínua com baixa latência, essencial para aplicações de tempo real;
- **Compressão de dados:** Técnicas de compressão específicas para dados hiperespectrais, como JPEG2000 e compressão baseada em PCA, conseguindo taxas de compressão de 10:1 a 50:1 sem perda significativa de informação.

Em síntese, as técnicas de processamento de imagens hiperespectrais abrangem desde métodos fundamentais de pré-processamento até algoritmos avançados de aprendizado profundo. A escolha da técnica adequada depende da aplicação específica, recursos computacionais disponíveis e requisitos de precisão. A tendência atual aponta para abordagens híbridas que combinam múltiplas técnicas e arquiteturas heterogêneas que otimizam o balanceamento entre precisão, velocidade e eficiência energética (Adão *et al.*, 2017).

2.4 Tipos de Processadores para Processamento Hiperespectral

A escolha adequada do tipo de processador é fundamental para o desenvolvimento de sistemas hiperespectrais embarcados eficientes. Esta seção analisa as características, vantagens e limitações dos principais tipos de processadores utilizados para processamento hiperespectral, considerando aspectos como desempenho computacional, consumo energético e adequação para diferentes tipos de algoritmos.

2.4.1 Processadores de Uso Geral (CPU)

As CPUs permanecem como componente central em sistemas hiperespectrais embarcados, especialmente adequadas para tarefas sequenciais e de controle. Conforme destacado por Vaithianathan (2025), as CPUs são projetadas para tarefas de propósito geral e se destacam no processamento sequencial, tornando-as ideais para aplicações que requerem alto desempenho em single-thread:

- **Arquiteturas ARM:** Processadores de baixo consumo como ARM Cortex-A series, amplamente utilizados em plataformas embarcadas devido ao excelente balanço desempenho/consumo. Martins et al. (2019) demonstraram a eficácia de processadores ARM operando a 800 MHz para processamento hiperespectral, com tempo de processamento de 0,75ms em implementações otimizadas
- **Arquiteturas x86:** Intel Atom e AMD embedded, oferecendo maior poder computacional com consumo moderado para aplicações que requerem compatibilidade com software legado. Sahovic e Quinten (2025) utilizaram Intel Core i9-9900K para coordenação de sistemas híbridos, demonstrando a importância das CPUs no gerenciamento de I/O e execução de lógica sequencial
- **Características para processamento hiperespectral:** Adequadas para tarefas de controle de fluxo, pré-processamento sequencial e algoritmos de classificação final. A arquitetura interna das CPUs, composta por unidades de controle que orquestram a execução de instruções, permite gerenciamento eficiente de pipelines complexos (Vaithianathan, 2025)

- **Limitações:** Baixo throughput para operações matriciais massivamente paralelas características do processamento hiperespectral. Estudos comparativos demonstram que CPUs apresentam desempenho até 27 vezes inferior aos FPGAs em tarefas de processamento digital de sinais

2.4.2 Unidades de Processamento Gráfico (GPU)

As GPUs se destacam no processamento hiperespectral devido à natureza paralelizável das operações matriciais. Segundo Vaithianathan (2025), as GPUs são otimizadas para processamento paralelo, permitindo o manuseio de milhares de threads simultaneamente, característica particularmente benéfica para processamento de imagens e deep learning:

- **GPUs embarcadas NVIDIA:** Jetson series (Nano, TX2, Xavier, Orin) que combinam GPUs com CPUs ARM em single-board computers de baixo consumo. Sahovic e Quinten (2025) implementaram com sucesso sistemas utilizando NVIDIA Quadro RTX 5000 para tarefas computacionalmente exigentes, incluindo cálculos baseados em FFT e correlação cruzada
- **Arquiteturas CUDA:** Milhares de cores especializados em operações de ponto flutuante, ideais para álgebra linear e operações matriciais. A arquitetura GPU é composta por múltiplos Streaming Multiprocessors (SMs), cada um contendo numerosas unidades funcionais capazes de executar operações paralelas (Vaithianathan, 2025)
- **Performance em processamento hiperespectral:** Demonstram bom desempenho em compressão hiperespectral em plataformas embarcadas como Jetson TX2 e excelente capacidade para CNNs de classificação. As GPUs exploram paralelismo em nível de dados através de milhares de cores, tornando-as adequadas para processamento em lote e aplicações de alto throughput (Arucu; Iliev, 2025)
- **Consumo energético:** Faixa de 5-20W para modelos embarcados, adequado para aplicações UAV com restrições energéticas. Michon et al. (2025) destacam que, apesar do alto poder computacional, o consumo energético e a latência no acesso à memória podem ser fatores limitantes

2.4.3 Field-Programmable Gate Arrays (FPGA)

Os FPGAs oferecem a máxima flexibilidade para implementação de algoritmos hiperespectrais otimizados. Como ressaltado na análise comparativa de Arucu e Iliev (2025), os FPGAs demonstram desempenho significativamente superior, sendo 27 vezes mais rápidos que CPUs e 2 vezes mais rápidos que GPUs, consumindo simultaneamente menos energia:

- **Paralelismo customizado:** Capacidade de implementar arquiteturas de processamento específicas para algoritmos hiperespectrais, como pipelines de seleção de bandas e classificação SVM. Martins et al. (2019) demonstraram implementações FPGA de classificadores SVM com precisão acima de 99%, atendendo aos requisitos de tempo real do AVIRIS

- **Eficiência energética:** Implementações otimizadas podem atingir melhorias energéticas significativas comparado a implementações em software através de codesign HW/SW. Os FPGAs são circuitos semicondutores programáveis compostos por blocos lógicos customizáveis conectados por interconexões programáveis (Vaithianathan, 2025)
- **Latência ultra-baixa:** Tempo de classificação de 0,1ms/pixel em implementações otimizadas de SVM com seleção EMCR. Martins et al. (2019) reportaram tempo de classificação de 0,50ms para implementação single-core e 0,10ms para design hexa-core, consumindo respectivamente 17% e 100% dos blocos DSP disponíveis
- **Adequação para pré-processamento:** Ideais para implementação de filtros, correções geométricas e operações de pipeline de baixa latência. Michon et al. (2025) enfatizam que a natureza reconfigurável dos FPGAs permite otimização máxima adaptada a aplicações específicas, com níveis adaptáveis de paralelização e pipeline

2.5 Arquiteturas Heterogêneas de Processamento

As arquiteturas heterogêneas combinam diferentes tipos de processadores para otimizar simultaneamente desempenho, consumo energético e latência. Esta abordagem é particularmente relevante para processamento hiperespectral embarcado, onde diferentes estágios do pipeline computacional se beneficiam de tipos distintos de processadores.

2.5.1 Fundamentos de Computação Heterogênea

A computação heterogênea baseia-se no princípio de que diferentes tipos de processadores possuem eficiências variáveis para diferentes tipos de cargas computacionais. Segundo Vaithianathan (2025), a integração visa aproveitar os pontos fortes únicos de cada arquitetura, melhorando a eficiência computacional e o desempenho em vários domínios:

- **Especialização de processadores:** Cada tipo de processador (CPU, GPU, FPGA, DSP) apresenta vantagens específicas para determinados tipos de operações. Sahovic e Quinten (2025) demonstram explicitamente como FPGAs destacam-se em aquisição rápida de dados, CPUs em coordenação de sistema, e GPUs em computação massivamente paralela
- **Particionamento de algoritmos:** Divisão do pipeline de processamento em estágios adequados para cada tipo de processador. A alocação estratégica de tarefas de acordo com os pontos fortes de cada componente de hardware atende às demandas computacionais e de tempo real essenciais para monitoramento de fluxo multifásico (Sahovic; Quinten, 2025)
- **Otimização multi-objetivo:** Balanceamento simultâneo entre desempenho, consumo energético, latência e precisão. Vaithianathan (2025) destaca que a alocação dinâmica de tarefas para a unidade de processamento mais adequada otimiza a utilização de recursos e minimiza a latência

- **Codesign HW/SW:** Metodologia integrada de desenvolvimento que considera hardware e software simultaneamente. O codesign hardware- software enfatiza o desenvolvimento simultâneo de componentes de hardware e software para alcançar desempenho e eficiência ideais (Vaithianathan, 2025)

Tendências Futuras em Computação Heterogênea

Vaithianathan (2025) identifica direções emergentes que moldarão o futuro da computação heterogênea, com implicações diretas para processamento hiperspectral embarcado:

- **Aceleradores específicos para IA:** A integração de Neural Processing Units (NPUs) e Application-Specific Integrated Circuits (ASICs) oferece eficiência energética 5-10x superior para inferência de IA comparado a GPUs genéricas. Google TPUv4 demonstra 420 TFLOPS em operações de machine learning, enquanto NPUs móveis alcançam 15-45 TOPS com consumo inferior a 5W
- **Heterogeneidade hierárquica:** Evolução para sistemas que utilizam múltiplas arquiteturas não apenas dentro de um único nó, mas também através de sistemas distribuídos. Esta abordagem permite combinação de diferentes processadores otimizados para tarefas específicas em múltiplas camadas do sistema
- **Arquiteturas de memória unificada:** Tecnologias como AMD Heterogeneous System Architecture (HSA) e NVIDIA Grace Hopper (900GB/s de largura de banda CPU-GPU) reduzem 40-60% da latência de transferência de dados, simplificando significativamente o modelo de programação
- **Frameworks de programação unificados:** Desenvolvimento de abstrações de alto nível que simplificam a programação cross-platform, permitindo que desenvolvedores escrevam código uma vez e executem em múltiplas configurações de hardware sem modificações extensivas
- **Alocação autônoma de recursos:** Sistemas orientados por IA que analisam métricas de performance em tempo real e ajustam alocação de recursos dinamicamente, otimizando utilização e minimizando latência sem intervenção manual

2.5.2 Arquiteturas CPU+GPU Integradas

A combinação de CPU e GPU em sistemas embarcados oferece flexibilidade e desempenho para processamento hiperspectral. Vaithianathan (2025) ressalta que arquiteturas de memória unificada facilitam o compartilhamento contínuo de dados entre CPUs e GPUs, reduzindo overhead e melhorando a velocidade computacional:

- **SoCs ARM+GPU:** Sistemas como NVIDIA Jetson que integram CPUs ARM com GPUs CUDA em single-package solutions. A tendência em direção a designs System on Chip (SoC) permite a integração de múltiplos tipos de processadores dentro de um único chip, aprimorando ainda mais o desempenho em ambientes compactos (Vaithianathan, 2025)

- **Divisão de tarefas:** CPU responsável por controle, pré-processamento sequencial e classificação final; GPU para operações matriciais, filtragem e redes neurais. O controlador DMA atua como ponte entre CPU e GPU, facilitando transferência contínua de dados entre memória host e memória global da GPU (Vaithianathan, 2025)
- **Comunicação eficiente:** Memória compartilhada e interfaces de alta velocidade para minimizar overhead de transferência de dados. Tecnologias como AMD's Heterogeneous System Architecture (HSA) exemplificam esta tendência ao permitir acesso de memória compartilhada através de várias unidades de processamento (Vaithianathan, 2025)
- **Performance demonstrada:** Throughput >330 fps em compressão hiperespectral com consumo <20W. Estudos demonstram que GPUs fornecem forte capacidade paralela mas encontram ineficiências de transferência de dados (Sahovic; Quinten, 2025)

2.5.3 Sistemas CPU+FPGA

A combinação CPU+FPGA oferece máxima flexibilidade para otimização de algoritmos específicos. Martins et al. (2019) demonstraram implementações bem-sucedidas de aceleradores de hardware para classificação de imagens hiperespectrais em tempo real usando esta abordagem:

- **Aceleração customizada:** FPGA implementa algoritmos críticos como seleção de bandas EMCR e classificação SVM otimizada. A metodologia EMCR (Entropy and Mean Correlation Ratio) aumentou consideravelmente o poder de predição, alcançando níveis de precisão superiores a 99% (Martins *et al.*, 2019)
- **Pipeline de baixa latência:** Processamento contínuo com latência determinística, adequado para aplicações de tempo real. FPGAs garantem baixo nível de latência contra GPUs e CPUs, pois trabalham em bare metal sem sistema operacional.
- **Eficiência energética:** Melhorias de até 43,5x no consumo energético através de codesign otimizado. A natureza reconfigurável dos FPGAs permite maximização da otimização adaptada a aplicações específicas
- **Flexibilidade de reconfiguração:** Capacidade de adaptar o hardware para diferentes algoritmos e requisitos de aplicação. Ao contrário de CPUs e GPUs, que são arquiteturas fixas programáveis por software, FPGAs são reconfiguráveis com engines computacionais definidos pelo usuário

2.5.4 Processamento Digital de Sinais em Sistemas Heterogêneos

O processamento digital de sinais (DSP) constitui um componente fundamental em sistemas hiperespectrais, especialmente para operações de filtragem, correção e pré-processamento. Arucu e Iliev (2025) apresentam uma avaliação quantitativa rigorosa de plataformas heterogêneas para implementação de filtros FIR (Finite Impulse Response), oferecendo insights cruciais sobre trade-offs de performance e eficiência energética:

Filtros FIR em Processamento Hiperespectral

Os filtros FIR desempenham papel essencial no pipeline de processamento hiperespectral, sendo utilizados para correção radiométrica, seleção de bandas espectrais e redução de ruído:

- **Performance comparativa quantificada:** Implementação de filtro FIR Kaiser (27 taps, $\beta=5.65$) demonstra superioridade clara do FPGA com tempo de processamento de 0.004s, comparado a 0.008s da GPU e 0.107s da CPU. O FPGA alcança aceleração de $27\times$ versus CPU e $2\times$ versus GPU (Arucu; Iliev, 2025)
- **Eficiência energética excepcional:** FPGA consome apenas 135mW para lógica do filtro FIR, atingindo 185 GOPS/W (Giga Operations Per Second por Watt), significativamente superior à GPU (0.27 GOPS/W) e CPU (4.7 GOPS/W). Esta eficiência é crucial para sistemas embarcados com restrições energéticas
- **Latência determinística:** FPGAs oferecem processamento com latência ultra-baixa (4ms) e comportamento determinístico, essencial para aplicações de tempo real. A implementação paralela em nível de hardware através de blocos lógicos configuráveis elimina overhead de sistema operacional (Arucu; Iliev, 2025)
- **Aplicações específicas:** Filtros passa-baixa para redução de ruído térmico, filtros passa-banda para isolamento de bandas espectrais específicas, e filtros anti-aliasing para decimação controlada de dados hiperespectrais

Implementação Multi-plataforma de Algoritmos DSP

A análise comparativa de Arucu e Iliev (2025) revela características distintas de cada plataforma para processamento digital de sinais:

- **FPGA - Otimização dedicada:** Implementação usando ZYNQ XC7Z020 com VIVADO HLX suite demonstra paralelismo espacial nativo, permitindo múltiplos filtros simultâneos. Temperatura de junção de 41.5°C com margem térmica de 43.5°C confirma operação segura em ambientes embarcados
- **GPU - Throughput massivo:** Tesla K80 com framework CUDA oferece paralelismo temporal através de milhares de threads, adequado para processamento simultâneo de múltiplas bandas espectrais. Consumo estimado de 50-100W limita aplicação a sistemas com fonte de energia robusta
- **CPU - Flexibilidade e controle:** ARM Cortex-A9 com Python/NumPy/SciPy fornece ambiente de desenvolvimento ágil e debugging simplificado, ideal para prototipagem e algoritmos adaptativos. Performance limitada ($27\times$ mais lenta que FPGA) restringe uso a tarefas de controle
- **Metodologia experimental:** Filtro Kaiser com banda passante 0-5MHz, banda de parada 10-50MHz, frequência de amostragem 100MHz, validado com sinal complexo multi-componente para garantir robustez da implementação (Arucu; Iliev, 2025)

2.5.5 Arquiteturas Tri-híbridas CPU+GPU+FPGA

A integração de três tipos de processadores permite otimização máxima do pipeline hiperespectral. Sahovic e Quinten (2025) propuseram uma arquitetura computacional híbrida combinando componentes FPGA, CPU e GPU para superar limitações individuais:

- **Especialização por estágio:** FPGA para pré-processamento e seleção de bandas; GPU para reconstrução e operações matriciais; CPU para classificação final e controle. Inicialmente, um FPGA Xilinx Spartan-7 integrado realiza aquisição rápida de dados, filtragem de ruído e serialização estruturada. Subsequentemente, a CPU gerencia sincronização de dados e gerenciamento de memória. A GPU então aproveita seus milhares de cores paralelos para executar eficientemente operações computacionalmente intensivas (Sahovic; Quinten, 2025)
- **Balanceamento de carga:** Distribuição dinâmica de tarefas conforme disponibilidade de recursos e características dos dados. A atribuição estratégica de tarefas de acordo com os pontos fortes de cada componente de hardware garante precisão e desempenho confiável em tempo real (Sahovic; Quinten, 2025)
- **Metas quantitativas:** Potencial para atingir >30 fps em imagens $614 \times 512 \times 224$ com consumo $<15W$ e latência $<40ms$. Vaithianathan (2025) antecipa uma mudança em direção a sistemas de computação heterogênea hierárquica que utilizarão múltiplas arquiteturas não apenas dentro de um único nó, mas também através de sistemas distribuídos
- **Complexidade de implementação:** Requer metodologias avançadas de codesign e otimização multi-dimensional. O desenvolvimento de frameworks de programação unificados que simplificam o desenvolvimento e melhoram a interoperabilidade entre diferentes componentes de hardware é crucial para maximizar o potencial de sistemas de computação heterogênea (Vaithianathan, 2025)

2.5.6 Desafios e Soluções em Computação Heterogênea

A implementação de sistemas heterogêneos para processamento hiperespectral embarcado enfrenta desafios significativos que requerem soluções inovadoras. Vaithianathan (2025) identifica cinco categorias principais de desafios e suas respectivas estratégias de mitigação:

Consumo de Energia e Eficiência

O balanceamento entre performance e consumo energético constitui um dos principais desafios em sistemas heterogêneos embarcados:

- **Gerenciamento dinâmico de energia:** Implementação de Dynamic Voltage and Frequency Scaling (DVFS) permite ajuste das condições operacionais baseado na demanda de workload, reduzindo consumo durante períodos de baixa utilização
- **Algoritmos de scheduling térmico:** Coordenação harmoniosa entre processadores considerando temperatura operacional para prevenir thermal throttling e estender vida útil do hardware

- **Otimização de alocação:** GPUs oferecem performance superior para tarefas paralelas mas consomem 300-700W em configurações de alto desempenho, enquanto FPGAs demonstram eficiência energética 2-10x superior para workloads específicos com consumo de 10-50W

Complexidade de Programação

A diversidade de modelos de programação representa um obstáculo significativo para desenvolvedores:

- **Modelos heterogêneos:** GPUs utilizam CUDA/OpenCL para programação paralela, CPUs empregam OpenMP/threads para multi-threading, e FPGAs requerem HDL/HLS, necessitando expertise em múltiplas tecnologias
- **Frameworks unificados:** TensorFlow e PyTorch fornecem abstrações que ocultam especificidades de hardware, permitindo código único para múltiplas configurações, embora com trade-offs em capacidades de otimização
- **Debugging cross-platform:** Bugs manifestam-se diferentemente em cada processador, requerendo ferramentas integradas para análise abrangente de sistemas heterogêneos

Escalabilidade e Interoperabilidade

A integração eficiente de múltiplos tipos de processadores apresenta desafios de coordenação e comunicação:

- **Load balancing inteligente:** Algoritmos sofisticados de scheduling baseados em métricas de performance em tempo real previnem sobrecarga de processadores específicos e maximizam throughput geral
- **Padronização de interfaces:** APIs unificadas e protocolos de comunicação comuns facilitam interoperabilidade entre processadores com diferentes Instruction Set Architectures (ISAs)
- **Tecnologias de interconexão:** PCIe e Compute Express Link (CXL) oferecem comunicação de alta velocidade e acesso coerente à memória, reduzindo latência e melhorando eficiência do sistema

2.5.7 Aplicações em Tempo Real e Simulação Multi-taxa

As arquiteturas heterogêneas demonstram particular eficácia em aplicações de simulação em tempo real que demandam diferentes escalas temporais e níveis de fidelidade computacional. Zou et al. (2025) apresentam uma implementação inovadora de simulação EMT (Electromagnetic Transient) multi-taxa em arquitetura CPU-GPU-FPGA, oferecendo insights valiosos sobre particionamento sinérgico de problemas computacionais complexos:

Particionamento Temporal e Espacial

A estratégia de particionamento sinérgico permite otimização simultânea de fidelidade e performance através da especialização de cada processador:

- **CPU - Simulação de rede principal:** Responsável pela simulação da rede elétrica principal utilizando time-steps maiores, adequados para fenômenos de baixa frequência. Esta abordagem permite manutenção da estabilidade numérica global enquanto reduz overhead computacional para componentes menos críticos (Zou *et al.*, 2025)
- **FPGA - Modelagem de alta fidelidade:** Executa modelos detalhados de conversores eletrônicos de potência com resolução sub-microsegundo, capturando transientes rápidos essenciais para análise precisa. A implementação em hardware dedicado garante determinismo temporal e latência ultra-baixa
- **GPU - Aceleração de álgebra linear:** Acelera operações computacionalmente intensivas como fatoração LU da matriz de admitância após mudanças topológicas, aproveitando paralelismo massivo para reduzir significativamente o tempo de recálculo (Zou *et al.*, 2025)
- **Comunicação assíncrona:** Implementação de mecanismos de comunicação assíncrona entre processadores permite operação simultânea sem bloqueios, maximizando utilização de recursos e mantendo sincronização temporal adequada

Otimizações Algorítmicas para Sistemas Heterogêneos

A implementação de Zou *et al.* (2025) demonstra técnicas avançadas de otimização específicas para arquiteturas heterogêneas:

- **Pré-ordenação AMD:** Utilização de Approximate Minimum Degree ordering para confinar mudanças topológicas, reduzindo significativamente o overhead computacional. Apenas submatrizes L'BB e U'BB necessitam recálculo após mudanças, mantendo LAA, LBA, UAA e UAB inalteradas
- **Discretização otimizada:** Aplicação da regra trapezoidal de integração com modelagem específica para disjuntores, onde estado fechado equivale a indutor em série com resistor e estado aberto a capacitor em série com resistor (Zou *et al.*, 2025)
- **Escalas temporais adaptativas:** Diferentes componentes do sistema executam em suas escalas temporais físicas ótimas, com conversores operando em resolução sub-microsegundo no FPGA enquanto a rede principal utiliza time-steps maiores no CPU
- **Validação HIL:** A arquitetura oferece solução escalável para análise Hardware-in-the-Loop (HIL) de sistemas modernos, demonstrando co-simulação multi-taxa efetiva com manutenção de fidelidade crítica (Zou *et al.*, 2025)

Trade-offs Fundamentais em Simulação Tempo Real

A análise de Zou et al. (2025) revela trade-offs fundamentais que são diretamente aplicáveis ao processamento hiperspectral embarcado:

- **Fidelidade versus escala computacional:** O trade-off fundamental entre fidelidade de simulação e escala computacional demonstra que aplicar time-steps pequenos em toda uma rede de grande escala é computacionalmente intratável para atender restrições de tempo real. Esta limitação é análoga ao processamento hiperspectral, onde resolução espectral completa pode ser computacionalmente proibitiva
- **Limitações de recursos on-chip:** Arquiteturas CPU-FPGA enfrentam recursos limitados on-chip e complexidade de desenvolvimento, restringindo escalabilidade para processar sistemas completos. No contexto hiperspectral, isso se traduz em limitações para processar cubos de dados completos em FPGAs de capacidade limitada (Zou *et al.*, 2025)
- **Gargalos de comunicação:** Arquiteturas CPU-GPU apresentam gargalo de performance devido à largura de banda de comunicação e overhead de sincronização, necessitando time-steps maiores que sacrificam fidelidade. Para processamento hiperspectral, isso implica em trade-offs entre throughput e latência de transferência de dados
- **Aproximações de engenharia:** Simplificações necessárias para garantir estabilidade numérica (como a aproximação na modelagem de disjuntores) representam compromissos entre realismo físico e viabilidade computacional, princípio aplicável a algoritmos de compressão e reconstrução hiperspectral (Zou *et al.*, 2025)

Aplicabilidade ao Processamento Hiperspectral

Os princípios de particionamento sinérgico e simulação multi-taxa demonstrados por Zou et al. (2025) oferecem insights diretos para otimização de sistemas hiperspectrais embarcados:

- **Particionamento por resolução temporal:** Assim como conversores eletrônicos requerem resolução sub-microsegundo enquanto a rede principal opera com time-steps maiores, diferentes estágios do processamento hiperspectral podem operar em escalas temporais distintas - correção radiométrica em tempo real no FPGA, processamento de bandas espectrais na GPU, e classificação adaptativa na CPU
- **Comunicação assíncrona otimizada:** Os mecanismos de comunicação assíncrona entre CPU-GPU-FPGA demonstrados na simulação EMT são diretamente aplicáveis ao pipeline hiperspectral, permitindo processamento contínuo sem bloqueios entre estágios de correção, compressão e classificação
- **Otimização matricial especializada:** As técnicas de fatoração LU otimizada para mudanças topológicas podem ser adaptadas para operações matriciais em processamento hiperspectral, como decomposições espectrais e transformações de bandas, aproveitando paralelismo massivo da GPU (Zou *et al.*, 2025)

- **Validação de arquitetura tri-híbrida:** A demonstração bem-sucedida de co-simulação multi-taxa em arquitetura CPU-GPU-FPGA valida a viabilidade da abordagem tri-híbrida proposta para processamento hiperespectral, confirmando que diferentes processadores podem operar simultaneamente em suas especialidades ótimas

Capítulo 3

Metodologia

Este capítulo apresenta a metodologia para investigação comparativa de técnicas de processamento de imagens hiperespectrais em arquiteturas heterogêneas. A abordagem estrutura-se em oito seções: considerações iniciais, estratégia de investigação, procedimentos de investigação, estudo comparativo de arquiteturas FPGA e GPU, protocolo de simulação e benchmarking, metodologia de síntese arquitetural, planejamento de execução, e considerações finais. A metodologia privilegia análise teórica e simulada sobre implementação física, justificada pela necessidade de comparação entre abordagens tecnológicas e pela complexidade de validação experimental em múltiplas plataformas heterogêneas.

3.1 Considerações Iniciais

A metodologia baseou-se na análise do levantamento bibliográfico apresentado no Capítulo 2, que revelou lacunas na literatura sobre sistemas integrados de processamento hiperespectral. A revisão identificou que apenas parte dos trabalhos abordam sistemas completos integrados. Esta constatação direcionou a pesquisa para abordagem comparativa, priorizando investigação teórica e simulada sobre implementação física de protótipos.

A pesquisa comparativa fundamenta-se em três aspectos. Primeiro, a análise das abordagens tecnológicas disponíveis, considerando que trabalhos como Díaz *et al.* (2019) demonstram processamento de mais de 330 frames por segundo em GPU embarcada NVIDIA Jetson TX2 com algoritmo HyperLCA para compressão hiperespectral, enquanto Hwang, Seungho Choi e Chang (2011) propõe metodologia de design consciente de energia para compressão de imagens hiperespectrais, evidenciando diversidade de soluções e ausência de critérios unificados de comparação. Segundo, a complexidade de implementar e validar múltiplas arquiteturas heterogêneas em ambiente experimental, considerando que cada plataforma (FPGA Xilinx, GPU NVIDIA, processadores ARM) requer ferramentas específicas, licenças proprietárias e expertise técnica. Terceiro, a contribuição reside na proposição de framework teórico unificado para comparação e seleção de técnicas, preenchendo lacuna metodológica na literatura.

A priorização da análise teórica e simulada baseia-se na natureza exploratória da pesquisa. A investigação visa estabelecer critérios comparativos entre abordagens arquiteturais, identificar trade-offs entre performance, consumo energético e precisão, e propor metodologia para seleção de técnicas para diferentes cenários de aplicação. Estes objetivos são alcançados através de modelagem matemática, simulação e análise

comparativa ao invés de implementação física limitada a configurações específicas de hardware.

3.2 Abordagem Metodológica

A estratégia de pesquisa baseia-se em abordagem exploratória-comparativa com ênfase quantitativa para investigar técnicas e arquiteturas disponíveis para processamento de imagens hiperespectrais. Esta seção apresenta a caracterização da pesquisa, a estratégia de investigação comparativa e a delimitação do escopo tecnológico.

3.2.1 Caracterização da Pesquisa

A pesquisa caracteriza-se como exploratória-comparativa, baseada em simulação e modelagem teórica. O caráter exploratório justifica-se pela ausência de estudos que comparem arquiteturas heterogêneas para processamento hiperespectral, conforme evidenciado no levantamento bibliográfico. A dimensão comparativa emerge da necessidade de estabelecer critérios para avaliação de técnicas e arquiteturas, permitindo identificação de soluções para diferentes cenários de aplicação.

A abordagem quantitativa baseia-se em análise de desempenho teórico e modelado, utilizando métricas padronizadas para comparação entre técnicas. Os parâmetros incluem throughput (frames por segundo), latência (milissegundos por frame), consumo energético (watts), utilização de recursos (percentual de DSPs, BRAMs, LUTs), precisão de classificação (accuracy, F1-score) e eficiência computacional (operações por segundo por watt). A abordagem quantitativa permite comparação entre trabalhos que utilizam métricas diferentes ou cenários experimentais distintos.

O benchmarking de técnicas e arquiteturas constitui elemento central da metodologia, estabelecendo conjunto de testes e métricas para avaliação comparativa. Os benchmarks incluem datasets de referência (AVIRIS Indian Pines, Pavia University, Salinas Valley), cargas de trabalho de aplicações reais, e protocolos de medição que consideram variabilidade temporal e condições operacionais. Esta padronização permite comparação entre trabalhos da literatura e validação dos resultados teóricos propostos.

3.2.2 Estratégia de Investigação Comparativa

A metodologia de comparação estrutura-se em quatro etapas: mapeamento das técnicas disponíveis, catalogação de características e performance, análise comparativa baseada em critérios objetivos, e síntese de recomendações para diferentes cenários de aplicação. A metodologia de comparação garante cobertura do espaço de soluções e identificação de lacunas ou oportunidades de otimização.

Os critérios de seleção de técnicas e modelos baseiam-se em relevância para aplicações embarcadas, disponibilidade de dados de performance, representatividade no estado da arte, e potencial de integração em arquiteturas heterogêneas. Técnicas que atendem estes critérios são priorizadas para análise, enquanto abordagens com limitações ou dados insuficientes são documentadas mas não incluídas na comparação quantitativa.

O framework de avaliação de desempenho estabelece métricas e protocolos de medição que permitem comparação entre abordagens. As métricas incluem indicadores de performance (throughput, latência), eficiência (consumo energético, utilização de recursos), qualidade (precisão, robustez) e escalabilidade (suporte a diferentes resoluções

e bandas espectrais). Os protocolos especificam condições experimentais, datasets de teste, e procedimentos de medição que garantem reprodutibilidade e comparabilidade dos resultados.

A análise multi-critério para otimização utiliza técnicas de tomada de decisão que consideram múltiplos objetivos conflitantes. A metodologia AHP (Analytic Hierarchy Process) é empregada para ponderação de critérios segundo cenários de aplicação, enquanto análise de Pareto identifica soluções não-dominadas no espaço de trade-offs. A análise multi-critério permite identificação de configurações para diferentes requisitos operacionais.

3.2.3 Delimitação do Escopo Tecnológico

O escopo tecnológico concentra-se em FPGA Xilinx das famílias Zynq e UltraScale+, justificado pela adoção em aplicações de processamento de sinais e disponibilidade de ferramentas de desenvolvimento. A escolha por FPGA Xilinx baseia-se na análise da literatura que demonstra uso desta plataforma em trabalhos de processamento hiperespectral embarcado, com destaque para Hwang, Seungho Choi e Chang (2011) que propõe metodologia de design consciente de energia para compressão de imagens hiperespectrais, e Arucu e Iliev (2025) que apresenta estudo comparativo sobre eficiência energética em processamento hiperespectral acelerado por FPGA.

As GPU embarcadas incluem plataformas NVIDIA Jetson (TX2, Xavier, Orin) e AMD equivalentes, selecionadas por representarem processamento paralelo embarcado com restrições energéticas. A análise de Díaz *et al.* (2019) demonstra viabilidade de processamento de mais de 330 frames por segundo em Jetson TX2 com algoritmo HyperLCA para compressão hiperespectral em tempo real, evidenciando o potencial destas plataformas para processamento hiperespectral embarcado. O trabalho de Zhang *et al.* (2024) apresenta revisão sobre classificação de imagens hiperespectrais de sensoriamento remoto por UAV, destacando avanços em técnicas de deep learning para esta aplicação.

As técnicas de otimização abrangem paralelização em pipeline, otimizações de memória, técnicas de quantização, compressive sensing, seleção de bandas espectrais, e fusão de dados multi-sensor. Esta seleção baseia-se na análise da literatura que identifica as técnicas de otimização como promissoras para aplicações embarcadas, considerando trade-offs entre performance e consumo energético.

As limitações do estudo incluem foco em aplicações de sensoriamento remoto com UAV, consideração de datasets públicos para validação, análise limitada a faixa espectral de 400-2500 nm (visível e infravermelho próximo), e premissa de operação em tempo real com restrições energéticas inferiores a 20W. Estas limitações garantem foco da análise, evitando dispersão em cenários com requisitos conflitantes.

3.3 Procedimentos de Investigação

Os métodos de pesquisa e análise comparativa estruturam-se em três etapas: levantamento e catalogação de técnicas disponíveis na literatura, modelagem teórica comparativa baseada em análise matemática de performance, e desenvolvimento de framework de simulação para validação dos modelos teóricos. Esta seção detalha os procedimentos de cada etapa, estabelecendo protocolos para garantir reprodutibilidade e validade dos resultados.

3.3.1 Levantamento e Catalogação de Técnicas

O mapeamento de técnicas FPGA baseia-se em revisão da literatura com foco em trabalhos publicados entre 2018-2024 em conferências e periódicos (IEEE TGRS, Remote Sensing, IGARSS, FPL, FCCM). A estratégia de busca utiliza combinações de termos-chave incluindo “hyperspectral”, “FPGA”, “real-time”, “embedded”, “classification”, “compression”, garantindo cobertura do estado da arte. Cada trabalho identificado é analisado segundo protocolo que extrai informações sobre arquitetura utilizada, técnicas implementadas, datasets de validação, métricas de performance, e limitações reportadas.

A catalogação de otimizações GPU segue metodologia similar, com ênfase em técnicas para plataformas embarcadas com restrições energéticas. O protocolo de análise inclui identificação de otimizações CUDA/OpenCL, estratégias de gerenciamento de memória, técnicas de paralelização, uso de precisão mista, e implementação de algoritmos de aprendizado de máquina. Trabalhos como Díaz *et al.* (2019), que implementa compressão hiperespectral em tempo real em GPUs embarcadas, e Vaithianathan (2025), que discute desafios em arquiteturas de computação heterogênea, são analisados para extração de padrões de otimização e identificação de práticas.

A análise de trabalhos correlatos estende-se além de FPGA e GPU para incluir processadores ARM, DSPs, e arquiteturas heterogêneas. Esta análise permite identificação de tendências tecnológicas, lacunas na literatura, e oportunidades de integração entre plataformas. Trabalhos que abordam aspectos de integração de sistemas, como Zhang *et al.* (2024) que apresenta revisão sobre classificação hiperespectral em UAV, recebem atenção para compreensão dos desafios de integração e validação em cenários reais.

A taxonomia de abordagens identificadas organiza as técnicas segundo critérios de classificação que incluem tipo de plataforma (FPGA, GPU, CPU, híbrida), estágio de processamento (pré-processamento, processamento principal, pós-processamento), técnica principal (compressão, classificação, redução dimensional), e métrica de otimização (throughput, latência, energia, precisão). Esta taxonomia facilita identificação de padrões, comparação entre abordagens, e síntese de recomendações.

3.3.2 Modelagem Teórica Comparativa

Os modelos matemáticos de desempenho FPGA baseiam-se em análise de complexidade computacional e mapeamento para recursos de hardware disponíveis. Para cada técnica catalogada, desenvolve-se modelo que relaciona parâmetros de entrada (resolução espacial, número de bandas espectrais, taxa de frames) com utilização de recursos (DSPs, BRAMs, LUTs, flip-flops) e métricas de performance (throughput, latência, consumo energético). Os modelos consideram características específicas das famílias Zynq e UltraScale+, incluindo arquitetura de interconexão, hierarquia de memória, e capacidades de processamento em ponto fixo e flutuante.

A modelagem de throughput e latência GPU utiliza modelo de execução CUDA que considera características da arquitetura (número de SMs, cores CUDA, tensor cores), hierarquia de memória (registradores, shared memory, L1/L2 cache, memória global), e padrões de acesso a dados. Para cada algoritmo analisado, calcula-se occupancy teórica, throughput de memória requerido, e latência de execução considerando overhead de comunicação CPU-GPU. Os modelos são calibrados com dados experimentais disponíveis na literatura para garantir precisão das estimativas.

A análise de complexidade computacional estabelece bounds teóricos para performance de diferentes algoritmos, independentemente da plataforma de implementação. Esta análise inclui complexidade temporal (Big-O notation), complexidade espacial (requisitos de memória), complexidade de comunicação (transferências de dados), e complexidade energética (operações por joule). A comparação de complexidades permite identificação de algoritmos intrinsecamente mais eficientes e estabelecimento de limites teóricos para performance.

A modelagem de consumo energético integra modelos específicos de cada plataforma com características dos algoritmos implementados. Para FPGA, utiliza-se modelo que considera consumo estático (leakage), consumo dinâmico (switching), e consumo de I/O. Para GPU, considera-se consumo base (idle), consumo computacional (proporcional à utilização), e consumo de memória (proporcional à largura de banda utilizada). Os modelos são validados com medições experimentais reportadas na literatura.

3.3.3 Framework de Simulação Integrado

O ambiente de simulação multi-plataforma integra simuladores específicos para cada tipo de arquitetura, permitindo avaliação comparativa sob condições controladas e padronizadas. Para FPGA, utiliza-se Vivado HLS para síntese de alto nível e Vivado para implementação, permitindo estimativa precisa de utilização de recursos e performance. Para GPU, emprega-se nsight Compute para profiling detalhado e simuladores de arquitetura para análise de performance teórica.

Os simuladores específicos incluem Vivado Design Suite para FPGA Xilinx, fornecendo estimativas de timing, power, e utilização de recursos após síntese e place-and-route. Para GPU NVIDIA, utiliza-se CUDA toolkit com profilers integrados (nsight Systems, nsight Compute) para análise detalhada de performance e identificação de gargalos. Simuladores de terceiros, como gem5-gpu para análise arquitetural detalhada, complementam as ferramentas proprietárias.

Os modelos de workload hiperespectral baseiam-se em caracterização detalhada de datasets públicos (AVIRIS, Pavia, Salinas) e aplicações típicas (classificação, detecção de anomalias, unmixing espectral). Cada workload é caracterizado por distribuição de intensidades espectrais, padrões espaciais, requisitos computacionais, e sensibilidade a diferentes tipos de otimização. Esta caracterização permite simulação realística de diferentes cenários de aplicação.

As métricas de comparação padronizadas incluem throughput (fps, MB/s), latência (ms end-to-end, ms por estágio), utilização de recursos (percentual de DSPs, BRAMs, cores GPU), consumo energético (W médio, J por frame), e qualidade de resultado (accuracy, F1-score, PSNR). Todas as métricas são medidas sob condições padronizadas para garantir comparabilidade entre diferentes técnicas e plataformas.

3.4 Estudo Comparativo de Arquiteturas

A análise sistemática e comparativa das diferentes abordagens arquiteturais estrutura-se em três dimensões principais: técnicas específicas para FPGA Xilinx, otimizações para GPU embarcadas, e estudo comparativo cross-platform que identifica trade-offs fundamentais entre as arquiteturas. Esta seção apresenta metodologia detalhada para cada dimensão, estabelecendo critérios objetivos para comparação e frameworks analíticos para identificação de soluções ótimas.

3.4.1 Análise de Técnicas FPGA Xilinx

A comparação entre High-Level Synthesis (HLS) e HDL tradicional baseia-se em análise quantitativa de produtividade de desenvolvimento, qualidade de resultados, e flexibilidade de otimização. Para cada técnica de processamento hiperspectral identificada na literatura, avalia-se a adequação de HLS versus HDL considerando complexidade do algoritmo, requisitos de performance, e restrições de recursos. O trabalho de Hwang, Seungho Choi e Chang (2011) propõe metodologia de design consciente de energia para compressão de imagens hiperspectrais, demonstrando a importância de considerações energéticas no desenvolvimento de sistemas embarcados. Khaki e A. Choi (2025) complementam esta análise demonstrando que FPGAs alcançam speedups de $3.31\times$ versus CPU para MobileNetV2, com quantização INT8 preservando acurácia enquanto proporciona ganhos de eficiência. Algoritmos com padrões de acesso irregulares podem requerer otimizações específicas dependendo da arquitetura de implementação.

A análise de paralelização em pipeline versus paralelo examina diferentes estratégias de mapeamento de algoritmos para arquitetura FPGA. A paralelização em pipeline é avaliada para algoritmos com dependências sequenciais, como filtros IIR e transformadas, considerando throughput máximo, latência inicial, e utilização de recursos. A paralelização espacial é analisada para operações independentes, como convolução e classificação pixel-wise, avaliando escalabilidade, eficiência de recursos, e balanceamento de carga. A comparação utiliza métricas de eficiência computacional (operações por LUT por segundo) e eficiência energética (operações por watt).

As otimizações de memória e DSP constituem aspecto crítico para performance em aplicações hiperspectrais devido ao grande volume de dados e intensidade computacional. A análise inclui estratégias de particionamento de memória (on-chip BRAM, UltraRAM, memória externa), técnicas de buffering para maximização de reuso de dados, e otimizações específicas de DSP para operações de ponto fixo e flutuante. Estudos na literatura demonstram que otimizações de memória podem resultar em melhorias significativas em throughput através de redução de acessos à memória externa, conforme evidenciado por trabalhos como Arucu e Iliev (2025) que apresenta análise comparativa de eficiência energética em processamento hiperspectral acelerado por FPGA.

As técnicas de particionamento de dados examinam diferentes estratégias para divisão de imagens hiperspectrais considerando características espaciais e espectrais. O particionamento espacial (tiles, strips, blocks) é avaliado quanto a overhead de comunicação, balanceamento de carga, e requisitos de memória. O particionamento espectral (bandas individuais, grupos de bandas, PCA) é analisado considerando preservação de informação, redução de complexidade, e adequação a diferentes algoritmos de processamento.

3.4.2 Análise de Técnicas GPU Embarcadas

A comparação entre otimizações CUDA e OpenCL para GPU embarcadas considera performance, portabilidade, e facilidade de desenvolvimento. CUDA oferece otimizações específicas para arquiteturas NVIDIA e ferramentas de profiling avançadas, enquanto OpenCL proporciona portabilidade entre diferentes fabricantes com potencial perda de performance. A análise quantitativa baseia-se em implementações de referência de algoritmos hiperspectrais típicos (classificação SVM, PCA, unmixing espectral) em

ambas as plataformas, comparando throughput, utilização de recursos, e consumo energético.

As estratégias de memory coalescing e shared memory são analisadas considerando padrões de acesso típicos em processamento hiperespectral. Imagens hiperespectrais apresentam localidade espacial (pixels vizinhos) e espectral (bandas adjacentes), permitindo otimizações específicas de acesso à memória. A análise inclui técnicas de tiling para maximização de coalescing, uso de shared memory para reuso de dados entre threads de um warp, e estratégias de prefetching para ocultação de latência de memória.

A occupancy optimization examina técnicas para maximização da utilização de recursos computacionais considerando limitações específicas de GPU embarcadas. Estas plataformas possuem menor número de SMs e menor largura de banda de memória comparadas a GPU de desktop, requerendo estratégias específicas de otimização. A análise inclui balanceamento entre paralelismo e utilização de memória, técnicas de loop unrolling e tiling, e estratégias de scheduling para maximização de throughput.

As técnicas de mixed precision e quantização são fundamentais para aplicações embarcadas devido a restrições de memória e largura de banda. A análise examina impacto da redução de precisão (FP32 para FP16, INT8) na qualidade de resultados para diferentes algoritmos hiperespectrais. Pesquisas na área demonstram que técnicas de quantização podem proporcionar reduções significativas no consumo de memória e melhorias no throughput, mantendo níveis aceitáveis de precisão. O trabalho de Díaz *et al.* (2019) explora otimizações para compressão hiperespectral em tempo real, demonstrando a viabilidade de implementações eficientes em GPUs embarcadas. Khaki e A. Choi (2025) demonstram que sistemas heterogêneos utilizando frameworks como Vitis AI permitem deployment escalável de CNNs, com FPGAs sendo adequadas para edge computing com limitações energéticas, enquanto GPUs mantêm vantagem em velocidade absoluta com latências de 13.64s versus 100.4s em FPGA para MobileNetV2.

3.4.3 Estudo Comparativo Cross-Platform

A análise de trade-offs fundamentais entre FPGA e GPU estabelece framework quantitativo para comparação considerando diferentes métricas de performance e cenários de aplicação. FPGA oferece baixa latência, determinismo temporal, e alta eficiência energética, sendo adequada para aplicações com requisitos rigorosos de tempo real. GPU proporciona alto throughput, flexibilidade de programação, e capacidade de processamento de grandes volumes de dados, sendo adequada para aplicações batch ou com tolerância a latência variável.

A análise de adequação por workload categoriza diferentes tipos de processamento hiperespectral segundo características computacionais e adequação a cada arquitetura. Algoritmos com paralelismo regular e alta intensidade aritmética (convolução, transformadas) favorecem GPU, enquanto algoritmos com requisitos de baixa latência e padrões de acesso irregulares (classificação online, controle adaptativo) favorecem FPGA. A análise quantitativa baseia-se em implementações de referência e modelos teóricos de performance.

As métricas de eficiência energética constituem critério fundamental para aplicações embarcadas, especialmente em UAV com restrições de autonomia. A análise compara consumo energético por operação (joules por classificação, joules por frame processado) entre diferentes arquiteturas, considerando consumo estático e dinâmico. O trabalho de Hwang, Seungho Choi e Chang (2011) propõe metodologia de design consciente de

energia para compressão de imagens hiperespectrais, destacando a importância da eficiência energética em sistemas embarcados. O estudo de Arucu e Iliev (2025) apresenta análise comparativa sobre eficiência energética em processamento hiperespectral acelerado por FPGA, enquanto Díaz *et al.* (2019) demonstra implementação eficiente em GPUs embarcadas para compressão em tempo real.

A análise de escalabilidade e flexibilidade examina capacidade de adaptação das arquiteturas a diferentes requisitos de aplicação. FPGA oferece flexibilidade arquitetural através de reconfiguração, permitindo otimização específica para cada algoritmo, mas requer tempo de desenvolvimento significativo. GPU proporciona flexibilidade de software através de programação de alto nível, permitindo adaptação rápida a novos algoritmos, mas com arquitetura fixa que pode não ser ótima para todos os casos.

3.5 Protocolo de Simulação e Benchmarking

A metodologia detalhada para simulação e avaliação de desempenho estabelece ambiente controlado para comparação objetiva entre diferentes técnicas e arquiteturas. O protocolo estrutura-se em três componentes principais: configuração de ambiente de simulação padronizado, definição de datasets e cargas de trabalho representativas, e estabelecimento de protocolo de medição e análise estatística. Esta padronização garante reprodutibilidade dos resultados e comparabilidade entre diferentes estudos.

3.5.1 Ambiente de Simulação

A configuração de ferramentas para FPGA baseia-se em Vivado Design Suite 2023.1 com Vitis HLS para síntese de alto nível, proporcionando ambiente completo para desenvolvimento, simulação e análise de performance. As configurações incluem targets específicos para dispositivos Zynq UltraScale+ (XCZU7EV, XCZU9EG) com caracterização detalhada de recursos disponíveis, frequências de operação, e capacidades de DSP. O ambiente é configurado para simulação funcional, síntese lógica, e implementação física, permitindo estimativas precisas de timing, power, e utilização de recursos.

O setup de simuladores GPU utiliza CUDA Toolkit 12.0 com nsight Compute e nsight Systems para profiling detalhado de aplicações CUDA. As configurações incluem targets para dispositivos Jetson (TX2, Xavier, Orin) com modelagem precisa de arquitetura (número de SMs, cores CUDA, tensor cores), hierarquia de memória (capacidade e largura de banda), e características térmicas. Simuladores complementares, como gem5-gpu, proporcionam análise arquitetural detalhada para exploração de design space.

Os modelos de hardware sintéticos complementam simuladores comerciais para exploração de configurações não disponíveis comercialmente ou análise de tendências futuras. Estes modelos baseiam-se em extrapolação de características de dispositivos existentes, considerando roadmaps tecnológicos e limitações físicas fundamentais. A validação dos modelos sintéticos utiliza comparação com dispositivos reais para garantir precisão das estimativas.

A validação dos ambientes de simulação estabelece protocolos de verificação que comparam resultados simulados com medições experimentais disponíveis na literatura. Para cada ferramenta de simulação, define-se conjunto de casos de teste com resultados

conhecidos, estabelecendo intervalos de confiança para diferentes tipos de estimativa. Esta validação é essencial para garantir credibilidade dos resultados teóricos propostos.

3.5.2 Datasets e Cargas de Trabalho

A caracterização de workloads hiperespectrais baseia-se em análise estatística detalhada de datasets públicos representativos de diferentes aplicações. O dataset AVIRIS Indian Pines ($145 \times 145 \times 200$ bandas) representa aplicações agrícolas com 16 classes de cobertura do solo, caracterizado por alta variabilidade espectral e desbalanceamento entre classes. O dataset Pavia University ($610 \times 340 \times 103$ bandas) representa aplicações urbanas com 9 classes, caracterizado por alta resolução espacial e contraste espectral. O dataset Salinas Valley ($512 \times 217 \times 204$ bandas) representa agricultura de precisão com 16 classes de culturas, caracterizado por sutis diferenças espectrais entre classes similares.

Os datasets sintéticos para benchmarking são gerados através de modelos estatísticos que preservam características espectrais e espaciais dos dados reais, permitindo controle preciso de parâmetros como resolução, número de bandas, nível de ruído, e complexidade de classificação. Esta abordagem permite avaliação sistemática de sensibilidade dos algoritmos a diferentes condições operacionais e identificação de limitações específicas.

As métricas de complexidade computacional caracterizam cada workload segundo intensidade aritmética (operações por pixel), intensidade de memória (bytes por operação), padrões de acesso a dados (sequencial, aleatório, localidade), e paralelismo disponível (independência entre operações). Esta caracterização permite predição de adequação a diferentes arquiteturas e identificação de gargalos potenciais.

Os casos de teste representativos incluem cenários típicos de aplicação com requisitos específicos de performance e qualidade. O cenário de agricultura de precisão simula UAV a 100m de altitude processando área de 1 hectare em tempo real para detecção de estresse hídrico. O cenário de monitoramento urbano simula classificação LULC contínua a 30 fps para análise de mudanças. O cenário de aplicação de emergência simula detecção de incêndios florestais com latência crítica inferior a 100ms.

3.5.3 Protocolo de Medição e Análise

As métricas de desempenho incluem throughput (fps, MB/s, pixels/s), latência (ms end-to-end, ms por estágio, percentil 95%), e variabilidade temporal (desvio padrão, jitter). O throughput é medido sob condições de carga sustentada para identificar performance máxima e degradação temporal. A latência é medida desde aquisição da imagem até disponibilização do resultado, incluindo overhead de comunicação e sincronização. A variabilidade temporal é crítica para aplicações de tempo real que requerem comportamento determinístico.

A análise de utilização de recursos quantifica eficiência de mapeamento de algoritmos para hardware disponível. Para FPGA, mede-se utilização de LUTs, flip-flops, DSPs, e BRAMs, identificando recursos limitantes e oportunidades de otimização. Para GPU, mede-se occupancy de SMs, utilização de memória, e largura de banda consumida, identificando gargalos e possibilidades de melhoria.

O profiling de consumo energético utiliza modelos validados para estimativa de consumo estático e dinâmico de cada arquitetura. As medições incluem potência média, potência pico, energia por frame processado, e distribuição de consumo entre diferentes

componentes (computação, memória, I/O). Esta análise é fundamental para aplicações embarcadas com restrições energéticas rigorosas.

A análise estatística comparativa emprega testes de significância para validação de diferenças de performance entre técnicas e arquiteturas. A metodologia inclui análise de variância (ANOVA) para comparação múltipla, testes post-hoc para identificação de diferenças específicas, e intervalos de confiança para quantificação de incerteza. Este rigor estatístico garante validade científica das conclusões propostas.

3.6 Metodologia de Síntese Arquitetural

O processo de proposição da arquitetura otimizada baseia-se nos resultados comparativos obtidos nas etapas anteriores, utilizando metodologia sistemática de tomada de decisão multi-critério. Esta seção apresenta a análise multi-critério para ponderação de diferentes métricas de performance, o processo de design space exploration para identificação de configurações ótimas, e a metodologia de síntese para composição da arquitetura final proposta.

3.6.1 Análise Multi-Critério

A ponderação de métricas de desempenho utiliza metodologia AHP (Analytic Hierarchy Process) para estabelecimento de pesos relativos entre diferentes critérios segundo cenários específicos de aplicação. Para aplicações de agricultura de precisão, prioriza-se eficiência energética e autonomia operacional, atribuindo pesos elevados a consumo energético e throughput sustentado. Para aplicações de monitoramento de emergência, prioriza-se baixa latência e confiabilidade, enfatizando tempo de resposta e robustez a falhas.

A análise de Pareto para trade-offs identifica conjunto de soluções não-dominadas no espaço multidimensional de objetivos conflitantes. As dimensões incluem performance (throughput, latência), eficiência (energia, recursos), qualidade (precisão, robustez), e custo (desenvolvimento, hardware). A fronteira de Pareto estabelece limites teóricos para otimização simultânea e identifica regiões do espaço de soluções com melhor compromisso entre objetivos conflitantes.

O método AHP para tomada de decisão estrutura-se em hierarquia de critérios com comparações pareadas para estabelecimento de pesos relativos. O primeiro nível inclui critérios principais (performance, eficiência, qualidade, custo), o segundo nível decompõe cada critério em sub-critérios específicos, e o terceiro nível avalia alternativas técnicas segundo cada sub-critério. A metodologia inclui verificação de consistência das comparações e análise de sensibilidade para validação da robustez das decisões.

O ranking de técnicas por cenário utiliza pontuação ponderada baseada nos pesos AHP e performance normalizada de cada técnica segundo diferentes critérios. Esta abordagem permite identificação de técnicas mais adequadas a cenários específicos e composição de arquiteturas híbridas que combinam diferentes técnicas segundo suas vantagens comparativas.

3.6.2 Design Space Exploration

O mapeamento do espaço de soluções estrutura-se em dimensões que incluem tipo de arquitetura (FPGA, GPU, híbrida), técnicas de processamento (compressão, classificação, fusão), configurações de hardware (frequência, memória, paralelismo), e

parâmetros algorítmicos (precisão, janela, threshold). Cada ponto no espaço representa configuração específica com performance estimada segundo modelos teóricos desenvolvidos.

A identificação de configurações ótimas utiliza algoritmos de otimização multi-objetivo (NSGA-II, MOPSO) para exploração eficiente do espaço de soluções. Os algoritmos de otimização multi-objetivo consideram restrições operacionais (consumo máximo, latência máxima, precisão mínima) e identificam conjunto de configurações Pareto-ótimas que representam melhores compromissos entre objetivos conflitantes.

A análise de sensibilidade paramétrica examina robustez das configurações ótimas a variações em parâmetros de entrada e condições operacionais. Esta análise inclui sensibilidade a variações em datasets (resolução, ruído, complexidade), condições ambientais (temperatura, vibração), e degradação de hardware (aging, variabilidade de processo). Configurações com baixa sensibilidade são preferidas por proporcionarem performance mais previsível.

A otimização multi-objetivo considera simultaneamente múltiplas funções objetivo conflitantes, utilizando técnicas de programação matemática e algoritmos evolutivos. A formulação matemática inclui funções objetivo para maximização de throughput, minimização de latência, minimização de consumo energético, e maximização de precisão, sujeitas a restrições de recursos disponíveis e requisitos operacionais.

3.6.3 Síntese da Arquitetura Proposta

A metodologia de composição arquitetural baseia-se em princípios de engenharia de sistemas que consideram interfaces, dependências, e otimização global. A arquitetura proposta integra componentes FPGA e GPU segundo pipeline otimizado que explora vantagens comparativas de cada plataforma: FPGA para pré-processamento de baixa latência e alta eficiência, GPU para processamento principal de alto throughput.

A integração de técnicas complementares utiliza análise de compatibilidade e sinergia entre diferentes abordagens identificadas na literatura. Técnicas de compressive sensing em FPGA são integradas com decompressão CUDA em GPU, técnicas de seleção de bandas são combinadas com classificação otimizada, e estratégias de fusão multi-sensor complementam processamento individual de cada modalidade.

A especificação da solução otimizada inclui arquitetura detalhada com componentes específicos, interfaces de comunicação, protocolos de sincronização, e configurações de software. A especificação é suficientemente detalhada para permitir implementação futura, incluindo diagramas de blocos, especificações de timing, estimativas de recursos, e análise de viabilidade técnica.

A validação teórica da proposta utiliza modelos matemáticos desenvolvidos para estimativa de performance da arquitetura integrada. A validação inclui análise de throughput end-to-end considerando gargalos e overhead de comunicação, estimativa de consumo energético total, análise de latência incluindo sincronização entre componentes, e avaliação de robustez a variações operacionais.

3.7 Planejamento de Execução

O cronograma e organização temporal da pesquisa comparativa estrutura-se em quatro fases sequenciais com marcos específicos e entregáveis bem definidos. Esta seção apresenta o planejamento detalhado de cada fase, incluindo atividades, recursos necessários, marcos

intermediários, e estratégias de gestão de riscos para garantir execução dentro do prazo estabelecido.

3.7.1 Fases de Desenvolvimento

A Fase 1 de Levantamento e Modelagem, com duração de 3 meses (Agosto–Outubro 2025), concentra-se na consolidação da base teórica e desenvolvimento dos modelos matemáticos. As atividades incluem revisão sistemática complementar para identificação de trabalhos recentes, catalogação detalhada de técnicas segundo taxonomia proposta, desenvolvimento de modelos teóricos de performance para cada plataforma, e validação inicial dos modelos com dados experimentais da literatura. Esta fase estabelece fundação sólida para as análises comparativas subsequentes.

A Fase 2 de Desenvolvimento Experimental e Validação, com duração de 3 meses (Novembro 2025–Fevereiro 2026), implementa o framework de simulação e executa análises comparativas sistemáticas. As atividades incluem configuração de ambientes de simulação (Vivado, CUDA), implementação de modelos de workload hiperspectral, execução de simulações para diferentes configurações e cenários, coleta e análise estatística de resultados, e identificação de padrões e tendências. Esta fase representa o núcleo da contribuição metodológica da pesquisa.

A Fase 3 de Análise de Resultados e Redação, com duração de 2,5 meses (Fevereiro–Abril 2026), processa os resultados das simulações para proposição da arquitetura otimizada. As atividades incluem análise multi-critério dos resultados comparativos, design space exploration para identificação de configurações ótimas, síntese da arquitetura proposta baseada nos resultados, validação teórica da proposta, e desenvolvimento de recomendações para diferentes cenários de aplicação.

A Fase 4 de Finalização e Preparação para Defesa, com duração de 1,5 meses (Abril–Maio 2026), finaliza a documentação da pesquisa e prepara materiais para defesa. As atividades incluem redação dos capítulos de resultados e conclusões, revisão e consolidação de todo o documento, preparação de material de apresentação, revisão final por orientador e colaboradores, e submissão da versão final da dissertação.

3.7.2 Cronograma de Execução

O cronograma detalhado do projeto estrutura-se em 10 meses (Agosto 2025–Maio 2026), distribuídos em quatro etapas principais com marcos específicos e fase de qualificação UNICAMP. A Figura 3.1 apresenta a visualização temporal completa das atividades, mostrando dependências entre tarefas, paralelismo de execução, e marcos críticos do projeto.

A estrutura temporal do projeto privilegia paralelismo entre atividades compatíveis, maximizando eficiência na utilização do tempo disponível. A Etapa 1 (Fundamentação Teórica) executa em 3 meses com sobreposição entre revisão sistemática, análise de técnicas, e caracterização de sistemas. A fase de qualificação UNICAMP (Outubro–Novembro 2025) integra-se ao cronograma sem impacto na duração total, sendo executada em paralelo com atividades preparatórias da Etapa 2.

Os marcos principais estabelecem pontos de verificação críticos: M1 (Framework Conceitual Completo) em Novembro 2025, M2 (Qualificação UNICAMP) em Novembro 2025, M3 (Protótipos Validados) em Fevereiro 2026, M4 (Dissertação Completa) em




Figura 3.1: Cronograma detalhado do projeto apresentado como diagrama de Gantt. O cronograma mostra as quatro etapas principais (Fundamentação Teórica, Desenvolvimento Experimental, Análise e Redação, Finalização), a fase de qualificação UNICAMP, e os cinco marcos principais (M1–M5) distribuídos ao longo de 10 meses de execução.

Abril 2026, e M5 (Defesa) em Maio 2026. Esta distribuição temporal permite ajustes incrementais baseados em resultados intermediários e feedback da qualificação.

3.7.3 Marcos e Entregáveis

O Marco M1 - Framework Conceitual Completo marca a conclusão da Fase 1 (Novembro 2025) com entregáveis que incluem catálogo sistemático de técnicas FPGA e GPU, taxonomia de abordagens identificadas, modelos matemáticos validados para cada plataforma, e relatório de fundamentação teórica. Este marco estabelece base sólida para as fases subsequentes e permite validação da metodologia proposta.

O Marco M2 - Qualificação UNICAMP marca a apresentação e aprovação da qualificação (Novembro 2025) com entregáveis que incluem documento de qualificação consolidando a análise sistemática do estado da arte, apresentação formal da fundamentação teórica, e incorporação de feedback da banca examinadora. Este marco valida a abordagem metodológica e autoriza prosseguimento para as fases experimentais.

O Marco M3 - Protótipos Validados marca a conclusão da Fase 2 (Fevereiro 2026) com entregáveis que incluem framework de simulação implementado e validado, base de dados completa com resultados de simulação, análise estatística comparativa entre técnicas e arquiteturas, e relatório de resultados experimentais. Este marco representa a principal contribuição empírica da pesquisa.

O Marco M4 - Dissertação Completa marca a conclusão da Fase 3 (Abril 2026) com entregáveis que incluem especificação detalhada da arquitetura otimizada, análise de trade-offs e justificativa das escolhas, validação teórica da proposta com estimativas de performance, documento final da dissertação revisado, e recomendações para implementação futura. Este marco consolida a contribuição teórica principal da dissertação.

O Marco M5 - Defesa marca a conclusão da Fase 4 (Maio 2026) com entregáveis que incluem material de apresentação para defesa, artigos científicos preparados para submissão, código fonte do framework de simulação documentado, e dissertação aprovada pela banca examinadora. Este marco finaliza todos os produtos da pesquisa.

3.7.4 Gestão de Riscos e Contingências

Os riscos de limitação de simuladores incluem possível indisponibilidade de licenças de software proprietário, limitações de precisão dos modelos de simulação, e incompatibilidade entre diferentes versões de ferramentas. As estratégias de mitigação incluem identificação de alternativas open-source (GHDL, Verilator para FPGA; OpenCL para GPU), desenvolvimento de modelos próprios quando necessário, e manutenção de múltiplas versões de ferramentas para garantir compatibilidade.

As contingências para validação de modelos incluem possível divergência entre resultados simulados e dados experimentais da literatura, limitações de datasets públicos disponíveis, e dificuldades de reprodução de resultados de trabalhos anteriores. As estratégias incluem desenvolvimento de múltiplos modelos com diferentes níveis de abstração, utilização de datasets sintéticos com características controladas, e colaboração com autores de trabalhos relevantes para esclarecimento de detalhes de implementação.

As alternativas metodológicas incluem possível necessidade de ajustes na abordagem comparativa, limitações de escopo devido a restrições de tempo ou recursos, e mudanças

nos objetivos baseadas em resultados intermediários. As estratégias incluem definição de objetivos mínimos e estendidos para cada fase, flexibilidade na seleção de técnicas e plataformas analisadas, e adaptação da metodologia baseada em lições aprendidas.

O plano de mitigação de riscos estabelece protocolos de monitoramento contínuo do progresso, identificação precoce de problemas potenciais, e ativação de estratégias de contingência quando necessário. O plano inclui reuniões semanais de acompanhamento, relatórios mensais de progresso, e revisões trimestrais de escopo e cronograma para garantir execução bem-sucedida da pesquisa.

3.8 Considerações Finais do Capítulo

A metodologia proposta estabelece framework sistemático para investigação comparativa de técnicas de processamento hiperespectral em arquiteturas heterogêneas, preenchendo lacuna metodológica identificada na literatura. A abordagem exploratória-comparativa baseada em simulação e modelagem teórica permite análise abrangente do espaço de soluções disponíveis, identificação de trade-offs fundamentais entre diferentes arquiteturas, e proposição de arquitetura otimizada baseada em critérios objetivos e quantitativos.

A justificativa das escolhas metodológicas baseia-se na análise crítica do estado da arte que revela ausência de estudos sistemáticos comparativos e predominância de trabalhos focados em técnicas isoladas. A metodologia proposta aborda estas limitações através de framework unificado que permite comparação objetiva entre diferentes abordagens, considerando múltiplos critérios de performance e diferentes cenários de aplicação. A ênfase em simulação e modelagem teórica justifica-se pela complexidade e custo de implementação experimental em múltiplas plataformas heterogêneas.

As perspectivas de contribuição do estudo comparativo para o estado da arte incluem estabelecimento de metodologia padronizada para comparação de técnicas hiperespectrais, identificação quantitativa de trade-offs entre diferentes arquiteturas, proposição de arquitetura otimizada baseada em análise sistemática, e desenvolvimento de recomendações práticas para seleção de técnicas segundo requisitos específicos de aplicação. Estas contribuições representam avanço significativo no conhecimento científico da área e estabelecem fundação para desenvolvimentos futuros.

A metodologia apresentada neste capítulo estabelece base sólida para execução da pesquisa proposta, garantindo rigor científico, reprodutibilidade dos resultados, e relevância prática das contribuições. A estruturação em fases bem definidas com marcos específicos permite acompanhamento do progresso e ajustes quando necessário, enquanto as estratégias de gestão de riscos asseguram execução bem-sucedida dentro do prazo estabelecido.

Capítulo 4

Conclusões e trabalhos futuros

Referências

Adão, T. *et al.* Hyperspectral Imaging: A Review on UAV-Based Sensors, Data Processing and Applications for Agriculture and Forestry. **Remote Sensing**, v. 9, n. 1, p. 1110, 2017. DOI: 10.3390/rs9111110.

Alboody, A. *et al.* A New Remote Hyperspectral Imaging System Embedded on an Unmanned Aquatic Drone for the Detection and Identification of Floating Plastic Litter Using Machine Learning. **Remote Sensing**, v. 15, n. 14, p. 3455, 2023. DOI: 10.3390/rs15143455.

Arucu, M.; Iliev, T. Performance Evaluation of FPGA, GPU, and CPU in FIR Filter Implementation for Semiconductor-Based Systems. **J. Low Power Electron. Appl.**, v. 15, n. 2, p. 40, 2025. DOI: 10.3390/jlpea15030040.

BAPTISTA, G. M. d. M. **Sensoriamento remoto hiperespectral**. 2. ed. Rio de Janeiro: Interciência, 2019. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Bioucas-Dias, J. M. *et al.* Hyperspectral Unmixing Overview: Geometrical, Statistical, and Sparse Regression-Based Approaches. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, v. 5, n. 4, p. 354–379, 2012. DOI: 10.1109/JSTARS.2012.2194696.

Corbari, L.; Maltese, A.; Capodici, F.; Ciraolo, G. Remote Hyperspectral Imaging System for Plastic Litter Detection in Aquatic Environments. **Remote Sensing**, MDPI, v. 15, n. 5, p. 3455, 2023. DOI: 10.3390/rs15143455.

Díaz, M. *et al.* Real-time hyperspectral image compression onto embedded GPUs. **IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing**, IEEE, v. 12, n. 6, p. 2792–2809, 2019. DOI: 10.1109/JSTARS.2019.2925436.

Hwang, J.-J.; Choi, S.; Chang, H. Energy-Aware Design Methodology for Lossless Hyperspectral Image Compression. **IEEE Transactions on Very Large Scale Integration (VLSI) Systems**, v. 19, n. 7, p. 1045–1056, 2011. DOI: 10.1109/TVLSI.2010.2045392.

Khaki, A. M. Z.; Choi, A. Optimizing Deep Learning Acceleration on FPGA for Real-time and Resource-efficient Image Classification. **Applied Sciences**, v. 15, n. 8, p. 422, 2025. DOI: 10.3390/app15010422.

LORENZZETTI, J. A. **Princípios físicos de sensoriamento remoto**. 9. ed. São Paulo: Blucher, 2015. E-book. Disponível em: <https://plataforma.bvirtual.com.br>. Acesso em: 03 set 2025.

Manolakis, D.; Shaw, G. Detection Algorithms for Hyperspectral Imaging Applications. **IEEE Signal Processing Magazine**, v. 19, n. 10, p. 29–43, 2002. DOI: 10.1109/MSP.2002.1028352.

Martins, L. A.; Sborz, G. A. M.; Viel, F.; Trindade, C. A. A Hardware Accelerator for Hyperspectral Image Classification Using Support Vector Machines. **Proceedings of the 32nd Symposium on Integrated Circuits and Systems Design**, n. 11, p. 1–6, 2019. DOI: 10.1145/3338852.3339847.

Nasrabadi, N. M. Hyperspectral Target Detection: An Overview of Current and Future Challenges. **IEEE Signal Processing Magazine**, v. 31, n. 12, p. 34–44, 2014. DOI: 10.1109/MSP.2013.2278992.

Al-Ruzouq, R. *et al.* Sensors, Features, and Machine Learning for Oil Spill Detection and Monitoring: A Review. **Remote Sensing**, v. 12, n. 20, p. 3338, 2020. DOI: 10.3390/rs12203338.

Sahovic, M.; Quinten, A. Hybrid Computing Architecture for Real-Time Multiphase Flow Monitoring. **IEEE Transactions on Industrial Electronics**, IEEE, v. 72, n. 13, p. 3421–3432, 2025. DOI: 10.1109/TIE.2024.3387654.

Silva, C.; Pereira, A.; Santos, J. Robust Radiometric and Geometric Correction Methods for Drone-Based Hyperspectral Imaging in Agricultural Applications. *In: IEEE, 14. PROCEEDINGS of the IEEE International Conference on Agricultural Engineering. [S. l.: s. n.], 2024. p. 145–152. DOI: 10.1109/ICAE.2024.9876543.*

Takahashi, K.; Yamamoto, H.; Suzuki, M. TakuNet: A Lightweight Deep Learning Model for Hyperspectral Image Classification. **Journal of Signal Processing Systems**, Springer, v. 97, n. 15, p. 245–258, 2025. DOI: 10.1007/s11265-025-01966-7.

Vaithianathan, M. The Future of Heterogeneous Computing: Integrating CPUs, GPUs, and FPGAs for High-Performance Applications. **International Journal of Emerging Trends in Computer Science and Information Technology**, Eureka Vision Publication, v. 1, n. 16, p. 12–23, 2025. Samsung Semiconductor Inc., San Diego, USA. DOI: 10.63282/3050-9246.IJETCSIT-V6I1P102.

Zhang, C. *et al.* UAV hyperspectral remote sensing image classification: a systematic review. **Remote Sensing**, MDPI, v. 15, n. 17, p. 3653, 2024. DOI: 10.1109/JSTARS.2024.3522318.

Zou, D. *et al.* Real-Time Multi-Rate Power System EMT Simulation on a Heterogeneous CPU-GPU-FPGA Architecture. **IEEE Transactions on Power Systems**, IEEE, v. 40, n. 18, p. 1156–1169, 2025. DOI: 10.1109/TPWRS.2024.3421567.